Riesgo Geopolítico y Volatilidad en los Mercados Financieros: Un Enfoque Basado en Machine Learning e Inteligencia Artificial

Octubre 2026



Universidad Internacional de Valencia

Titulación:

Máster Universitario en Big Data y Ciencia de Datos

Curso académico:

2025 – 2026

Alumno:

Leonardo Jesus Villarreal Marcano

Pasaporte: 201023402

Directora de TFT:

Edith Cecilia Macedo Ruiz

Convocatoria:

Periodo 3

De:

Planeta Formación y Universidades

Riesgo Geopolítico y Volatilidad en los Mercados Financieros: Un Enfoque Basado en Machine Learning e Inteligencia Artificial

Leonardo Jesus Villarreal Marcano

RESUMEN

Este trabajo evalúa si el riesgo geopolítico mejora la predicción de la volatilidad de cinco familias de activos financieros, representadas por seis series, y qué tipos de evento geopolítico concentran su contribución. Las familias son la renta variable (S&P 500), la energía (petróleo Brent y WTI), los metales preciosos (oro), la deuda soberana (bono del Tesoro estadounidense a diez años) y los criptoactivos (Bitcoin). El riesgo geopolítico se mide con el índice AI-GPR, construido con modelos de lenguaje, que permite separar su intensidad de su composición por siete tipos de evento: conflicto militar, tensión diplomática, terrorismo, guerra civil, amenaza nuclear, golpe de Estado y sanciones. La volatilidad se mide como volatilidad realizada a partir de rendimientos diarios, en horizontes semanal y mensual.

Se compara el modelo econométrico HAR con tres modelos de aprendizaje automático (Elastic Net, SVR y XGBoost). Cada modelo se estima con tres conjuntos de variables, el primero con la volatilidad pasada, el segundo con la intensidad del riesgo geopolítico y el tercero, solo en el horizonte mensual, con su composición por tipos de evento. Con la volatilidad pasada, el HAR es el modelo de referencia (HAR-RV), y con información geopolítica se convierte en su extensión lineal (HAR-X). Los modelos se entrenan con datos hasta 2021 y se evalúan fuera de muestra entre enero de 2022 y agosto de 2026, con reestimación mensual y la QLIKE como pérdida principal. La mejora predictiva se contrasta con los tests de Clark-West y Diebold-Mariano y con el conjunto de confianza de modelos, y la contribución de cada variable se mide con valores SHAP y con la importancia por permutación. Se incluyen seis pruebas de robustez y la validación de la reproducibilidad del flujo.

La intensidad del riesgo geopolítico mejora la predicción del modelo principal en un único caso, Bitcoin en el horizonte mensual, donde reduce la pérdida un 7,8 % frente al HAR-RV. Esta mejora resiste el ajuste por comparaciones múltiples, aunque la mayor ganancia del modelo no lineal frente al HAR-X no es significativa. En la energía solo aparecen mejoras en modelos secundarios del horizonte semanal, concentradas en episodios de tensión. En el resto de familias la intensidad no mejora la predicción, y en el oro la deteriora. La composición por tipos de evento no mejora a la intensidad en ningún modelo principal, aunque los modelos le asignan una contribución considerable, lo que distingue lo que un modelo usa de lo que efectivamente le ayuda a predecir. Los resultados son compatibles con un cambio en la relación entre riesgo geopolítico y volatilidad del entrenamiento a la prueba, periodo en el que el peso del conflicto militar se duplica.

Palabras clave: riesgo geopolítico, índice AI-GPR, predicción de la volatilidad, HAR-RV, aprendizaje automático, SHAP.

Objetivos de desarrollo sostenible (ODS): 8. Trabajo decente y crecimiento económico, 9. Industria, innovación e infraestructura, 16. Paz, justicia e instituciones sólidas.

Geopolitical Risk and Volatility in Financial Markets: A Machine Learning and Artificial Intelligence Approach

Leonardo Jesus Villarreal Marcano

ABSTRACT

This study assesses whether geopolitical risk improves volatility forecasts for five asset classes, represented by six series, and which types of geopolitical event account for its contribution. The asset classes are equities (S&P 500), energy (Brent and WTI crude oil), precious metals (gold), sovereign debt (10-year US Treasury bond) and crypto-assets (Bitcoin). Geopolitical risk is measured with the AI-GPR index, built with language models, which separates its intensity from its composition across seven event types: military conflict, diplomatic tension, terrorism, civil war, nuclear threat, coup d'état and sanctions. Volatility is measured as realized volatility from daily returns, at weekly and monthly horizons.

The econometric HAR model is compared with three machine learning models (Elastic Net, SVR and XGBoost). Each model is estimated with three sets of variables, the first with past volatility, the second with the intensity of geopolitical risk and the third, at the monthly horizon only, with its composition by event type. With past volatility, the HAR is the benchmark model (HAR-RV), and with geopolitical information it becomes its linear extension (HAR-X). The models are trained on data up to 2021 and evaluated out of sample between January 2022 and August 2026, with monthly re-estimation and QLIKE as the main loss function. Forecast improvements are assessed with the Clark-West and Diebold-Mariano tests and the model confidence set, and the contribution of each variable is measured with SHAP values and permutation importance. The study includes six robustness checks and a validation of the reproducibility of the workflow.

Geopolitical risk intensity improves the forecast of the main model in a single case, Bitcoin at the monthly horizon, where it reduces the loss by 7.8% relative to the HAR-RV. This improvement survives the adjustment for multiple comparisons, although the larger gain of the nonlinear model over the HAR-X is not significant. In energy, improvements appear only in secondary models at the weekly horizon and are concentrated in episodes of tension. In the remaining asset classes, intensity does not improve forecasts, and for gold it worsens them. The composition by event type does not improve on intensity in any main model, although the models assign it a considerable contribution, which distinguishes what a model uses from what actually helps it forecast. The results are consistent with a change in the relationship between geopolitical risk and volatility from the training to the test period, during which the weight of military conflict doubles.

Keywords: geopolitical risk, AI-GPR index, volatility forecasting, HAR-RV, machine learning, SHAP.

Sustainable Development Goals (SDGs): 8. Decent work and economic growth, 9. Industry, innovation and infrastructure, 16. Peace, justice and strong institutions.

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL

En la elaboración de este trabajo se han empleado herramientas de inteligencia artificial generativa como apoyo en tareas concretas, siempre bajo la supervisión y la responsabilidad del autor. Esta declaración describe las fases de aplicación del trabajo y el alcance, de acuerdo con los principios de integridad académica y uso responsable. La tabla 1 distingue para cada fase la contribución de la herramienta y la del autor.

Tabla 1: Uso de herramientas de inteligencia artificial por fase del trabajo.

Fase	Uso	Intervención del autor
Revisión de estructura, redacción y estilo	Revisión complementaria de integridad del documento para mejorar la estructura, narrativa, estilo y ortografía	Decisión sobre cada cambio propuesto, y contraste y adaptación de cada cada propuesta de mejora. Revisión, corrección y reescritura de cada sección. Verificación de cifras.
Programación	Compañero de código para completación, mejoras y diagnóstigo de errores de código	Diseño del flujo de trabajo, implementación, validación de resultados y ejecución reproducible
Revisión de referencias	Comprobación de integridad referencial en el documento	Verificación de cada referencia y contraste con las fuentes.

Las herramientas de inteligencia artificial no se han empleado para generar datos, estimar modelos ni producir resultados. Todas las cifras de esta memoria proceden de la ejecución del notebook descrito en el capítulo 3, cuyo código está disponible en el repositorio del trabajo. El planteamiento del problema, el diseño metodológico, la formulación de las hipótesis y la interpretación de los resultados son responsabilidad del autor, que ha tomado cada decisión.

A Dios.

A mi Familia.

A quienes han enriquecido mi pasión por el conocimiento.

ÍNDICE GENERAL

RESUMEN ii

ABSTRACT iii

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL iv

ÍNDICE GENERAL vi

ÍNDICE DE TABLAS viii

ÍNDICE DE FIGURAS ix

INTRODUCCIÓN 1

1 MARCO TEÓRICO Y ESTADO DEL ARTE 4
- 1.1 La medición del riesgo geopolítico y sus tipos de evento . . . 4
- 1.2 La predicción de la volatilidad realizada . . . 5
- 1.3 Transmisión del riesgo geopolítico a la volatilidad . . . 7
- 1.4 Aportación del trabajo e hipótesis . . . 10

2 DATOS Y METODOLOGÍA 13
- 2.1 Datos . . . 13
  - 2.1.1 El índice AI-GPR . . . 13
  - 2.1.2 Familias de activos y series . . . 14
  - 2.1.3 Control de calidad y limpieza . . . 15
- 2.2 Análisis descriptivo y exploratorio . . . 16
  - 2.2.1 Estadísticos descriptivos . . . 16
  - 2.2.2 Evolución del riesgo geopolítico y de la volatilidad . . . 17
- 2.3 Variable objetivo . . . 20
- 2.4 Variables predictoras . . . 21
- 2.5 Modelos . . . 22
  - 2.5.1 Modelo de referencia y extensión lineal . . . 23
  - 2.5.2 Elastic Net . . . 23
  - 2.5.3 Máquinas de vectores de soporte para regresión . . . 23
  - 2.5.4 XGBoost . . . 24
- 2.6 Diseño de la evaluación fuera de muestra . . . 24
  - 2.6.1 Partición, estimación y ajuste de hiperparámetros . . . 24
  - 2.6.2 Métricas . . . 25
  - 2.6.3 Contrastes y criterios de resolución . . . 25
- 2.7 Interpretabilidad . . . 26
- 2.8 Pruebas de robustez . . . 28

3 DESARROLLO EXPERIMENTAL **29**
3.1 Organización de la implementación . . . 29
3.2 Construcción y depuración del conjunto de datos . . . 29
3.3 Cambios de contrato en las series de energía . . . 31
3.4 Validación de la alineación temporal de Bitcoin . . . 31
3.5 Ajuste de hiperparámetros . . . 32
3.6 Reproducibilidad . . . 33

4 RESULTADOS Y DISCUSIÓN **34**
4.1 Resultados principales . . . 34
4.2 Resultados por familia de activos . . . 35
4.2.1 Renta variable . . . 37
4.2.2 Energía . . . 37
4.2.3 Metales preciosos . . . 39
4.2.4 Deuda soberana . . . 41
4.2.5 Criptoactivos . . . 42
4.3 Análisis comparativo entre familias de activos . . . 44
4.3.1 La intensidad del riesgo geopolítico . . . 44
4.3.2 La composición por tipos de evento . . . 45
4.3.3 Análisis exploratorio de la persistencia . . . 49
4.4 Pruebas de robustez . . . 50
4.5 Resolución de las hipótesis . . . 52
4.6 Discusión . . . 53
4.6.1 Diálogo con la literatura . . . 53
4.6.2 Lectura de los resultados a través de los canales de transmisión . . . 54
4.6.3 Sensibilidad de los resultados al ajuste de hiperparámetros . . . 54
4.6.4 Implicaciones . . . 55

CONCLUSIONES, RECOMENDACIONES Y TRABAJOS FUTUROS **56**

REFERENCIAS BIBLIOGRÁFICAS **58**

A DATOS Y DEPURACIÓN **63**

B AJUSTE DE LOS MODELOS Y ENTORNO DE EJECUCIÓN **65**

C RESULTADOS COMPLETOS Y COMPLEMENTARIOS **68**

D CONTRIBUCIÓN Y CONCENTRACIÓN TEMPORAL **73**

ÍNDICE DE TABLAS

1 Uso de herramientas de inteligencia artificial por fase del trabajo. iv

1.1 Selección de estudios previos sobre riesgo geopolítico y volatilidad. 8
1.2 Canales de transmisión del riesgo geopolítico a la volatilidad. 9
1.3 Persistencia esperada y canal principal de los tipos de evento. 11
1.4 Vinculación entre preguntas, hipótesis, objetivos y resultados. 12

2.1 Resumen de las decisiones de diseño. 13
2.2 Familias de activos y series financieras. 14
2.3 Controles de calidad de las series de precios. 15
2.4 Estadísticos descriptivos de la volatilidad diaria. 16
2.5 Anomalías por serie y acción. 17
2.6 Proporción de cada tipo de evento en el índice AI-GPR. 17
2.7 Criterios de resolución de las hipótesis. 26
2.8 Pruebas de robustez. 28

4.1 Resultados del modelo principal de cada caso. 34
4.2 Sesgo medio de la predicción del modelo principal en el horizonte mensual en logaritmos. 45
4.3 Contribución SHAP de los tipos persistentes y transitorios dentro de la composición. 50
4.4 Contribución de los tipos persistentes y transitorios por unidad de variación y coeficientes estandarizados del HAR-X. 51
4.5 Mejoras significativas de F1 frente a F0 en las pruebas de robustez. 51
4.6 Resolución de las hipótesis. 52

A.1 Calendarios de sesiones y tratamiento de los días fuera de sesión. 63
A.2 Volatilidad diaria media en logaritmos en torno a los vencimientos. 64

B.1 Rangos de búsqueda de la primera fase. 65
B.2 Hiperparámetros del modelo principal de cada caso. 66
B.3 Tiempo de cómputo por etapa. 67

C.1 Resultados completos por serie, horizonte y estimador, con la QLIKE como pérdida 68
C.2 Resultados por serie, horizonte y estimador, con el MSE como pérdida . . 70
C.3 Conjunto de confianza de modelos (MCS) por serie y horizonte 71

D.1 Aumento de la pérdida QLIKE al desordenar cada bloque de variables. . . 74
D.2 Meses con mayor contribución a la diferencia acumulada de la pérdida QLIKE entre F0 y F1. 75

ÍNDICE DE FIGURAS

2.1 Logaritmo del AI-GPR diario, media móvil de 30 días, 1999 a 2026. 18
2.2 Proporción mensual de cada tipo de evento en el índice AI-GPR, 1999 a 2026. 18
2.3 Logaritmo de la volatilidad media de casa serie. 19

3.1 Flujo del notebook de investigación. 30

4.1 Diferencia acumulada de la pérdida QLIKE entre F0 y F1 en el modelo principal de cada caso. 36
4.2 Diferencia acumulada de la pérdida QLIKE entre F0 y F1 en los tres modelos de energía semanal. 38
4.3 Diferencia acumulada de la pérdida QLIKE entre F0 y F1, SVR, oro mensual. 40
4.4 Dependencia de los valores SHAP respecto al valor de cada variable en el SVR del oro mensual con F2, periodo de prueba. 40
4.5 Bitcoin en horizonte mensual con modelo SVR. 43
4.6 Contribución SHAP de la intensidad en los modelos con F1. 46
4.7 Proporción de la contribución SHAP por bloque de variables, por serie y estimador (horizonte mensual, conjunto F2). 47
4.8 Contribución SHAP de cada tipo de evento dentro de la composición, por serie y estimador (horizonte mensual, conjunto F2). 49

INTRODUCCIÓN

Este trabajo estudia si el riesgo geopolítico mejora la predicción de la volatilidad de cinco familias de activos financieros (renta variable, energía, metales preciosos, deuda soberana y criptoactivos), representadas por seis series financieras, y qué tipos de evento geopolítico concentran su contribución. Para ello, compara un modelo econométrico de referencia y su extensión lineal con modelos de aprendizaje automático y separa la intensidad del riesgo geopolítico de su composición por tipos de evento.

Hasta hace poco, el riesgo geopolítico, entendido como la amenaza, la materialización o la escalada de eventos adversos asociados a guerras, terrorismo y tensiones entre Estados (Caldara & Iacoviello, 2022), quedaba fuera de la medición cuantitativa. Sus eventos son escasos, heterogéneos y solo observables a posteriori, y la literatura se limitaba a estudios de evento sobre episodios aislados (Rigobon & Sack, 2005) o a bases de crisis codificadas manualmente (Berkman et al., 2011). La digitalización de la prensa permitió tratar el texto como dato (S. Baker et al., 2015; Paul C. Tetlock, 2007), y Caldara y Iacoviello (2022) llevaron ese enfoque al riesgo geopolítico con el índice GPR, una serie continua y replicable construida a partir de millones de artículos de prensa. La frontera actual sustituye los diccionarios de palabras clave por modelos de lenguaje. El índice AI-GPR (Iacoviello & Tong, 2026) no solo mide la intensidad del riesgo geopolítico, sino que la descompone en tipos de evento, como el conflicto militar, las sanciones o el terrorismo. Existen también enfoques que infieren el riesgo a partir de los propios precios (Engle & Campos-Martins, 2023) o de fuentes abiertas en tiempo casi real (Azqueta-Gavaldon & Ureta, 2026), pero este trabajo se centra en la medida textual, que es la que permite distinguir tipos de evento.

Medir el riesgo geopolítico no basta para interpretar cómo afecta a los mercados. La evidencia indica que la relación entre riesgo geopolítico y volatilidad es no lineal, heterogénea entre mercados y cambia con el periodo y la situación (Ortiz et al., 2026; A. A. Salisu et al., 2022; Smales, 2021). Estas características motivan el uso del aprendizaje automático (Niu et al., 2023; Plakandaras et al., 2019) a pesar de que la evidencia predictiva es escasa y poco concluyente. Buena parte de los estudios estima relaciones dentro de la muestra, analiza un único activo o usa el índice agregado. Por ello no se sabe si los distintos tipos de evento afectan de forma diferente a cada activo, ni si esa información mejora la predicción fuera de muestra. En este sentido, conviene precisar también el alcance del problema. Este trabajo no estudia la dirección en que se mueven los precios, sino su volatilidad, que mide la intensidad con que reacciona el mercado, y su enfoque es predictivo y no causal.

En este contexto, la presente investigación pretende responder a dos preguntas.

P1 ¿Mejora la intensidad del riesgo geopolítico la predicción de la volatilidad frente a un modelo basado en la volatilidad pasada, y depende esa mejora del tipo de modelo?

P2 ¿Aporta la composición por tipos de evento capacidad predictiva adicional a la in-

tensidad, y cómo se distribuye su contribución entre familias de activos?

Para responderlas, el riesgo geopolítico se mide con el índice AI-GPR, cuya intensidad corresponde al índice diario agregado y cuya composición corresponde a la proporción mensual de siete tipos de evento. La volatilidad se mide como volatilidad realizada construida con rendimientos diarios, en horizontes semanal y mensual. La capacidad predictiva se evalúa fuera de muestra, entre enero de 2022 y agosto de 2026, frente al modelo HAR-RV (Corsi, 2008), con su extensión lineal y con tres modelos de aprendizaje automático (Elastic Net, SVR y XGBoost). La mejora se contrasta con los tests de Clark-West y Diebold-Mariano, con la QLIKE como pérdida principal y el MSE como complementaria, según criterios fijados antes de la estimación (capítulo 2). La contribución de cada variable se mide con técnicas de interpretabilidad. Las hipótesis se formulan al cierre del capítulo 1, una vez expuesto el marco teórico que las sustenta.

El trabajo hace tres aportaciones. Primera, aplica un mismo diseño, exigente y fuera de muestra, a cinco familias de activos a la vez. Segunda, separa la intensidad del riesgo geopolítico de su composición por tipos de evento, algo que hace posible la clasificación por tipos de evento del índice AI-GPR. Tercera, distingue de forma explícita entre la contribución de una variable a la predicción de un modelo y su capacidad para mejorar esa predicción. Los resultados muestran que la intensidad del riesgo geopolítico mejora la predicción del modelo principal solo en Bitcoin, en el horizonte mensual, y que en la energía a corto plazo lo hace únicamente en modelos secundarios y en episodios de tensión. La composición por tipos de evento, aunque los modelos le asignan una contribución considerable, no mejora la predicción en ningún modelo principal.

El documento se organiza como sigue. El capítulo 1 revisa el riesgo geopolítico, su medición y sus canales de transmisión a los mercados, y formula las hipótesis. El capítulo 2 describe los datos y la metodología, y el capítulo 3, el desarrollo experimental. El capítulo 4 presenta y discute los resultados, y el último capítulo resume las conclusiones, las limitaciones y las líneas de trabajo futuro.

Objetivos

El objetivo general de este trabajo es evaluar si el riesgo geopolítico, medido con el índice AI-GPR y descompuesto por tipos de evento, mejora la predicción fuera de muestra de la volatilidad de distintas familias de activos financieros, e identificar qué tipos de evento concentran su contribución predictiva.

Para alcanzarlo, se plantean los siguientes objetivos específicos:

OE1. Construir una base de datos integrada y validada con la volatilidad de seis series de cinco familias de activos y la intensidad y la composición del índice AI-GPR.

OE2. Comparar fuera de muestra el modelo HAR-RV y su extensión lineal con Elastic Net, SVR y XGBoost, con y sin información geopolítica, en horizontes semanal y mensual.

OE3. Contrastar estadísticamente la mejora predictiva, controlar las comparaciones múltiples y evaluar la robustez de los resultados.

OE4. Medir la contribución de la intensidad y de cada tipo de evento a la predicción, y compararla entre familias de activos.

OE5. Garantizar la reproducibilidad del flujo de análisis.

Vinculación con los Objetivos de Desarrollo Sostenible

La investigación se vincula con tres Objetivos de Desarrollo Sostenible de la Agenda 2030.

ODS 9: Industria, innovación e infraestructura. Se aplican modelos de aprendizaje automático (Elastic Net, SVR y XGBoost) y un índice de riesgo geopolítico construido con modelos de lenguaje (AI-GPR) a un problema económico vinculado al riesgo geopolítico, y sus resultados se someten a técnicas de interpretabilidad. Con ello, el trabajo contribuye a la meta 9.5, relativa al fomento de la investigación científica y la capacidad tecnológica, al explorar si estas técnicas aportan valor frente a un modelo econométrico de referencia (HAR-RV).

ODS 8: Trabajo decente y crecimiento económico. La volatilidad es un insumo directo de la gestión del riesgo, la valoración de activos y la regulación y planificación financiera. Identificar en qué familias de activos y horizontes el riesgo geopolítico mejora la predicción de la volatilidad apoya la toma de decisiones de inversores e instituciones en contextos de incertidumbre y, de forma indirecta, la estabilidad financiera sobre la que descansa el crecimiento económico.

ODS 16: Paz, justicia e instituciones sólidas. El objeto de estudio es el riesgo geopolítico, que incluye eventos como guerras, terrorismo y tensiones entre Estados. El vínculo, para este caso es de contexto. Esta investigación aporta una cuantificación de los efectos económicos del conflicto que puede servir de insumo a instituciones como bancos centrales y reguladores, alineado con la meta de la creación de instituciones eficaces.

CAPÍTULO 1
MARCO TEÓRICO Y ESTADO DEL ARTE

Este capítulo reúne la literatura sobre la que se apoya el trabajo y construye a partir de ella el marco teórico y las hipótesis. Las secciones 1.1 y 1.2 recogen el estado del arte sobre la medición del riesgo geopolítico y sobre la predicción de la volatilidad. La sección 1.3 organiza la evidencia empírica por familia de activos y propone el marco teórico que explica cómo se transmite el riesgo geopolítico a la volatilidad. La sección 1.4 identifica las brechas que deja la literatura, delimita el alcance del trabajo y formula las hipótesis.

1.1 La medición del riesgo geopolítico y sus tipos de evento

En esta investigación se adopta la definición de Caldara y Iacoviello (2022), en la que el riesgo geopolítico es la amenaza, la materialización y la escalada de eventos adversos asociados a guerras, terrorismo y tensiones entre Estados y actores políticos que alteran el curso pacífico de las relaciones internacionales. La definición incluye tensiones sin violencia, como las crisis diplomáticas o las sanciones. Además, agrega en un mismo concepto la amenaza, la materialización y la escalada porque de esta manera suelen reflejarse, entrelazadas, en la prensa. Ambos rasgos muestran que el riesgo geopolítico es un fenómeno heterogéneo, lo que justifica descomponerlo por tipo de evento.

Durante décadas, el riesgo geopolítico quedó fuera de la medición cuantitativa porque sus eventos son escasos, heterogéneos y solo observables a posteriori. Por ello, la literatura se limitaba a estudios de evento sobre episodios aislados (Rigobon & Sack, 2005) o a bases de crisis codificadas manualmente (Berkman et al., 2011). Con el avance del Big Data, la digitalización de la prensa permitió después tratar el texto como dato (S. Baker et al., 2015; Paul C. Tetlock, 2007) y Caldara y Iacoviello (2022) llevaron ese enfoque al riesgo geopolítico con el índice GPR. Este índice mide la frecuencia de artículos sobre eventos geopolíticos adversos mediante la búsqueda de palabras de un diccionario en periódicos de Estados Unidos, el Reino Unido y Canadá. Se publica en frecuencia diaria desde 1985 y mensual desde 1900, y sus máximos coinciden con la guerra del Golfo, los atentados del 11 de septiembre de 2001 y la invasión de Irak de 2003.

Los autores muestran que la variación del GPR es en gran medida independiente de la incertidumbre de política económica (EPU) de S. Baker et al. (2015) y del índice de volatilidad implícita VIX. El GPR no reacciona a las crisis económicas ni a los periodos electorales, mientras que el EPU y el VIX no responden a episodios geopolíticos como la anexión de Crimea. Trabajos posteriores también tratan ambas medidas como distintas (Baur & Smales, 2020; Engle & Campos-Martins, 2020), lo que respalda estudiar el riesgo geopolítico como un fenómeno propio. Existen además enfoques que infieren el riesgo geopolítico a partir de los precios (Engle & Campos-Martins, 2023) o de fuentes abiertas en tiempo casi real (Azqueta-Gavaldon & Ureta, 2026). Este trabajo se centra

en la medida textual porque es la única que distingue diferentes tipos de evento.

Con el avance reciente de la inteligencia artificial, Iacoviello y Tong (2026) proponen el índice AI-GPR, que sustituye el diccionario de palabras clave por la interpretación contextual de un modelo de lenguaje. El modelo empleado, GPT-4o mini, asigna a cada artículo una puntuación de riesgo entre 0 y 1 a partir de una rúbrica explícita y sin ejemplos previos. El corpus reúne más de 4,5 millones de artículos del *New York Times*, el *Washington Post* y el *Chicago Tribune* publicados desde 1960. El índice diario es la suma de las puntuaciones del día dividida por el total de artículos publicados ese día, normalizada por una constante

$$\text{AI-GPR}_t = \frac{1}{\bar{S}} \frac{1}{A_t} \sum_{i=1}^{N_t} S_{it}, \tag{1.1}$$

donde S_{it} es la puntuación del artículo i en la fecha t, N_t el número de artículos puntuados, A_t el total de artículos publicados ese día y $\bar{S}$ la constante de normalización.

El AI-GPR clasifica como geopolítico el 15% de los artículos, frente al 3,3% del índice original, con el que mantiene una correlación de 0,69. Su fiabilidad se apoya en una auditoría humana de 2.000 artículos y en la comparación entre cinco modelos de lenguaje, con correlaciones entre 0,84 y 0,94. La serie diaria presenta un ciclo semanal ligado al volumen de publicación que desaparece con una media móvil de siete días.

En una segunda etapa, un clasificador asigna cada artículo con puntuación positiva a una de ocho categorías. Siete son tipos de evento (conflicto militar, tensión diplomática, terrorismo, guerra civil, amenaza nuclear, golpe de Estado y sanciones) y la octava (otra) es una categoría residual. El clasificador elige entre una lista cerrada de opciones sin una definición explícita de cada una. Por ello, la frontera entre categorías próximas, como la tensión diplomática y las sanciones es difusa. No obstante, los autores documentan que estas categorías siguen patrones históricos reconocibles, como el auge de las sanciones desde 2014, a pesar de que no las emplean como variables explicativas (Iacoviello & Tong, 2026, p. 23).

Estas categorías se diferencian de las ocho subcategorías del GPR original, que ya se han usado en la literatura financiera (Niu et al., 2023). Aquellas se obtienen por palabras clave y mezclan la fase del evento con su tema, como ocurre al separar las amenazas de la escalada de guerra. Por su parte, las del AI-GPR clasifican semánticamente la naturaleza del evento, una clasificación que ninguno de los estudios revisados en la sección 1.3 utiliza como predictor de la volatilidad.

1.2 La predicción de la volatilidad realizada

La volatilidad realizada mide la variabilidad efectiva del precio de un activo durante un periodo a partir de las variaciones observadas del mismo. Su construcción habitual consiste en la suma los rendimientos intradía al cuadrado (Andersen & Bollerslev, 1998), lo que exige datos de alta frecuencia. Ahora, con datos diarios, la medida se reduce al rendimiento de cierre a cierre al cuadrado y esto genera un estimador insesgado cuyo error de medida en un solo día es elevado. Los estimadores de rango reducen ese error

al incorporar el máximo, el mínimo y la apertura de cada sesión (Garman & Klass, 1980; Parkinson, 1980; Rogers & Satchell, 1991; Yang & Zhang, 2000). Si bien en teoría son más precisos, la evidencia empírica muestra que no siempre producen mejores predicciones y que su ventaja depende del activo, del periodo y del horizonte de predicción (Korkusuz et al., 2023).

Patton (2011) muestra que una medida ruidosa de la volatilidad ordena los modelos igual que la volatilidad verdadera si se evalúan con funciones de pérdida robustas, como el error cuadrático medio (MSE) o la QLIKE. El ruido reduce la potencia de los contrastes, pero no invalida la comparación entre modelos. Este resultado permite justificar la realización de predicciones de volatilidad con medidas construidas a partir de datos diarios, siempre que se empleen pérdidas robustas.

El modelo HAR-RV de Corsi (2008) es referencia habitual para la predicción de la volatilidad realizada. Explica la volatilidad futura a partir del propio pasado en tres horizontes, que corresponden al día anterior y a las medias de la última semana y del último mes,

$$RV_{t+h} = \beta_0 + \beta_d \, RV_t + \beta_w \, RV_t^{(w)} + \beta_m \, RV_t^{(m)} + \varepsilon_{t+h}. \tag{1.2}$$

Su fundamento es la hipótesis de mercados heterogéneos, según la cual conviven agentes que operan con frecuencias distintas, desde operadores diarios hasta inversores de largo plazo. Con una estructura lineal de solo tres regresores, el modelo reproduce la memoria larga de la volatilidad, lo que lo posiciona como una referencia difícil de superar fuera de muestra. Su extensión habitual, el HAR-X, añade variables exógenas a la regresión y ha servido en la literatura sobre riesgo geopolítico para contrastar si el índice GPR aporta información más allá de la persistencia de la volatilidad.

Cuando las variables explicativas tienen una frecuencia distinta de la volatilidad, el modelo GARCH-MIDAS de Engle et al. (2013) separa un componente de corto plazo de otro de largo plazo, impulsados por variables de alta y baja frecuencia repectivamente. A. A. Salisu et al. (2022) lo aplican con el GPR a once índices bursátiles de economías emergentes y encuentran que la información geopolítica mejora la predicción fuera de muestra de su volatilidad.

Los modelos de aprendizaje automático pueden capturar relaciones no lineales e interacciones sin imponer una forma funcional previa. Niu et al. (2023) predicen la volatilidad realizada mensual del S&P 500 con seis de estos modelos y las ocho subcategorías del GPR original. Todos los modelos entrenados superan fuera de muestra al de referencia, con las máquinas de vectores de soporte para regresión (SVR) como el más preciso y con la acumulación militar y la escalada de guerra como las categorías más importantes. El modelo de referencia ya incluía el índice de riesgo geopolítico, por lo que la mejora procede del estimador y no de la información añadida. Como además los rezagos de la volatilidad son las variables más importantes en todos sus modelos, sus resultados obligan a separar dos fuentes de mejora, la no linealidad del estimador y la información de la variable añadida.

Para interpretar los modelos se emplean los valores SHAP (Lundberg & Lee, 2017)

y la importancia por permutación (Breiman, 2001; Fisher et al., 2019). Ambas técnicas describen cuánto usa un modelo ya estimado cada una de sus variables para construir la predicción. No indican si una variable mejora la predicción fuera de muestra ni si causa cambios en la volatilidad, ya que descomponen la predicción en contribuciones sin establecer relaciones causales.

1.3 Transmisión del riesgo geopolítico a la volatilidad

La literatura coincide en que el riesgo geopolítico afecta a la volatilidad y el efecto difiere entre activos y no es lineal (Ortiz et al., 2026; A. A. Salisu et al., 2022; Smales, 2021). Para ordenar dicha heterogeneidad resulta útil agrupar los activos en familias, entendidas como conjuntos de activos que comparten naturaleza económica similar y, por tanto, una exposición similar a los canales por los que se transmite el riesgo geopolítico. Esta agrupación permite comparar activos que cumplen funciones distintas en una cartera de inversión, desde los ligados a la actividad productiva hasta los que se consideran refugio.

Esta sección revisa la evidencia de cinco familias (renta variable, energía, metales preciosos, deuda soberana y criptoactivos), desde la que presenta resultados más homogéneos hasta la que cuenta con menos estudios. Seguidamente, propone los canales que explican esas diferencias y caracteriza los tipos de evento según su canal y su persistencia esperada.

El petróleo es el activo con mayor cantidad de estudios realizados y con la evidencia más consistente, ya que el riesgo geopolítico eleva la volatilidad del crudo más que la de la renta variable (Antonakakis et al., 2017; Smales, 2021). En la renta variable el efecto es más débil y depende de los controles empleados, hasta el punto de que Engle y Campos-Martins (2023) no encuentran efecto sobre la volatilidad bursátil global cuando controlan mediante otras fuentes de incertidumbre. En los metales preciosos, el oro actúa como cobertura frente a las amenazas geopolíticas (Baur & Smales, 2020). Entre los activos que estudian Plakandaras et al. (2019), el GPR solo mejora la predicción del precio del oro, aunque su trabajo no evalúa la volatilidad.

En el bono del Tesoro estadounidense, los contrastes lineales no detectan efecto del riesgo geopolítico sobre la curva de tipos, mientras que los no lineales sí lo hacen (Gupta et al., 2021). Bitcoin, concebido como un sistema de pago electrónico entre pares (Nakamoto, 2008), cuenta con evidencia aún más escasa en comparación con el resto de familias. La más directa procede de estudios de evento, como la caída de la liquidez y de los rendimientos de las criptomonedas tras los acontecimientos de febrero de 2022 (Kamal & Wahlstrøm, 2023). La tabla 1.1 resume estos estudios revisados, cuya evidencia procede de métodos, frecuencias y periodos distintos que impide compararlos de forma directa.

Para explicar estas diferencias, este trabajo distingue cuatro canales de transmisión (tabla 1.2). El canal de oferta física actúa cuando una interrupción, real o temida, del suministro de energía altera su precio (Hamilton, 2003; Kilian, 2009). El de huida hacia la calidad lleva a los inversores a reasignar sus carteras hacia activos seguros (Baur &

Tabla 1.1: Selección de estudios previos sobre riesgo geopolítico y volatilidad.

Estudio	Medida y frecuencia	Activos	Método	Hallazgo principal
Antonakakis et al. (2017)	GPR mensual	Petróleo WTI y S&P 500	VAR-BEKK-GARCH	El petróleo es más sensible que la renta variable
Plakandaras et al. (2019)	GPR mensual	Petróleo, oro, bolsas y divisas (precios)	Paseo aleatorio, MCO y SVR	El GPR solo mejora la predicción del oro
Baur & Smales (2020)	Amenazas y actos del GPR, diario	Oro, plata, platino, paladio, cobre y bono a diez años	Regresión con controles	Los metales preciosos cubren frente a las amenazas
Gupta et al. (2021)	Amenazas y actos del GPR, diario	Curva de tipos del Tesoro	Causalidad en cuantiles	Los contrastes lineales no detectan efecto y los no lineales sí
Smales (2021)	GPR diario	Petróleo WTI y S&P 500	GARCH multivariante	El GPR eleva la volatilidad de ambos, más en el petróleo
A. A. Salisu et al. (2022)	Amenazas y actos del GPR, mensual	Bolsas de mercados emergentes	GARCH-MIDAS	El GPR, en mayor medida los actos, mejora la predicción fuera de muestra
Engle & Campos-Martins (2023)	GPR agregado, COVOL, VIX y EPU, mensual	Renta variable global	GARCH	Sin efecto del GPR sobre la volatilidad global
Kamal & Wahlstrøm (2023)	Eventos de febrero de 2022	Principales criptomonedas por capitalización	Estudio de evento	El acto redujo la liquidez y los rendimientos
Niu et al. (2023)	Ocho subcategorías del GPR, mensual	S&P 500	Seis modelos de aprendizaje automático y SHAP	La acumulación militar y la escalada de guerra son las más importantes

Lucey, 2010). El de incertidumbre eleva la volatilidad cuando las decisiones de los actores políticos son inciertas (Pástor & Veronesi, 2012). Por último, el de sentimiento provoca reacciones bruscas y transitorias ante eventos que generan miedo (M. Baker & Wurgler, 2006).

La columna de familias expuestas describe una exposición teórica y no un resultado esperado. Para el bono del Tesoro, la teoría lo sitúa en el canal de huida hacia la calidad a pesar de que la evidencia revisada no lo confirma frente al riesgo geopolítico. Por su parte, para Bitcoin no existe una teoría establecida, de modo que su asignación al canal de sentimiento es una conjetura y no un supuesto de este trabajo.

Tabla 1.2: Canales de transmisión del riesgo geopolítico a la volatilidad.

Canal	Mecanismo general	Activación por el riesgo geopolítico	Familias más expuestas
Oferta física	Una interrupción, real o temida, de la oferta de energía altera su precio (Hamilton, 2003; Kilian, 2009)	El riesgo geopolítico se asocia a subidas del petróleo coherentes con una interrupción de la oferta (Smales, 2021) y a caídas de la producción (Iacoviello & Tong, 2026)	Petróleo y renta variable por contagio
Huida hacia la calidad	Ante el riesgo, los inversores reasignan su cartera hacia activos seguros (Baur & Lucey, 2010)	El oro cubre frente a las amenazas geopolíticas (Baur & Smales, 2020)	Oro y bono del Tesoro en teoría
Incertidumbre	La incertidumbre sobre las decisiones políticas eleva la volatilidad y la correlación de los rendimientos (Pástor & Veronesi, 2012)	El riesgo de guerra afecta a los mercados (Rigobon & Sack, 2005) y reduce la inversión (Caldara & Iacoviello, 2022)	Renta variable y Bitcoin con evidencia limitada (Kamal & Wahlstrøm, 2023)
Sentimiento	Los eventos que generan miedo provocan reacciones bruscas y transitorias (M. Baker & Wurgler, 2006)	Los atentados afectan al sentimiento y a los rendimientos bursátiles (Drakos, 2010)	Renta variable y Bitcoin como conjetura

El efecto del riesgo geopolítico depende además de dos propiedades, su no linealidad previamente mencionada y la persistencia del evento. En cuanto a la no linealidad, Caldara y Iacoviello (2022) muestran que un GPR elevado aumenta la probabilidad de desastres económicos, lo que sugiere un efecto concentrado en episodios extremos. Si el efecto es de umbral, un modelo lineal lo promedia y lo diluye, mientras que un modelo no lineal puede capturarlo.

Por su parte, la persistencia determina cuánto dura la incertidumbre generada por un evento, que se mantiene durante meses en una guerra o en un régimen de sanciones y se corrige en pocos días tras un atentado o golpe de Estado. El efecto de un atentado sobre los rendimientos bursátiles es significativo el mismo día, sin embargo no permanente (Drakos, 2010). Iacoviello y Tong (2026) encuentran un patrón compatible para el índice agregado, en el que las amenazas afectan a los rendimientos a través de su componente persistente.

Ambas propiedades sugieren entonces separar dos dimensiones del riesgo geopolítico

que evolucionan a distinto ritmo. La intensidad indica cuánto riesgo hay y puede cambiar de un día a otro, mientras que la composición indica qué tipo de riesgo predomina y cambia con mayor lentitud, alineado con la lógica de frecuencias mixtas que permite modelar GARCH-MIDAS. Sin embargo, la literatura revisada trabaja con el índice agregado o con su división por fase, por lo que no permite preguntar qué clase de riesgo geopolítico aporta información ni en qué familias de activos lo hace.

La tabla 1.3 caracteriza cada tipo de evento por su persistencia esperada y su canal principal. Como estas categorías aún no se han estudiado en la literatura financiera, la caracterización se apoya en la evidencia sobre los eventos en sí. El conflicto militar es el tipo con más canales simultáneos, ya que afecta a la oferta de energía cuando involucra a países productores, provoca huida hacia la calidad y deteriora las expectativas (Antonakakis et al., 2017; Kollias et al., 2013). Las sanciones restringen el comercio, en especial el energético, y suelen mantenerse durante meses o años (Farzanegan & Raeisian Parvari, 2014), por lo que ambos tipos se clasifican como persistentes. El terrorismo, en cambio, tiene un efecto intenso pero concentrado en los días posteriores al atentado (Drakos, 2010; Kollias et al., 2013). El golpe de Estado, que incluye los cambios de régimen, produce principalmente efectos breves que dependen de la exposición al país afectado (Boungou et al., 2024; Lumjiak et al., 2018), de modo que ambos tipos se clasifican como transitorios.

En los tres tipos restantes la persistencia depende del episodio, como ilustra la tensión diplomática, que puede prolongarse durante años aunque su efecto sobre la volatilidad se concentra en las fases de escalada (Charfeddine & Al Refai, 2019; Kapar & Buigut, 2020; A. Salisu & Nsonwu, 2026). La evidencia sobre la amenaza nuclear procede principalmente de episodios relacionados con Corea del Norte y muestra reacciones breves salvo que haya escalada (Huh & Pyun, 2018). Los conflictos internos tienen efectos globales principalmente cuando afectan a un país productor de petróleo. Así ocurrió con la guerra civil de Libia de 2011, que supuso la pérdida de unos 1,6 millones de barriles diarios (Darbouche & Fattouh, 2011), o con el paro petrolero de Venezuela de 2002 y 2003 (Kilian, 2008).

Esta clasificación procede exclusivamente de la evidencia previa y no de los datos del trabajo. Se ha fijado antes de estimar ningún modelo y por tanto evita que el análisis posterior se interprete con la misma información con la que se ha formulado.

1.4 Aportación del trabajo e hipótesis

La literatura revisada no utiliza como predictores los tipos de evento del AI-GPR, y la desagregación temática más próxima (Niu et al., 2023) se basa en las palabras clave del GPR original para un único activo en frecuencia mensual. Tampoco existe un diseño común para varias familias de activos, ya que los estudios más amplios cubren tres o cuatro (Baur & Smales, 2020; Plakandaras et al., 2019). El bono del Tesoro y Bitcoin cuentan solo con estudios econométricos mensuales o estudios de evento, sin predicción de su volatilidad fuera de muestra con aprendizaje automático. Por último, los estudios

Tabla 1.3: Persistencia esperada y canal principal de los tipos de evento.

Tipo de evento	Persistencia esperada	Canal principal	Respaldo
Conflicto militar	Persistente	Oferta física, huida hacia la calidad e incertidumbre	Antonakakis et al. (2017), Kollias et al. (2013)
Sanciones	Persistente	Oferta física y comercio	Farzanegan & Raeisian Parvari (2014)
Terrorismo	Transitoria	Sentimiento	Drakos (2010), Kollias et al. (2013)
Golpe de Estado	Transitoria	Local, según la exposición al país	Lumjiak et al. (2018), Boungou et al. (2024)
Tensión diplomática	Variable	Incertidumbre	Charfeddine & Al Refai (2019), Kapar & Buigut (2020), A. Salisu & Nsonwu (2026)
Amenaza nuclear	Variable	Huida hacia la calidad	Huh & Pyun (2018)
Guerra civil	Variable. Persistente si afecta a un país productor	Oferta física	Darbouche & Fattouh (2011)

con desagregación temática trabajan en frecuencia mensual, mientras que los diarios se limitan a la distinción entre amenazas y actos.

Este trabajo aborda esas brechas con un diseño de evaluación fuera de muestra común para cinco familias de activos, que separa la intensidad del riesgo geopolítico de su composición por tipos de evento. El diseño compara un conjunto de variables basado en la volatilidad pasada (F0) con otro que añade la intensidad (F1) y con un tercero que incorpora además la composición (F2). Cada conjunto se estima con el modelo HAR y con tres modelos de aprendizaje automático, según se detalla poesteriormente en el capítulo 2.

El alcance del trabajo es predictivo y no análisis de causalidad, ya que evalúa si el riesgo geopolítico mejora la predicción de la volatilidad y no la causa ni en qué dirección se mueven los precios. Por ello distingue entre lo que un modelo usa para construir su predicción y lo que efectivamente le ayuda a predecir mejor. La capacidad predictiva indica si un modelo con una variable predice mejor fuera de muestra, por lo que se evalúa comparando pérdidas de predicción. La contribución predictiva indica cuánto usa un modelo etrenado ya estimado cada variable, tal como la describen las técnicas de interpretabilidad de la sección 1.2. Una variable puede tener una contribución elevada sin mejorar la predicción, de modo que las hipótesis se formulan sobre la capacidad predictiva y la contribución se analiza de forma descriptiva.

Con este diseño, el trabajo responde a dos preguntas de investigación de las que se derivan tres hipótesis confirmatorias y un análisis exploratorio. La pregunta P1 plantea si la intensidad del riesgo geopolítico mejora la predicción de la volatilidad frente a un modelo basado en la volatilidad pasada y si esa mejora depende del tipo de modelo. La pregunta P2 plantea si la composición por tipos de evento aporta capacidad predictiva adicional a la intensidad y cómo se distribuye su contribución entre familias de activos.

H1a (información). En el modelo principal de cada familia de activos y horizonte, añadir la intensidad del riesgo geopolítico (F1) a la volatilidad pasada (F0) reduce la pérdida de predicción fuera de muestra.

H1b (tipo de modelo). En los casos en que se cumple la H1a, la mejora es mayor en los modelos de aprendizaje automático que en el HAR-X, porque el efecto del riesgo geopolítico sobre la volatilidad es no lineal y se concentra en episodios extremos.

H2 (composición). En el horizonte mensual, la composición por tipos de evento (F2) aporta información predictiva adicional a la intensidad (F1), de modo que su incorporación reduce la pérdida de predicción fuera de muestra del modelo principal de cada familia de activos. Esta hipótesis se deriva de la diversidad de canales y de persistencias descrita en la sección 1.3.

Las tres hipótesis admiten un resultado negativo que también es informativo, como ocurriría si la H2 no se cumpliera. En ese caso, la información geopolítica útil para predecir la volatilidad estaría contenida en la intensidad y la distinción por tipos de evento no añadiría capacidad predictiva con el diseño y la muestra de este trabajo.

La segunda parte de la pregunta P2 se aborda mediante un análisis exploratorio que describe cómo se distribuye la contribución entre tipos de evento en cada familia de activos. El análisis examina también si los tipos de persistencia esperada alta (conflicto militar y sanciones) concentran más contribución que los de persistencia baja (terrorismo y golpe de Estado). No se formula como hipótesis porque la persistencia es una clasificación previa basada en la literatura y no una magnitud estimada en el trabajo. Además, la composición solo se evalúa en el horizonte mensual, de modo que no puede contrastarse si la contribución de cada tipo cambia con el horizonte, que sería la consecuencia observable de su persistencia. Una contribución SHAP mide cuánto usa el modelo una variable, no cuánto dura su efecto sobre la volatilidad.

Las hipótesis se resuelven mediante contrastes de capacidad predictiva fuera de muestra, con criterios fijados antes de estimar los modelos que se detallan en la sección 2.6.3 junto con la selección del modelo principal de cada caso. La tabla 1.4 vincula cada pregunta con la hipótesis o el análisis que la responde, con el objetivo específico correspondiente y con la sección en que se presentan sus resultados, cuya resolución conjunta figura en la sección 4.5. Los objetivos OE1 y OE5, referidos a la construcción de los datos y a la reproducibilidad, sostienen el conjunto del diseño y no se vinculan a una pregunta concreta.

Tabla 1.4: Vinculación entre preguntas, hipótesis, objetivos y resultados.

Pregunta	Hipótesis o análisis	Objetivo	Resultados
P1	H1a y H1b	OE2 y OE3	Secciones 4.2 y 4.3.1
P2	H2	OE2 y OE3	Sección 4.3.2
P2	Análisis exploratorio	OE4	Secciones 4.3.2 y 4.3.3

CAPÍTULO 2

DATOS Y METODOLOGÍA

La investigación sigue un enfoque cuantitativo, de carácter predictivo y no causal. El diseño es un experimento de predicción fuera de muestra en el que, para cada serie financiera, se compara la volatilidad predicha con y sin información geopolítica dentro de un mismo estimador. La contribución de cada variable a esas predicciones se describe después con técnicas de interpretabilidad, sin que esa descripción intervenga en la resolución de las hipótesis. Las decisiones de diseño que desarrolla este capítulo se resumen en la tabla 2.1, ordenadas desde los datos hasta las pruebas de robustez.

Tabla 2.1: Resumen de las decisiones de diseño.

Elemento	Decisión
Riesgo geopolítico	AI-GPR consolidado diario (intensidad) y proporción mensual de siete tipos de evento (composición)
Familias y series	Cinco familias y seis series: renta variable (S&P 500), energía (petróleo Brent y WTI), metales preciosos (oro), deuda soberana (bono del Tesoro estadounidense a diez años) y criptoactivos (Bitcoin)
Variable objetivo	Volatilidad realizada de cierre a cierre, modelada en logaritmos y evaluada en niveles
Horizontes	Semanal y mensual, de 5 y 22 sesiones, o de 7 y 30 días naturales en Bitcoin
Conjuntos de variables	F0 (componentes HAR), F1 (F0 e intensidad) y F2 (F1 y composición del mes anterior, solo en el horizonte mensual)
Modelos	HAR-RV como referencia, HAR-X como extensión lineal, Elastic Net, SVR y XGBoost
Estimación	Ventana expansiva con reestimación mensual e hiperparámetros fijados en el periodo de entrenamiento
Evaluación	De enero de 2022 a agosto de 2026, con la QLIKE como pérdida principal, el test de Clark-West para comparaciones anidadas y el de Diebold-Mariano para las no anidadas
Interpretabilidad	Valores SHAP por bloques y por tipo de evento e importancia por permutación por bloques
Robustez	Seis pruebas sobre la muestra, el calendario, el cambio de contrato del WTI y el tratamiento de los valores nulos

2.1 Datos

2.1.1 El índice AI-GPR

Se emplean dos niveles del índice AI-GPR de Iacoviello y Tong (2026). El índice consolidado diario mide la intensidad del riesgo geopolítico, mientras que las series mensuales por tipo de evento muestran el peso de las ocho categorías del clasificador. Siete de ellas son los tipos de evento que analiza este trabajo y la octava es la categoría residual

otro. El clasificador asigna estas categorías solo a los artículos con puntuación de riesgo positiva y es el mismo que identifica los países implicados en cada noticia.

Se emplea el tramo de ambas series que coincide con la muestra del estudio, que termina en agosto de 2026, y las dos superan los controles de integridad realizados. La serie diaria no presenta días ausentes ni duplicados y es estrictamente positiva, mientras que la suma de las categorías mensuales reproduce el índice total con una diferencia máxima de 0,0002, atribuible al redondeo.

No se emplean las descomposiciones diarias por amenazas y actos ni los índices específicos del petróleo porque el interés del trabajo es la naturaleza del evento y no su fase (sección 1.1). Además, esos componentes forman parte del índice consolidado, por lo que incluirlos puede agregar información redundante y fuertemente correlacionada. En cambio, la descomposición por tipo de evento solo se publica en frecuencia mensual, lo que obliga a incorporarla a la frecuencia diaria como se describe en la sección 2.4.

La frontera difusa entre algunas categorías, descrita en la sección 1.1, tiene una consecuencia práctica. Los conflictos comerciales, por ejemplo, pueden asignarse a la tensión diplomática o a las sanciones, de modo que parte de la variación de una proporción puede reflejar decisiones del clasificador y no cambios en la naturaleza de los eventos. Por ello, los resultados por tipo de evento se interpretan con cautela entre categorías próximas, en particular entre la tensión diplomática y las sanciones y entre el conflicto militar y la tensión diplomática.

2.1.2 Familias de activos y series

El estudio abarca cinco familias de activos representadas por seis series financieras. La renta variable se representa con el índice S&P 500, la energía con los futuros de petróleo Brent y WTI, los metales preciosos con el oro, la deuda soberana con el bono del Tesoro estadounidense a diez años y los criptoactivos con Bitcoin (tabla 2.2). Los precios proceden de un proveedor comercial de datos financieros cuyas condiciones de uso no permiten su difusión pública, aunque los datos están disponibles bajo petición.

Tabla 2.2: Familias de activos y series financieras.

Familia	Serie	Variación medida	Inicio
Renta variable	S&P 500	Logarítmica del precio	Enero de 1999
Energía	Futuro de petróleo Brent	Logarítmica del precio	Enero de 1999
Energía	Futuro de petróleo WTI	Logarítmica del precio	Enero de 1999
Metales preciosos	Oro	Logarítmica del precio	Enero de 1999
Deuda soberana	Bono del Tesoro estadounidense a diez años	Del rendimiento, en puntos básicos	Enero de 1999
Criptoactivos	Bitcoin	Logarítmica del precio	Marzo de 2014

Todas las series terminan el 10 de septiembre de 2026. Las predicciones cuya ventana objetivo no se completa antes de esa fecha se excluyen de la evaluación.

Las dos series de energía se analizan por separado, cada una con sus propios modelos. En las comparaciones entre familias, la energía cuenta como una sola familia y sus dos series se leen de forma conjunta, de modo que el petróleo no pesa el doble que el resto de familias.

Ambas series de energía son futuros continuos que siguen el contrato más próximo y pasan al siguiente antes de su vencimiento, sin que se documente la regla de cambio ni se ajusten los precios entre contratos. Ello explica que la serie de WTI no registre el precio negativo del 20 de abril de 2020, pero implica que los días de cambio de contrato pueden contener variaciones que no responden a movimientos del mercado. Este riesgo es mayor en el WTI, cuya serie presenta en abril de 2020 distorsiones asociadas al colapso de los inventarios y al cambio de contrato (sección 3.2). Reconstruir las series a partir de los contratos individuales queda fuera del alcance del trabajo, por lo que el efecto de ese cambio de contrato se evalúa con una prueba de robustez específica.

2.1.3 Control de calidad y limpieza

Antes de calcular la volatilidad, cada serie se somete a siete controles (tabla 2.3). Las anomalías no se corrigen de forma automática, sino que cada una se marca en el conjunto de datos con su tipo, la acción decidida y su motivo, de modo que todas las decisiones quedan registradas y pueden revisarse.

Tabla 2.3: Controles de calidad de las series de precios.

Control	Qué detecta	Acción
Q1 Estructura	Fechas duplicadas, desordenadas y cierres faltantes	Corrección y registro
Q2 Precios no positivos	Logaritmo no definido	Exclusión, si aparecen
Q3 Calendario	Días fuera de sesión y sesiones ausentes	Según el control Q4
Q4 Variaciones nulas	Nulas fuera de sesión, en rachas o legítimas	Eliminación fuera de sesión, revisión en rachas y valor mínimo en las legítimas
Q5 Extremos	Variaciones superiores a diez desviaciones robustas	Se conservan si son reales, tras verificarlas con otra fuente
Q6 Logaritmo	Valor mínimo y asimetría	Valor mínimo igual al percentil 1 de los valores positivos
Q7 Variable objetivo	Medias de h sesiones nulas	Deben desaparecer tras la limpieza

Solo se eliminan los días fuera de sesión con variación nula, que corresponden a festivos y, por otra parte, los que presentan variación de precio se conservan porque indican que el mercado cotizaba ese día y que el calendario de referencia no se ajusta a él.

El inicio de la serie de Bitcoin requiere un criterio propio, porque en sus primeros años el mercado presentaba una liquidez reducida, con precios que permanecían sin cambios durante días consecutivos. La literatura documenta que Bitcoin fue un mercado ineficiente

durante esa etapa, sin embargo mejora a partir de agosto de 2013 (Urquhart, 2016) como una evolución asociada a su mayor liquidez (Brauneis & Mestel, 2018). Para fechar el fin de esa etapa con un criterio objetivo, se calculó la proporción de días sin variación de precio en ventanas móviles de seis meses y se consideró ilíquido todo periodo en que superase el 5%. Como prueba placebo, el mismo criterio aplicado al S&P 500, cuya proporción media de días sin variación es del 0,4%, no identifica ningún periodo ilíquido. En Bitcoin, el último periodo ilíquido termina en mayo de 2013.

La serie de Bitcoin no puede comenzar en esa fecha por un segundo motivo, relacionado con el colapso de la plataforma Mt. Gox en febrero de 2014. Durante esas semanas, el precio compuesto de la serie registra variaciones diarias de hasta el 337%. Como no se documenta cuales plataformas de negociación componen el precio en cada momento, no puede garantizarse que los precios anteriores a esa fecha sean comparables con los posteriores. Por esta razón se define el inicio de la serie en marzo de 2014.

2.2 Análisis descriptivo y exploratorio

2.2.1 Estadísticos descriptivos

La tabla 2.4 resume la volatilidad diaria de cada serie. En niveles, la distribución presenta una asimetría elevada y colas gruesas en todas las series, con coeficientes de asimetría entre 8,2 y 49,2 y curtosis entre 144 y 2.691. En logaritmos, la asimetría se sitúa entre −0,85 y −0,62 y la curtosis por debajo de uno, lo que justifica modelar el logaritmo de la volatilidad.

Tabla 2.4: Estadísticos descriptivos de la volatilidad diaria.

			Niveles		Logaritmos		
Serie	Obs.	Vol. anual.	Asim.	Curt.	Asim.	Curt.	Valor mínimo
S&P 500	6.963	19,2 %	14,15	293,87	−0,79	0,68	$9{,}72 \times 10^{-9}$
Brent	7.109	37,1 %	23,16	846,35	−0,79	0,63	$1{,}06 \times 10^{-7}$
WTI	7.050	42,7 %	49,19	2.690,84	−0,85	0,88	$1{,}00 \times 10^{-7}$
Oro	7.203	17,2 %	15,07	351,17	−0,82	0,66	$1{,}44 \times 10^{-8}$
Bono del Tesoro	6.920	94,7 pb	8,19	143,63	−0,76	0,27	$4{,}00 \times 10^{-6}$
Bitcoin	4.576	67,7 %	29,05	1.316,62	−0,62	0,21	$1{,}01 \times 10^{-7}$

Muestra desde el 4 de enero de 1999 (Bitcoin, desde el 1 de marzo de 2014) hasta el 10 de septiembre de 2026. Obs. es el número de variaciones diarias, que es una unidad menor que el de precios conservados en la tabla 2.5, porque la primera sesión de cada serie no tiene una sesión anterior con la que calcular su variación. Vol. anual. es la raíz de la volatilidad diaria media anualizada (252 días, o 365 en Bitcoin), en porcentaje o en puntos básicos en el bono del Tesoro. El valor mínimo es el percentil 1 de los valores positivos, aplicado antes del escalamiento en logaritmo.

La tabla 2.5 muestra el resultado del control de calidad, en el que las observaciones eliminadas corresponden a sesiones fuera del calendario oficial de cada mercado, en su gran mayoría festivos. Las eliminaciones se concentran en el bono del Tesoro y en el WTI, mientras que las variaciones nulas legítimas, escasas en todas las series, reciben

Tabla 2.5: Anomalías por serie y acción.

Acción	S&P 500	Brent	WTI	Oro	Bono del Tesoro	Bitcoin
Conservar	6.937	7.087	7.030	7.174	6.851	4.569
Valor mínimo	27	23	21	30	70	8
Eliminar	0	1	49	4	217	0

el valor mínimo.

La tabla 2.6 muestra que la composición del riesgo geopolítico cambia de forma marcada en el periodo de prueba. El conflicto militar pasa a concentrar casi la mitad del índice y las sanciones son cercanas a duplicar su peso, mientras que el terrorismo cae a poco más de la tercera parte de su nivel previo. El golpe de Estado representa en torno al 1% del índice en ambos periodos, por lo que los resultados sobre esta categoría se apoyan en un número reducido de observaciones informativas.

Tabla 2.6: Proporción de cada tipo de evento en el índice AI-GPR.

	Entrenamiento (1999–2021)		Prueba (2022–2026)		
Tipo de evento	Media	Desv. típ.	Media	Desv. típ.	Autocorr.
Conflicto militar	0,242	0,113	0,476	0,126	0,75
Tensión diplomática	0,317	0,099	0,247	0,079	0,72
Terrorismo	0,160	0,083	0,058	0,031	0,65
Guerra civil	0,071	0,046	0,030	0,025	0,77
Amenaza nuclear	0,043	0,030	0,020	0,015	0,52
Golpe de Estado	0,014	0,019	0,013	0,018	0,34
Sanciones	0,025	0,024	0,045	0,041	0,70

La última columna muestra la autocorrelación de primer orden de cada proporción mensual calculada sobre la muestra del estudio. Mide la persistencia de la cobertura periodística de cada tipo de evento, que complementa la clasificación de persistencia esperada del capítulo 1 (tabla 1.3). Ambas persistencias pueden diferir, porque la cobertura de un evento no mide la duración de su efecto sobre la volatilidad.

2.2.2 Evolución del riesgo geopolítico y de la volatilidad

La figura 2.1 muestra que los máximos del AI-GPR diario coinciden con los atentados del 11 de septiembre de 2001, la invasión de Irak en 2003 y los atentados de París en 2015. En el periodo reciente destacan la invasión de Ucrania en 2022, que marca el valor más alto de la serie, el conflicto entre Israel y Hamás desde octubre de 2023 y el ataque de Irán contra Israel en abril de 2024. Les siguen la guerra entre Israel e Irán de junio de 2025 y la guerra de Estados Unidos e Israel contra Irán iniciada a finales de febrero de 2026, mientras que el mínimo de 2020 refleja el desplazamiento de la cobertura informativa por la pandemia.

El rasgo más relevante para este trabajo es el cambio de nivel a partir de 2022, ya

que la media del logaritmo del índice pasa de 4,52 en el periodo 1999 a 2021 a 5,04 en el periodo 2022 a 2026. El periodo de prueba corresponde, por tanto, a un régimen de riesgo geopolítico elevado y persistente.

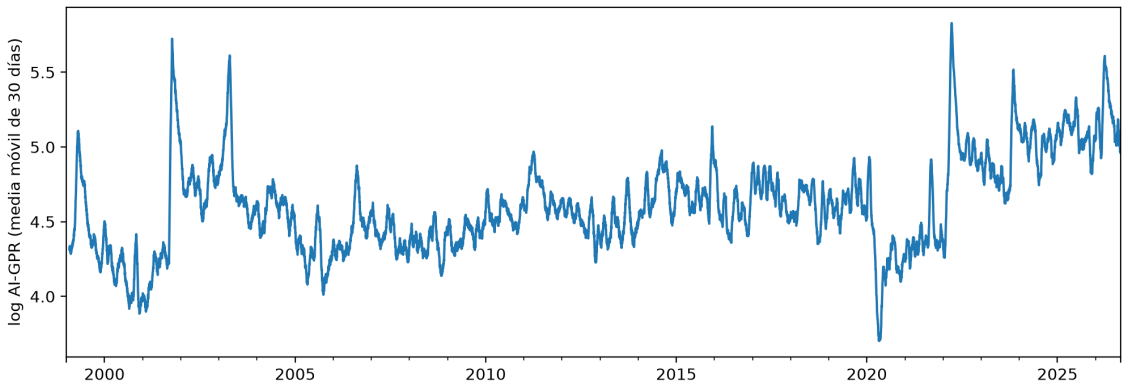


Figura 2.1: El sombreado marca el periodo de prueba, las líneas verticales los episodios citados en el texto y las horizontales la media de cada periodo.

La figura 2.2 muestra que el conflicto militar domina el índice en los grandes episodios bélicos, con proporciones cercanas al 75% en 2003 y en 2022. El terrorismo pierde peso de forma sostenida hasta quedar casi como residual en el periodo de prueba, mientras que las sanciones ganan presencia a partir de 2014 y, en especial, desde 2022.

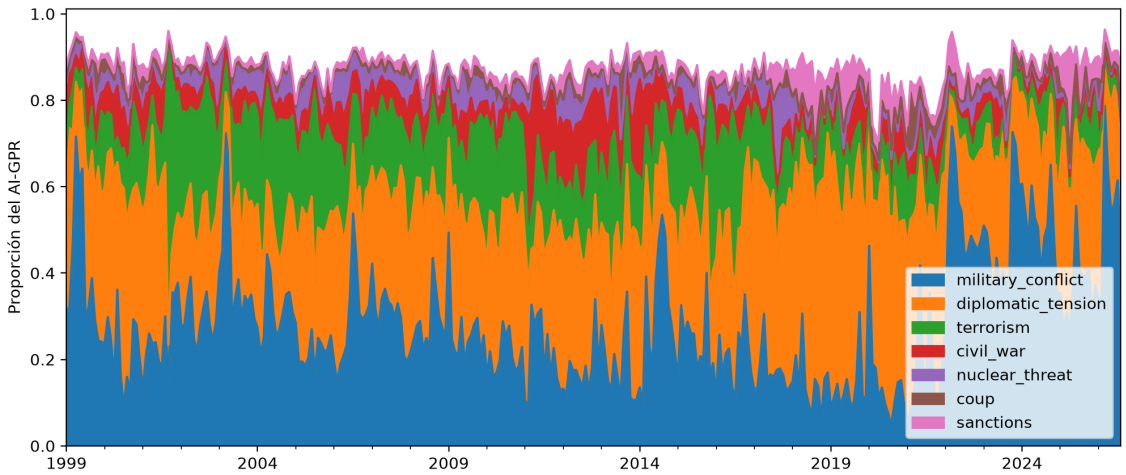


Figura 2.2: El espacio restante hasta la unidad corresponde a la categoría *otro*. La línea vertical separa el entrenamiento de la prueba.

En la figura 2.3, que muestra la volatilidad de cada serie en el periodo común a todas ellas, se observa agrupamiento de la volatilidad, es decir, una sucesión de periodos de volatilidad alta y baja en bloques persistentes. Este rasgo justifica emplear como referencia un modelo basado en la propia volatilidad pasada, como el HAR-RV. Todas las series alcanzan un máximo en marzo de 2020, al inicio de la pandemia, pero el resto de

episodios es específico de cada familia. La volatilidad del bono del Tesoro se mantiene elevada en 2022 y 2023, durante el ciclo de subidas de tipos, mientras que la del oro aumenta en 2025 y 2026. La del petróleo repunta en 2026 y la de Bitcoin muestra una tendencia descendente desde 2022. Esta diversidad indica que la volatilidad de cada familia responde en buena parte a factores propios, lo que justifica evaluar la aportación del riesgo geopolítico por separado en cada una.

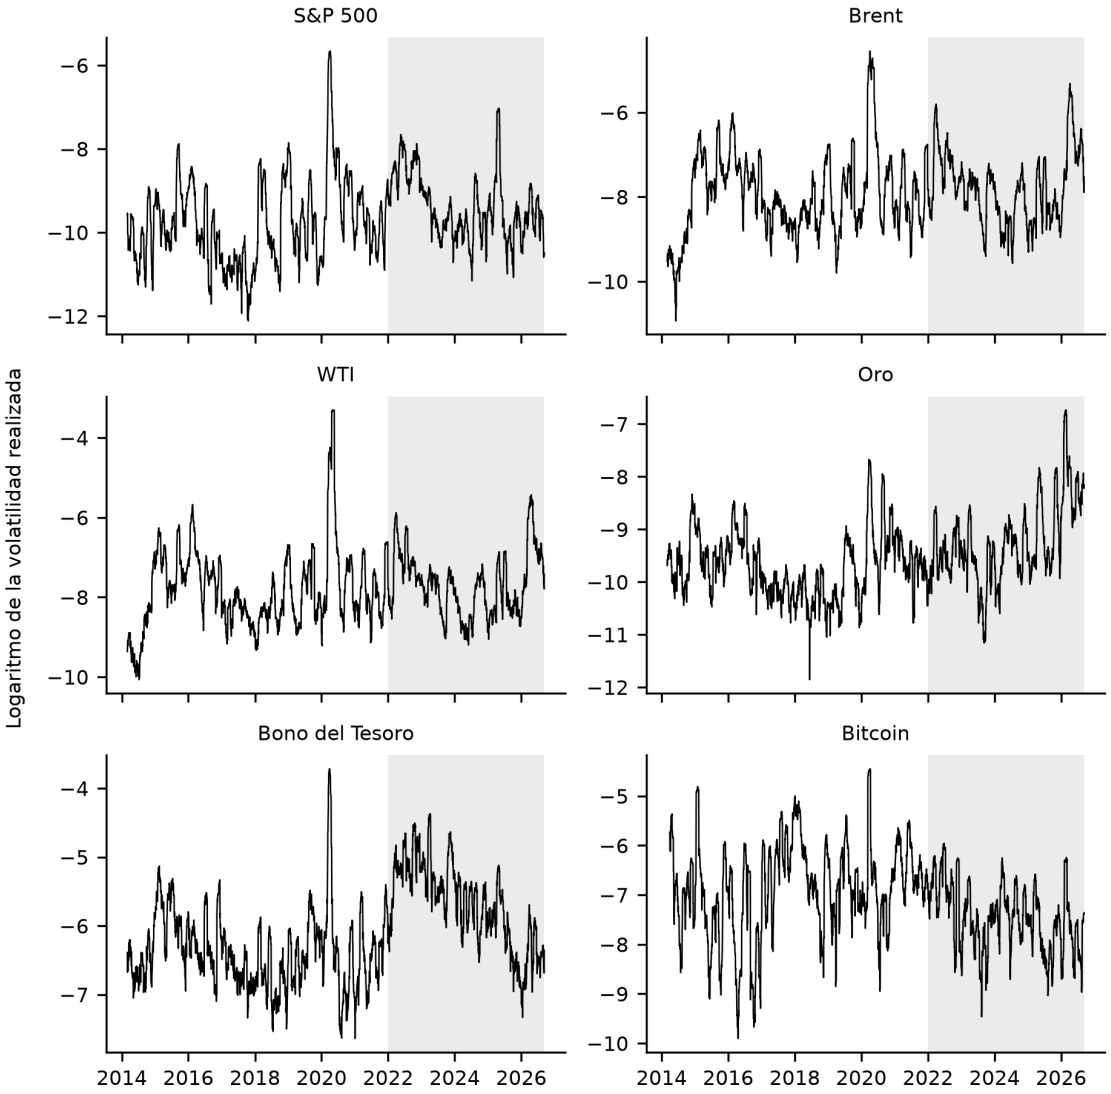


Figura 2.3: 30 días naturales en Bitcoin y 22 para el resto, en el periodo común a las seis series, desde 2014. El sombreado indica el periodo de prueba.

2.3 Variable objetivo

Para cada serie y sesión t, la variación diaria es

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right), \tag{2.1}$$

salvo en el bono del Tesoro, donde se usa la variación del rendimiento en puntos básicos, $r_t = y_t - y_{t-1}$, para evitar que los niveles bajos de tipos amplifiquen las variaciones relativas. La medida de la varianza diaria es $RV_t = r_t^2$, el cuadrado de la variación de cierre a cierre, que se elige por dos motivos. Con pérdidas robustas como la QLIKE, una medida ruidosa ordena los modelos igual que la volatilidad verdadera (Patton, 2011), mientras que la ventaja de los estimadores de rango es desigual entre activos, periodos y horizontes (Korkusuz et al., 2023). Además, la variación de cierre a cierre recoge los saltos entre el cierre de una sesión y la apertura de la siguiente, que los estimadores basados solo en el rango de la sesión omiten.

Como muestra la sección 2.2.1, la volatilidad se modela en logaritmos para corregir su asimetría. El logaritmo, sin embargo, no está definido cuando la variación es nula, algo que ocurre en días de mercado en que el movimiento del precio es inferior a la precisión con que se publica. Para el componente diario se aplica un valor mínimo ε,

$$\ell_t^{(d)} = \ln\left(\max(RV_t,\, \varepsilon)\right), \tag{2.2}$$

donde ε es el percentil 1 de las volatilidades diarias positivas de cada serie, calculado sobre la serie ya depurada y recogido en la tabla 2.4. Además de sustituir las variaciones nulas, este valor eleva hasta ε el 1 % inferior de las volatilidades positivas, cuyo logaritmo generaría valores atípicos en la cola inferior, motivo por el que se emplea un percentil y no el mínimo positivo de la serie. En los componentes semanal y mensual y en la variable objetivo, la volatilidad se promedia antes de tomar el logaritmo, porque una media de varias sesiones no es nula en la práctica.

La variable objetivo para un horizonte de h sesiones es la volatilidad media de las h sesiones siguientes,

$$RV_{t+1:t+h} = \frac{1}{h}\sum_{j=1}^{h} RV_{t+j}, \qquad h \in \{5,\ 22\}, \tag{2.3}$$

con $h \in \{7,\ 30\}$ días naturales en Bitcoin. Los horizontes se cuentan en sesiones tras eliminar los días fuera de sesión, de modo que cada ventana tiene siempre el mismo número de observaciones. Bitcoin cotiza los siete días de la semana, igual que el AI-GPR diario recoge los eventos ocurridos en fin de semana. Para conservar esa información, Bitcoin se analiza en calendario completo, con componentes y horizontes que cubren el mismo periodo de calendario que los del resto de series, y la sección 3.4 comprueba que esta elección no condiciona los resultados.

Se descarta el horizonte de un día por el error de medida de la variable objetivo y por

el del propio predictor. Si el rendimiento diario sigue una distribución normal con varianza σ^2, su cuadrado estima σ^2 sin sesgo, pero con una desviación típica de $\sqrt{2}\,\sigma^2$, lo que equivale a un error relativo del 141 %. Al promediar n días, el error relativo se reduce a $\sqrt{2/n}$, es decir, al 63 % en el horizonte semanal y al 30 % en el mensual. Son valores teóricos y mínimos, porque con las colas gruesas propias de los rendimientos financieros el error es mayor. Con un error de esa magnitud en el horizonte diario, un resultado nulo no permitiría distinguir si el riesgo geopolítico no aporta información o si la medida impide detectarla. En cuanto al predictor, el AI-GPR diario presenta un ciclo semanal ligado al volumen de publicación (Iacoviello & Tong, 2026) y recoge los eventos con un día de desfase. En el horizonte semanal ambos errores se atenúan sin renunciar a una lectura de corto plazo.

Los modelos se estiman sobre el logaritmo de la volatilidad pero se evalúan en niveles, de modo que al deshacer el logaritmo se aplica la corrección

$$\widehat{RV} = \exp(\hat{\ell} + \hat{s}^2/2), \tag{2.4}$$

donde $\hat{\ell}$ es la predicción en logaritmos y $\hat{s}^2$ la varianza del error en logaritmos del modelo. Esta varianza se calcula con los residuos del propio modelo en las 500 últimas observaciones de su muestra de estimación y se recalcula en cada reestimación mensual. La corrección se deriva de la distribución lognormal, ya que si el error en logaritmos es normal con varianza $\hat{s}^2$, la esperanza del nivel es la exponencial de la media más la mitad de la varianza. Como $\hat{s}^2$ procede de residuos dentro de muestra, su valor depende de cuánto se ajusta cada modelo a los datos de estimación, de modo que dos especificaciones de un mismo estimador pueden recibir correcciones distintas.

2.4 Variables predictoras

Los tres conjuntos de variables están anidados. El conjunto F0 contiene los componentes HAR de la volatilidad, es decir, la volatilidad del día anterior y sus medias de la última semana y del último mes,

$$RV_t^{(d)} = RV_t, \qquad RV_t^{(w)} = \frac{1}{5}\sum_{j=0}^{4} RV_{t-j}, \qquad RV_t^{(m)} = \frac{1}{22}\sum_{j=0}^{21} RV_{t-j}, \tag{2.5}$$

con ventanas de 1, 7 y 30 días naturales en Bitcoin. Los tres componentes se emplean en logaritmos, con la notación $\ell_t^{(d)}$, $\ell_t^{(w)}$ y $\ell_t^{(m)}$ de la ecuación (2.7).

La separación entre intensidad y composición sigue la lógica de frecuencia mixta del modelo GARCH-MIDAS (sección 1.2). La intensidad aporta la información de corto plazo y se mide con el AI-GPR diario, mientras que la composición aporta una información de cambio lento y se mide con la proporción mensual de cada tipo de evento.

El conjunto F1 añade a F0 la intensidad con la misma estructura de tres horizontes, de modo que sus componentes $g_t^{(d)}$, $g_t^{(w)}$ y $g_t^{(m)}$ son el logaritmo del AI-GPR diario y sus medias semanal y mensual. En las series que no cotizan en fin de semana, el AI-GPR

de los días no hábiles se agrega al siguiente día hábil mediante la media de los días agregados. Así el índice conserva su escala diaria, mientras que la suma multiplicaría artificialmente el valor de los lunes. Este tratamiento sigue a Smales (2021), quien muestra que los resultados son cualitativamente iguales con distintas formas de agregar el fin de semana.

El conjunto F2 añade a F1 la composición, medida con las proporciones de los siete tipos de evento en el mes anterior. Con la categoría *otro* como referencia, la proporción del tipo c en el mes m es

$$s_{c,m} = \frac{\text{AI-GPR}_{c,m}}{\sum_k \text{AI-GPR}_{k,m}}, \qquad c = 1, \ldots, 7. \tag{2.6}$$

Cada día t recibe la proporción del mes anterior al suyo, $s_{c,\,m(t)-1}$, mediante una función escalón, lo que garantiza que solo se usa información ya publicada. F2 se emplea únicamente en el horizonte mensual, que coincide con la frecuencia de publicación de la composición.

Se emplean proporciones y no los niveles de cada categoría porque los niveles suman exactamente el índice total y reproducirían la información de la intensidad. Las proporciones reducen ese solapamiento sin eliminarlo, ya que en la muestra del estudio la proporción del conflicto militar presenta una correlación de 0,62 con el logaritmo del AI-GPR mensual y la de la tensión diplomática, de −0,49, porque los episodios de mayor riesgo suelen estar dominados por conflictos armados. Además, como las proporciones suman uno, están correlacionadas entre sí. La relación más intensa es la del conflicto militar con la tensión diplomática, con una correlación de −0,70.

El trabajo no incorpora variables de control como el índice de incertidumbre de política económica (EPU) de S. Baker et al. (2015) o el factor de volatilidad geopolítica COVOL de Engle y Campos-Martins (2023). Como el objetivo es evaluar la capacidad predictiva del AI-GPR y no aislar un efecto causal, su inclusión no es necesaria para responder a las preguntas planteadas. Además, su correlación con la volatilidad pasada y con algunos tipos de evento dificultaría la atribución mediante técnicas de interpretabilidad. La contrapartida es que los resultados no permiten distinguir si la información aportada es específica del riesgo geopolítico o refleja en parte una incertidumbre más general.

2.5 Modelos

El diseño emplea un modelo de referencia, su extensión lineal y tres modelos de aprendizaje automático que cubren formas funcionales de complejidad creciente. Elastic Net mantiene la estructura lineal y añade regularización, el SVR introduce la no linealidad mediante un núcleo y XGBoost captura umbrales e interacciones mediante árboles de decisión.

No se incluye la combinación de predicciones de varios estimadores, pese a que Niu et al. (2023) documentan que mejora la precisión de la mayoría de los modelos individuales. El objeto del trabajo no es maximizar la precisión, sino determinar si el riesgo geopolítico

y su composición aportan información sobre la volatilidad futura. Una combinación no incorpora información distinta de la de sus componentes, por lo que no añade evidencia sobre esa pregunta. Por motivos análogos se descartan Random Forest, conceptualmente redundante con XGBoost, y las redes neuronales, en favor de la interpretabilidad de los modelos.

2.5.1 Modelo de referencia y extensión lineal

El modelo de referencia es el HAR-RV de Corsi (2008), estimado en logaritmos,

$$\ell_{t+1:t+h} = \beta_0 + \beta_d\, \ell_t^{(d)} + \beta_w\, \ell_t^{(w)} + \beta_m\, \ell_t^{(m)} + \varepsilon_{t+h}, \tag{2.7}$$

donde $\ell_{t+1:t+h}$ es el logaritmo de la variable objetivo. El HAR-X amplía la ecuación (2.7) con los bloques de información geopolítica,

$$\ell_{t+1:t+h} = \beta_0 + \beta_d \ell_t^{(d)} + \beta_w \ell_t^{(w)} + \beta_m \ell_t^{(m)} + \gamma_d g_t^{(d)} + \gamma_w g_t^{(w)} + \gamma_m g_t^{(m)} + \sum_{k=1}^{7} \delta_k\, s_{k,\, m(t)-1} + \varepsilon_{t+h}. \tag{2.8}$$

Como la categoría *otro* actúa como referencia, cada δ_k mide el efecto de que el tipo k gane peso a costa de ella. Con $\gamma = \delta = 0$ se obtiene el HAR-RV, que corresponde al conjunto F0, con $\delta = 0$ el conjunto F1 y sin restricciones el F2. Al estar anidados, la comparación entre los tres conjuntos aísla la aportación de cada bloque bajo una especificación lineal. Esa comparación sirve de referencia para valorar si los modelos de aprendizaje automático aprovechan mejor la misma información, como plantea la hipótesis H1b.

2.5.2 Elastic Net

Elastic Net (Zou & Hastie, 2005) estima una regresión lineal con una penalización que combina las normas L1 y L2 de los coeficientes,

$$\hat{\beta} = \arg\min_{\beta}\ \frac{1}{2n}\|y - X\beta\|_2^2 + \alpha\rho\|\beta\|_1 + \frac{\alpha(1-\rho)}{2}\|\beta\|_2^2, \tag{2.9}$$

donde α controla la intensidad de la penalización y ρ la proporción de la norma L1. La norma L1 puede anular coeficientes, lo que permite descartar variables que no aportan, mientras que la L2 estabiliza la estimación cuando las variables están correlacionadas, como ocurre entre los componentes HAR y entre las proporciones de tipos de evento.

Las variables se estandarizan antes de la estimación para que la penalización trate por igual a todos los coeficientes con independencia de su escala. Cuando α se aproxima a cero, el modelo equivale al HAR-X, de modo que Elastic Net solo se separa de él si la regularización mejora la predicción en la validación cruzada.

2.5.3 Máquinas de vectores de soporte para regresión

El modelo de máquinas de vectores de soporte para regresión (SVR) (Drucker et al., 1996; Smola & Schölkopf, 2004) estima una función que se desvía de los valores obser-

vados como máximo en un margen ε. Los errores dentro de ese margen se ignoran y los que lo superan se penalizan linealmente con un peso C, mientras que un núcleo gaussiano, $K(x, x') = \exp(-\gamma\|x - x'\|^2)$, permite que la función sea no lineal en las variables originales.

El hiperparámetro ε fija la tolerancia al error, C el equilibrio entre ajuste y suavidad y γ la escala a la que el núcleo considera similares dos observaciones, de modo que valores pequeños de γ producen funciones más suaves. Las variables se estandarizan antes de la estimación.

2.5.4 XGBoost

XGBoost (Chen & Guestrin, 2016) construye la predicción como una suma de árboles de decisión, cada uno ajustado sobre los errores de los anteriores, con regularización de la complejidad de los árboles. Los árboles capturan relaciones no lineales, umbrales e interacciones sin especificarlos de antemano. Su limitación es que no extrapolan fuera del rango observado en el entrenamiento, ya que ante un valor mayor que cualquiera de los observados la predicción se mantiene en la del último tramo conocido.

Se ajustan siete hiperparámetros, que son la profundidad de los árboles, su número, la tasa de aprendizaje, el peso mínimo por hoja, la proporción de filas y la de columnas muestreadas en cada árbol y la regularización L2. Las proporciones de filas y columnas se muestrean con una semilla fija, lo que hace reproducibles las estimaciones.

2.6 Diseño de la evaluación fuera de muestra

2.6.1 Partición, estimación y ajuste de hiperparámetros

El periodo de prueba abarca de enero de 2022 a agosto de 2026, es decir, 56 meses comunes a todas las series. Los modelos se estiman con una ventana expansiva y se reestiman cada mes, coincidiendo con la publicación de cada nuevo dato de los tipos de evento. Al reestimar en la fecha t, solo entran las observaciones cuya ventana objetivo ya ha concluido, es decir, hasta $t - h$, para evitar la fuga de información.

Los hiperparámetros se ajustan una sola vez, con validación cruzada temporal dentro del periodo de entrenamiento, y se mantienen fijos en la prueba. Cada conjunto de variables recibe su propio ajuste, de modo que un mismo estimador puede tener hiperparámetros distintos con F0, F1 y F2. La búsqueda comienza con una exploración aleatoria de 40 combinaciones por modelo sobre rangos amplios, en escala logarítmica para los parámetros de escala. Después, una rejilla fina refina el mejor punto encontrado evaluando, para cada parámetro principal, la mitad, el mismo valor y el doble.

La validación cruzada emplea cinco pliegues temporales, cada uno de los cuales entrena con las observaciones anteriores y valida con las posteriores. Entre ambas se deja un margen igual al horizonte mensual, de 22 sesiones o 30 días en Bitcoin, para que las variables objetivo del entrenamiento no se solapen con las de la validación. El criterio de selección es la pérdida QLIKE en niveles, la misma de la evaluación (Patton, 2011), y los rangos explorados y los valores seleccionados se detallan en la sección 3.5.

2.6.2 Métricas

Sobre las predicciones en niveles se calculan dos pérdidas,

$$\mathrm{MSE} = \frac{1}{T}\sum_{t}\left(RV_t - \widehat{RV}_t\right)^2, \qquad \mathrm{QLIKE} = \frac{1}{T}\sum_{t}\left(\frac{RV_t}{\widehat{RV}_t} - \ln\frac{RV_t}{\widehat{RV}_t} - 1\right), \tag{2.10}$$

donde RV_t es la volatilidad realizada en la ventana objetivo, $\widehat{RV}_t$ su predicción y T el número de predicciones del periodo de prueba. Ambas pérdidas son robustas al error de medida de la volatilidad (Patton, 2011). La QLIKE es la métrica principal porque penaliza más la subestimación de la volatilidad que su sobrestimación, lo que la hace adecuada para la gestión del riesgo, donde quedarse corto resulta más costoso. El MSE se emplea como métrica complementaria y, al ser más sensible a los valores extremos, permite comprobar si las conclusiones dependen de la pérdida elegida. La mejora frente al modelo de referencia se expresa con el R^2 fuera de muestra,

$$R^2_{\mathrm{OOS}} = 1 - \frac{L_{\mathrm{modelo}}}{L_{\text{HAR-RV}}}, \tag{2.11}$$

donde L es la pérdida media de cada modelo. Un valor positivo indica que el modelo predice mejor que el HAR-RV, y uno negativo, que predice peor.

2.6.3 Contrastes y criterios de resolución

El modelo principal de cada uno de los doce casos, que resultan de combinar las seis series con los dos horizontes, es el estimador con menor pérdida QLIKE en la validación cruzada del periodo de entrenamiento con el conjunto F0. Este modelo se elige sin usar el periodo de prueba, de modo que cada hipótesis se decide en cada caso con un único contraste, mientras que los demás estimadores se presentan como resultados parciales.

Las comparaciones anidadas, F1 frente a F0 y F2 frente a F1 con un mismo estimador, se contrastan con el test de Clark-West. Este test corrige el sesgo que introduce la estimación de los parámetros adicionales del modelo mayor, que bajo la hipótesis nula tiende a penalizarlo. Se construye sobre el error cuadrático de la predicción del logaritmo de la volatilidad, mientras que la QLIKE se calcula sobre la volatilidad en niveles. En SVR y XGBoost, los conjuntos F0 y F1 están anidados en la información pero no en los parámetros, porque cada conjunto tiene sus propios hiperparámetros, por lo que en esos casos el test de Clark-West se aplica como aproximación.

Como el test de Clark-West se basa en el error cuadrático en logaritmos y la métrica principal es la QLIKE en niveles, una mejora se acepta solo si el test es significativo al 5 % y la QLIKE disminuye. Así, la significación estadística y la reducción de la pérdida principal se exigen a la vez. Como la H1a implica doce contrastes, uno por caso, se informa además del valor p ajustado por el procedimiento de Holm (1979).

Las comparaciones no anidadas se contrastan con el test de Diebold-Mariano sobre la QLIKE en niveles. Con fines descriptivos, el test se aplica de forma bilateral para compa-

rar cada modelo con el HAR-RV. Para resolver la H1b, que compara el modelo principal con F1, cuando es de aprendizaje automático, frente al HAR-X con F1, se aplica de forma unilateral y con la corrección de muestra pequeña de Harvey et al. (1997). Como las ventanas objetivo se solapan, todos los contrastes usan errores estándar robustos a heterocedasticidad y autocorrelación (HAC) de Newey-West, con $h - 1$ rezagos. La tabla 2.7 resume, para cada hipótesis, la comparación que la decide, la prueba aplicada y la condición de aceptación.

Tabla 2.7: Criterios de resolución de las hipótesis.

Hipótesis	Comparación	Prueba	Se acepta si
H1a	F1 frente a F0 con el mismo estimador, en el modelo principal de los 12 casos	Clark-West unilateral con errores HAC	p < 0,05 y menor QLIKE. Se informa también del valor p ajustado por Holm
H1b	Modelo principal con F1, cuando es de aprendizaje automático, frente al HAR-X con F1, en los casos que cumplen la H1a	Diebold-Mariano unilateral sobre la QLIKE con corrección de muestra pequeña	p < 0,05 a favor del modelo de aprendizaje automático. Si ningún caso cumple la H1a, la H1b no se evalúa
H2	F2 frente a F1 con el mismo estimador, en el modelo principal de los 6 casos mensuales	Clark-West unilateral con errores HAC	p < 0,05 y menor QLIKE

Ninguna de las dos evidencias complementarias interviene en la resolución. La primera es la repetición de todas las comparaciones con el MSE, cuyos resultados están disponibles en la tabla C.2. La segunda es el conjunto de confianza de modelos (MCS) de Hansen et al. (2011), que se emplea siguiendo a Niu et al. (2023) porque el diseño compara numerosos modelos en cada caso. El MCS identifica el subconjunto de modelos que no pueden distinguirse estadísticamente del mejor al compararlos todos a la vez, de modo que controla el riesgo de falsos positivos asociado a las comparaciones múltiples. Se aplica en cada caso sobre la QLIKE de todos los modelos, con un nivel del 10 %, el estadístico de rango y un bootstrap estacionario con bloques de longitud igual al horizonte de predicción.

2.7 Interpretabilidad

Los valores SHAP describen la contribución predictiva de cada variable, es decir, cuánto aporta a la predicción de un modelo ya estimado. Esa contribución no depende de que la variable mejore la predicción fuera de muestra, que se contrasta con los tests de la sección 2.6.3. Por ello, la interpretabilidad no interviene en la resolución de las hipótesis, sino que describe cómo usan los modelos la información geopolítica y sostiene el análisis exploratorio de la sección 1.4.

La contribución se analiza en dos niveles, empezando por el peso de los tres bloques de variables, que son los componentes HAR, la intensidad y la composición. A continuación se compara la contribución de cada tipo de evento dentro del bloque de composición.

La contribución de cada variable es la media del valor absoluto de sus valores SHAP en los días del periodo de prueba. La de un bloque es la suma de las de sus variables, expresada como proporción del total.

El análisis por tipo de evento se aplica a los 24 modelos del horizonte mensual con F2, que resultan de seis series y cuatro estimadores. El análisis por bloques se aplica además a 17 modelos con F1 de ambos horizontes, que son los doce modelos principales y los cinco secundarios en que la intensidad mejora la predicción, para describir cómo se usa la intensidad allí donde aporta capacidad predictiva. En las comparaciones entre familias, los resultados del Brent y del WTI se leen de forma conjunta como los de la familia de energía.

Los valores SHAP se calculan sobre un modelo con F2, o con F1, ajustado una sola vez con todo el periodo de entrenamiento, salvo sus h últimas observaciones, y aplicado a todos los días del periodo de prueba. Se explica, por tanto, un único modelo representativo de cada combinación de serie y estimador, y no cada una de las reestimaciones mensuales. En los modelos lineales, los valores SHAP se calculan de forma exacta a partir de sus coeficientes, como el producto de cada coeficiente por la desviación de la variable respecto a su media en el entrenamiento, mientras que en XGBoost se emplea TreeSHAP. En el SVR, que no admite un cálculo exacto eficiente, se emplea KernelSHAP (Lundberg & Lee, 2017) con una muestra de fondo de 50 centroides del periodo de entrenamiento. Para reducir el tiempo de cómputo, el cálculo se reparte por bloques de días entre varios procesos, cada uno con una semilla fija, de modo que el resultado es reproducible.

La importancia por permutación complementa a SHAP. Mide cuánto aumenta la QLIKE del periodo de prueba cuando se desordenan los valores de un bloque, lo que rompe su relación con la variable objetivo. Las proporciones se permutan por bloques de mes completo, para respetar que cada valor se mantiene constante durante un mes.

En el análisis exploratorio, un tipo de evento solo se considera dominante si lo es con los cuatro estimadores, de modo que el resultado no dependa de una forma funcional concreta. La contribución de cada tipo se mide también por unidad de variación, porque la contribución SHAP de una variable depende de su efecto en el modelo y de cuánto se alejan sus valores en la prueba de la media del entrenamiento, que es la referencia del cálculo. Como la composición cambia entre ambos periodos (tabla 2.6), ese alejamiento combina la dispersión de cada proporción y el desplazamiento de su media. Por ello, la contribución media de cada tipo se divide entre

$$\sqrt{\sigma^2_{c,\text{prueba}} + \left(\mu_{c,\text{prueba}} - \mu_{c,\text{entrenamiento}}\right)^2}, \tag{2.12}$$

que es la distancia cuadrática media de su proporción en la prueba respecto a la media del entrenamiento. Dividir solo entre la desviación típica de la prueba dejaría sin corregir el desplazamiento de la media, que es grande en el terrorismo y en el conflicto militar. En los modelos lineales, donde el efecto de cada tipo es directamente su coeficiente, la comparación se completa con los coeficientes estandarizados.

Las correlaciones entre la intensidad y la composición, y entre las propias proporciones (sección 2.4), implican que SHAP reparte entre ellas una parte de la contribución que comparten. Por ello, la comparación entre el conflicto militar y la tensión diplomática se interpreta con cautela. También se tiene en cuenta que la contribución del conflicto militar puede quedar parcialmente absorbida por la intensidad, con la que presenta una correlación de 0,62.

2.8 Pruebas de robustez

Las seis pruebas de robustez de la tabla 2.8 comprueban si el resultado de la H1a en los modelos principales depende de decisiones concretas sobre la muestra, el calendario, el cambio de contrato del WTI o el tratamiento de los valores nulos. Como suman numerosos contrastes adicionales, sus resultados se leen como evidencia de estabilidad y no como nuevas mejoras, y se presentan en la sección 4.4.

Tabla 2.8: Pruebas de robustez.

Prueba	Casos	Decisión que evalúa
Agrupación por semana y mes de calendario, sin solapamiento	Los doce casos	El solapamiento de las ventanas objetivo
Agregación de toda la información a frecuencia mensual	Los seis casos mensuales	La combinación de frecuencias diaria y mensual
Series tradicionales reestimadas desde el inicio de Bitcoin	Los diez casos de las series tradicionales	La longitud de la muestra de entrenamiento
Bitcoin alineado al calendario hábil del S&P 500	Los dos casos de Bitcoin	El uso del calendario completo en Bitcoin
WTI con la variación del 22 de abril de 2020 medida en el contrato de junio	Los dos casos del WTI	El cambio de contrato de esa fecha
Valor mínimo en los percentiles 0,5 y 5	Los seis casos mensuales	El tratamiento de las variaciones nulas

CAPÍTULO 3

DESARROLLO EXPERIMENTAL

Este capítulo describe cómo se implementó el diseño del capítulo 2 y cuales comprobaciones se realizaron para garantizar que las decisiones de implementación no alteran los resultados. Se centra en cuatro aspectos que condicionan la validez de la evaluación: la depuración de los datos, los cambios de contrato de las series de energía, el calendario de Bitcoin y el ajuste de los hiperparámetros.

3.1 Organización de la implementación

La implementación se organiza en un único notebook de Python que reproduce todo el análisis a partir de los archivos de datos originales. El flujo abarca la carga, el control de calidad y la limpieza de los datos, la construcción de las variables, el ajuste de hiperparámetros, la predicción y la evaluación. Le siguen la interpretabilidad, las pruebas de robustez y la validación de la reproducibilidad (figura 3.1).

Cada paso se implementa en celdas numeradas que se apoyan en funciones reutilizables, de modo que todas las series, horizontes, conjuntos de variables y estimadores se procesan en un mismo entorno. Resultados intermedios y finales se guardan con un identificador de ejecución, que permite asociar cada cifra de esta memoria con la ejecución que la produjo, y el notebook puede ser ejecutado completo sin intervención manual.

3.2 Construcción y depuración del conjunto de datos

La construcción parte de los archivos originales de cada serie y del AI-GPR, que se cargan sin modificarlos. A continuación, el control de calidad marca cada observación con su tipo de anomalía, la acción aplicada y su motivo. Sobre la serie limpia se calculan después la variación diaria, la volatilidad diaria con su valor mínimo, los componentes HAR y la variable objetivo de cada horizonte, que forman el conjunto F0. Los conjuntos F1 y F2 se obtienen al añadir la intensidad del AI-GPR y la composición del mes anterior. El resultado es una matriz por serie con todas las variables y con la partición entre entrenamiento y prueba, que constituye la entrada común de todos los modelos.

El registro de anomalías se realiza mediante el tipo, la acción que requiere y el motivo que la justifica. Esto permite revisar cada decisión y reproducir los recuentos de la tabla 2.5.

Solo dos decisiones implicaron modificar datos o descartar observaciones con variación real. En el oro, los cierres del 10 y el 11 de marzo de 2008 repetían el valor del día anterior en sesiones con movimiento de precio, por lo que se sustituyeron por los cierres de una fuente externa. En el resto de casos, las observaciones eliminadas son días fuera del calendario de sesiones de cada mercado. Los calendarios del S&P 500, del bono del Tesoro y de Bitcoin se consideran verificados, de modo que toda observación fuera de

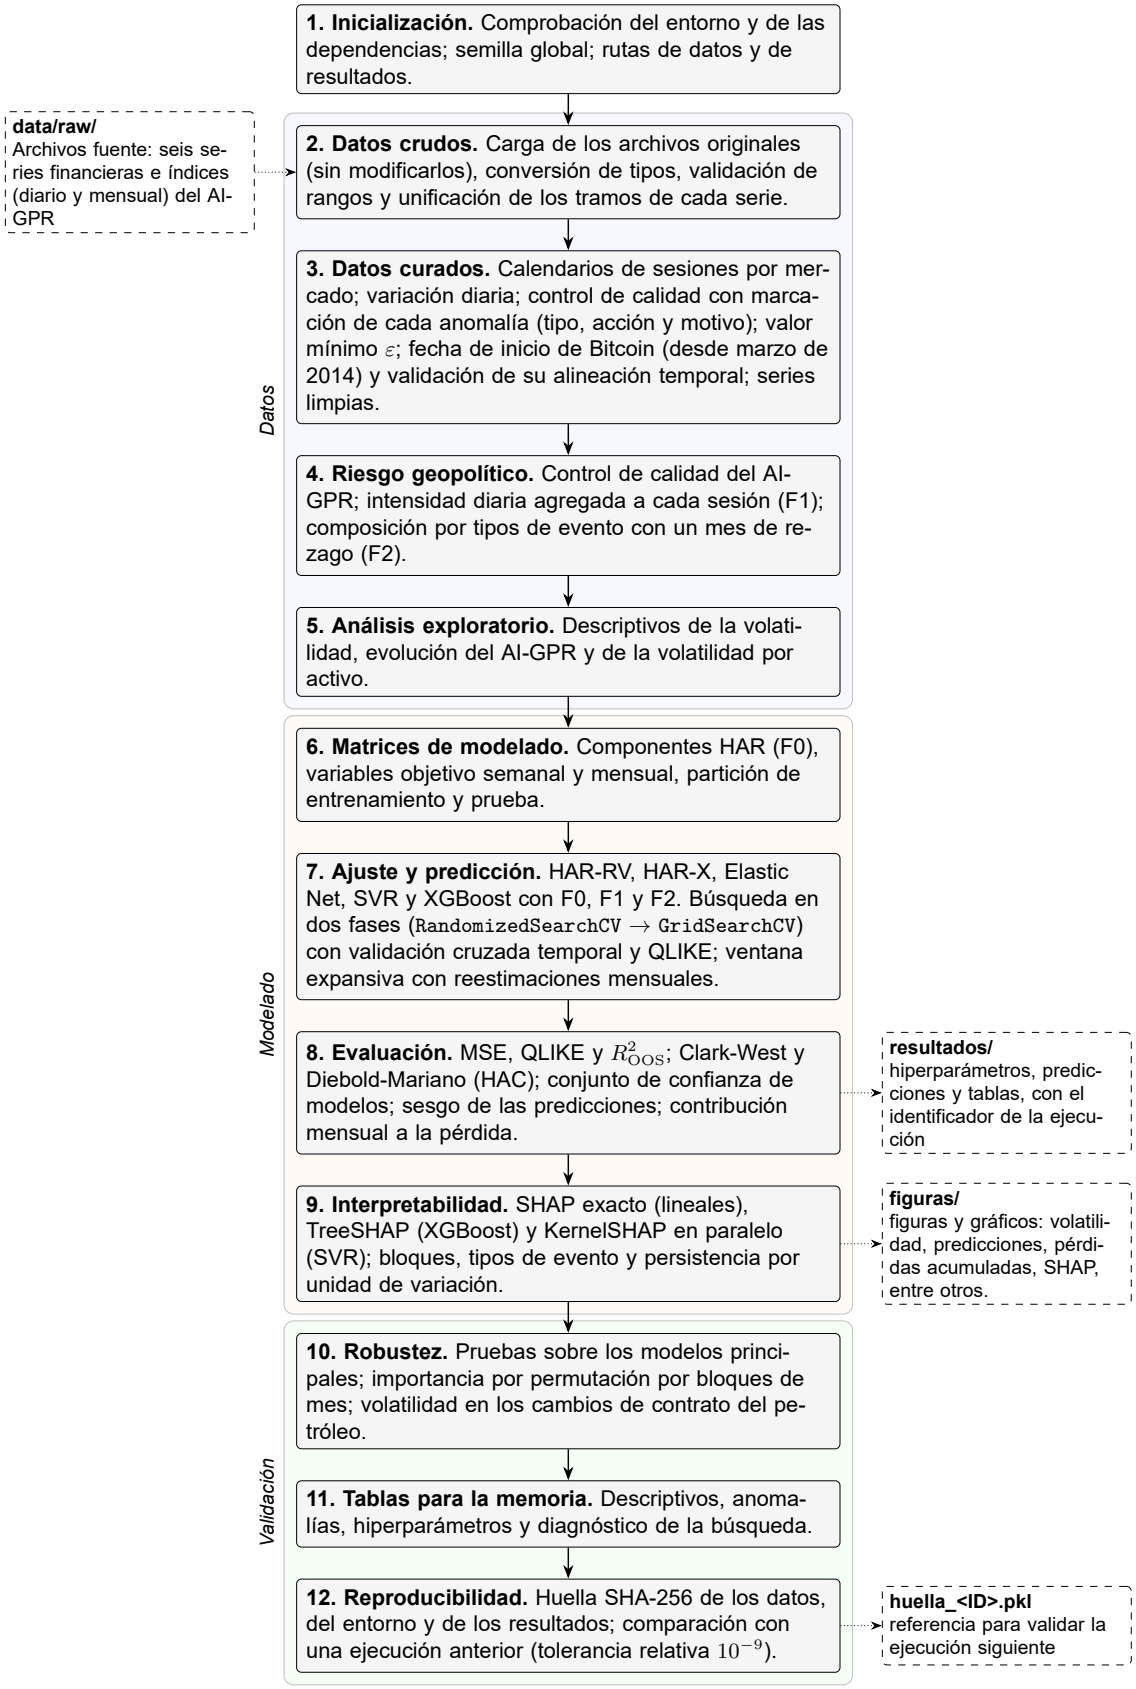


Figura 3.1: Flujo del notebook de investigación.

sesión se elimina. Los del petróleo y el oro no lo están, porque esos mercados pueden cotizar en días que el calendario no recoge, por lo que en ellos una observación fuera de sesión solo se elimina si su variación es nula. El apéndice A detalla los calendarios empleados y el desglose de las eliminaciones.

3.3 Cambios de contrato en las series de energía

Las series de energía son continuas y no se publican las fechas en que cambian de contrato. El caso más relevante se produjo el 22 de abril de 2020, cuando la serie de WTI pasó del contrato de junio al de julio, cuya diferencia de precio era entonces de casi siete dólares por barril según la serie de contratos de futuros de la EIA. La variación registrada ese día, del 79 %, combina el movimiento real del mercado, del 19 % en el contrato de junio, con la diferencia de precio entre ambos contratos.

De acuerdo con el criterio general de emplear los datos tal como se publican, la serie no se corrige. El efecto se limita a un día del periodo de entrenamiento y no afecta al de evaluación, pero una prueba de robustez repite la estimación con la variación de ese día medida dentro del contrato de junio (sección 4.4).

Para comprobar si otros cambios de contrato introducen saltos artificiales, se compara la volatilidad de varias ventanas en torno a cada vencimiento con la del resto de sesiones. Las cinco sesiones que terminan en el vencimiento presentan una volatilidad menor que el resto. En cambio, la sesión siguiente, en la que la serie continua pasa al nuevo contrato, presenta una volatilidad significativamente mayor en ambas series en el test de Mann-Whitney (p < 0,001), con una media geométrica 1,8 veces superior a la del resto en el WTI y 1,9 veces en el Brent. Cuando la ventana abarca desde cuatro sesiones antes hasta dos después del vencimiento, ambos efectos se compensan y la diferencia deja de ser significativa, como recoge el apéndice A junto con las reglas de vencimiento.

Este resultado indica que los cambios de contrato introducen variaciones que no responden solo a movimientos del mercado, como ocurre en el caso documentado de abril de 2020. En el Brent, la sesión siguiente al vencimiento coincide además con la primera de cada mes, de modo que la diferencia puede recoger también un efecto de cambio de mes. Estas sesiones representan en torno a una de cada veintiuna y están presentes tanto en el entrenamiento como en la prueba. Como todos los modelos de una misma serie predicen la misma variable objetivo, el ruido que introducen afecta por igual a las especificaciones con y sin riesgo geopolítico. No puede descartarse, sin embargo, que su efecto sea mayor en los episodios de tensión, en los que la diferencia de precio entre contratos consecutivos puede ampliarse. Por ello, las mejoras parciales de la energía semanal, concentradas en esos episodios, se interpretan con cautela (sección 4.2.2).

3.4 Validación de la alineación temporal de Bitcoin

Para comprobar que analizar Bitcoin en calendario completo (sección 2.3) no condiciona los resultados, se comparó con la alternativa de alinear la serie al calendario hábil del S&P 500 desde marzo de 2014. En la alineación, las variaciones de los días no hábiles

se acumulan en el siguiente día hábil. La alineación reduciría la varianza medida en un 3,0 %, con un intervalo de confianza del 95 % entre −0,9 % y 6,5 %, de modo que la diferencia no es significativa. Ambas medidas presentan además una correlación de 0,941 en el horizonte semanal y de 0,975 en el mensual. Como prueba de robustez, el modelo principal de Bitcoin se estima también con la serie alineada.

3.5 Ajuste de hiperparámetros

La búsqueda en dos fases de la sección 2.6.1 se aplicó a los 90 modelos con hiperparámetros, que resultan de los doce casos, con sus conjuntos de variables, y de los tres estimadores de aprendizaje automático, con los rangos de la tabla B.1. La segunda fase mejora la pérdida de validación en 76 modelos, aunque las mejoras medias son pequeñas, de 0,0002 en Elastic Net, 0,0033 en el SVR y 0,0024 en XGBoost, lo que indica que la búsqueda aleatoria ya se había aproximado al óptimo. La mayor mejora corresponde al SVR del S&P 500 mensual con F0, cuya pérdida pasa de 0,428 a 0,410, lo que lo convierte en el modelo principal de ese caso.

En 27 de los 90 modelos, la rejilla fina de la segunda fase sitúa algún hiperparámetro fuera del rango de la primera. Este comportamiento es posible por diseño, porque la rejilla evalúa la mitad y el doble del mejor valor encontrado, y su interpretación difiere según el estimador. En los trece modelos de Elastic Net afectados, la penalización desciende por debajo de 10^{-5}, lo que indica que la validación cruzada prefiere un modelo sin regularización. Como reducir más la penalización no modifica la estimación, que converge a la del HAR-X, estos casos no suponen una limitación del ajuste.

En el SVR y en XGBoost, en cambio, el valor seleccionado se sitúa en el límite del espacio explorado. Ocho SVR, siete de ellos de las series de energía, tienen un parámetro del núcleo γ inferior a 10^{-3}, que corresponde a funciones más suaves y próximas a una relación lineal, y el SVR de Bitcoin mensual con F2 tiene un margen ε inferior al límite del rango. En XGBoost, cuatro modelos superan los 1.500 árboles y el de Bitcoin semanal con F1 tiene una tasa de aprendizaje inferior a 0,005. En estos modelos no puede descartarse que un espacio de búsqueda más amplio ofrezca una pérdida de validación algo menor. Su posible efecto sobre los resultados se analiza en la sección 4.6.3, y los hiperparámetros elegidos en cada caso se recogen en la tabla B.2.

Por último, el número máximo de iteraciones de los optimizadores no forma parte de la búsqueda de hiperparámetros. No obstante, se fijó en 10.000 en Elastic Net y en 200.000 en el SVR para garantizar que cada estimación termine, y se mantuvo igual en todas las etapas del flujo de entrenamiento como medida de seguridad. La ejecución definitiva no registró avisos de falta de convergencia, de modo que ese límite no condicionó ninguna estimación. Por su parte, en XGBoost, el papel equivalente lo cumple el número de árboles, que sí forma parte de la búsqueda (tabla B.1).

3.6 Reproducibilidad

Todas las fuentes de aleatoriedad del flujo usan una única semilla, fijada antes de cualquier estimación. Para validar la reproducibilidad, el notebook se ejecutó completo dos veces con los mismos datos y con un reinicio previo, y se compararon ambas ejecuciones. Los datos de entrada coincidieron en su huella SHA-256, y el resto de resultados, desde los hiperparámetros hasta las tablas de esta memoria, fueron idénticos con una tolerancia relativa de 10^{-9}.

Una ejecución completa requiere aproximadamente 2.5 horas, en su mayor parte dedicadas a los valores SHAP del SVR y a la predicción con ventana expansiva. El entorno de software, con Python 3.14 y las versiones de cada librería, figura en el apéndice B.

El código se encuentra disponible en un repositorio público. También es posible solicitar el código y los datos a través del correo electrónico al autor.

CAPÍTULO 4

RESULTADOS Y DISCUSIÓN

En este capítulo se presentan los resultados en tres niveles, de los cuales el resultado principal corresponde al modelo principal de cada caso y es el único que decide las hipótesis. Los resultados parciales corresponden a los demás estimadores y matizan la lectura del principal. Los hallazgos de robustez indican si el resultado depende de decisiones concretas del diseño. Las secciones 4.1 a 4.4 recogen esa evidencia, la sección 4.5 resuelve las hipótesis y la sección 4.6 discute su alcance.

4.1 Resultados principales

La tabla 4.1 resume los resultados del modelo principal de cada caso, que es el estimador con menor pérdida QLIKE en la validación cruzada con el conjunto F0. La mejora se expresa frente al HAR-RV, de modo que un valor positivo indica que el modelo predice mejor que la referencia. La aportación del riesgo geopolítico es la diferencia entre la columna de F1, o de F2, y la de F0.

Tabla 4.1: Resultados del modelo principal de cada caso.

			Mejora QLIKE (%)			Mejora MSE (%)			Clark-West, p	
Caso	Principal	QLIKE F0	F0	F1	F2	F0	F1	F2	F1/F0	F2/F1
S&P 500, mensual	SVR	0,220	+1,3	−2,1	−18,2	−14,1	−13,7	−4,7	0,230	0,908
S&P 500, semanal	SVR	0,360	+2,7	+1,0	—	−4,2	−10,0	—	0,779	—
Brent, mensual	HAR	0,252	0,0	−3,2	−11,4	0,0	−1,5	−12,3	0,948	0,426
Brent, semanal	HAR	0,379	0,0	−0,1	—	0,0	−0,4	—	0,492	—
WTI, mensual	SVR	0,221	−2,1	−1,2	−16,9	−4,4	−1,5	−8,7	0,050	0,911
WTI, semanal	HAR	0,332	0,0	−0,3	—	0,0	−0,2	—	0,773	—
Oro, mensual	SVR	0,253	−1,6	−20,1	−35,2	−3,2	−6,4	−11,6	0,814	0,791
Oro, semanal	SVR	0,392	+0,5	−5,3	—	−0,4	−1,0	—	0,850	—
Bono del Tesoro, mensual	SVR	0,111	−5,0	−10,8	−14,8	−4,3	−24,4	−15,3	0,053	0,081
Bono del Tesoro, semanal	SVR	0,258	−0,4	−1,9	—	−0,4	−2,2	—	0,842	—
Bitcoin, mensual	SVR	0,258	+0,1	+7,8	−17,1	+2,3	+14,3	−19,4	<0,001	0,994
Bitcoin, semanal	Elastic Net	0,494	+2,7	+2,2	—	+4,2	+3,6	—	0,617	—

La mejora es el R^2 fuera de muestra frente al HAR-RV con cada pérdida. HAR designa al HAR-RV con F0 y al HAR-X con F1 y F2. Los resultados de todos los estimadores con ambas pérdidas figuran en las tablas C.1 y C.2.

El SVR es el modelo principal en ocho de los doce casos, porque en la validación cruzada supera al HAR en la mayoría de las series. Fuera de muestra, sin embargo, sus diferencias frente al HAR-RV con F0 son pequeñas y de signo variable. Predice mejor que la referencia en cuatro de sus ocho casos y peor en los otros cuatro, sin que ninguna diferencia sea significativa al 5 % según el test de Diebold-Mariano. Este test compara las pérdidas de ambos modelos, cada una calculada frente a la volatilidad realizada, de modo que contrasta si uno de los dos predice la volatilidad realizada mejor que el otro.

La intensidad del riesgo geopolítico mejora de forma significativa al modelo principal en un único caso, Bitcoin en el horizonte mensual, donde reduce la pérdida un 7,8 % respecto al HAR-RV. Este resultado mantiene su significación al ajustar por los doce contrastes, porque su valor p ajustado por Holm es inferior a 0,001. Los dos casos que quedan en el límite de la significación sin ajuste, el WTI y el bono del Tesoro mensuales, se alejan de ella tras el ajuste, con un valor p de 0,554. En diez de los doce casos, en cambio, la pérdida aumenta con F1, de modo que la intensidad empeora la predicción más a menudo de lo que la mejora. La composición por tipos de evento empeora a los seis modelos principales mensuales respecto a su versión con F1, con deterioros frente al HAR-RV de entre el 11 % y el 35 %. La figura 4.1 muestra cómo se reparte en el tiempo la diferencia de pérdidas entre F0 y F1 en los doce modelos principales, lo que permite distinguir las mejoras o los deterioros sostenidos de los que se concentran en episodios concretos. El MSE, que se emplea como pérdida complementaria, confirma en lo esencial estos resultados (tabla 4.1). Con esta pérdida, la intensidad reduce el error del modelo principal en Bitcoin y el WTI mensuales, como con la QLIKE, y también en el S&P 500 mensual, mientras que lo aumenta en los nueve casos restantes. En Bitcoin mensual, además, la ganancia es mayor, ya que pasa del 2,3 % al 14,3 % frente al HAR-RV. Las discrepancias entre ambas pérdidas se limitan a casos sin significación estadística. En el S&P 500 y el bono del Tesoro mensuales, F2 reduce el MSE respecto a F1, aunque ambos modelos siguen por debajo del HAR-RV y el test de Clark-West no es significativo. El MSE refuerza también la dificultad de superar al HAR-RV, porque el SVR con F0 predice peor que la referencia en siete de sus ocho casos y la diferencia es significativa en el bono del Tesoro mensual (p = 0,005).

La atribución SHAP anticipa una distinción que recorre todo el capítulo, la que separa la contribución de una variable de su capacidad predictiva. En los modelos principales con F1, la intensidad recibe entre el 13 % y el 44 % de la contribución, salvo en Elastic Net de Bitcoin semanal, que anula sus coeficientes. Ese reparto no guarda relación con los resultados de la tabla 4.1, porque el modelo en el que la intensidad tiene menos peso, el SVR de Bitcoin mensual (12,7 %), es el único que mejora con ella, mientras que el modelo en el que tiene más peso, el SVR del oro mensual (44,1 %), es el que más se deteriora. Con F2, la composición concentra más de la mitad de la contribución en el HAR-X de la energía, del oro y de Bitcoin, aunque no mejora la predicción en ningún modelo principal, como desarrollan las secciones 4.3.1 y 4.3.2.

4.2 Resultados por familia de activos

A continuación se presentan los resultados de cada familia en base a una misma estructura, que comienza por el resultado del modelo principal y continúa con los resultados parciales de los demás estimadores. Finalmente, cada apartado se cierra la descripción de la contribución con SHAP y con la importancia por permutación. Los resultados de todos los estimadores figuran en la tabla C.1, la pertenencia al conjunto de confianza de modelos en la tabla C.3 y la contribución de cada mes a la diferencia de pérdidas en la

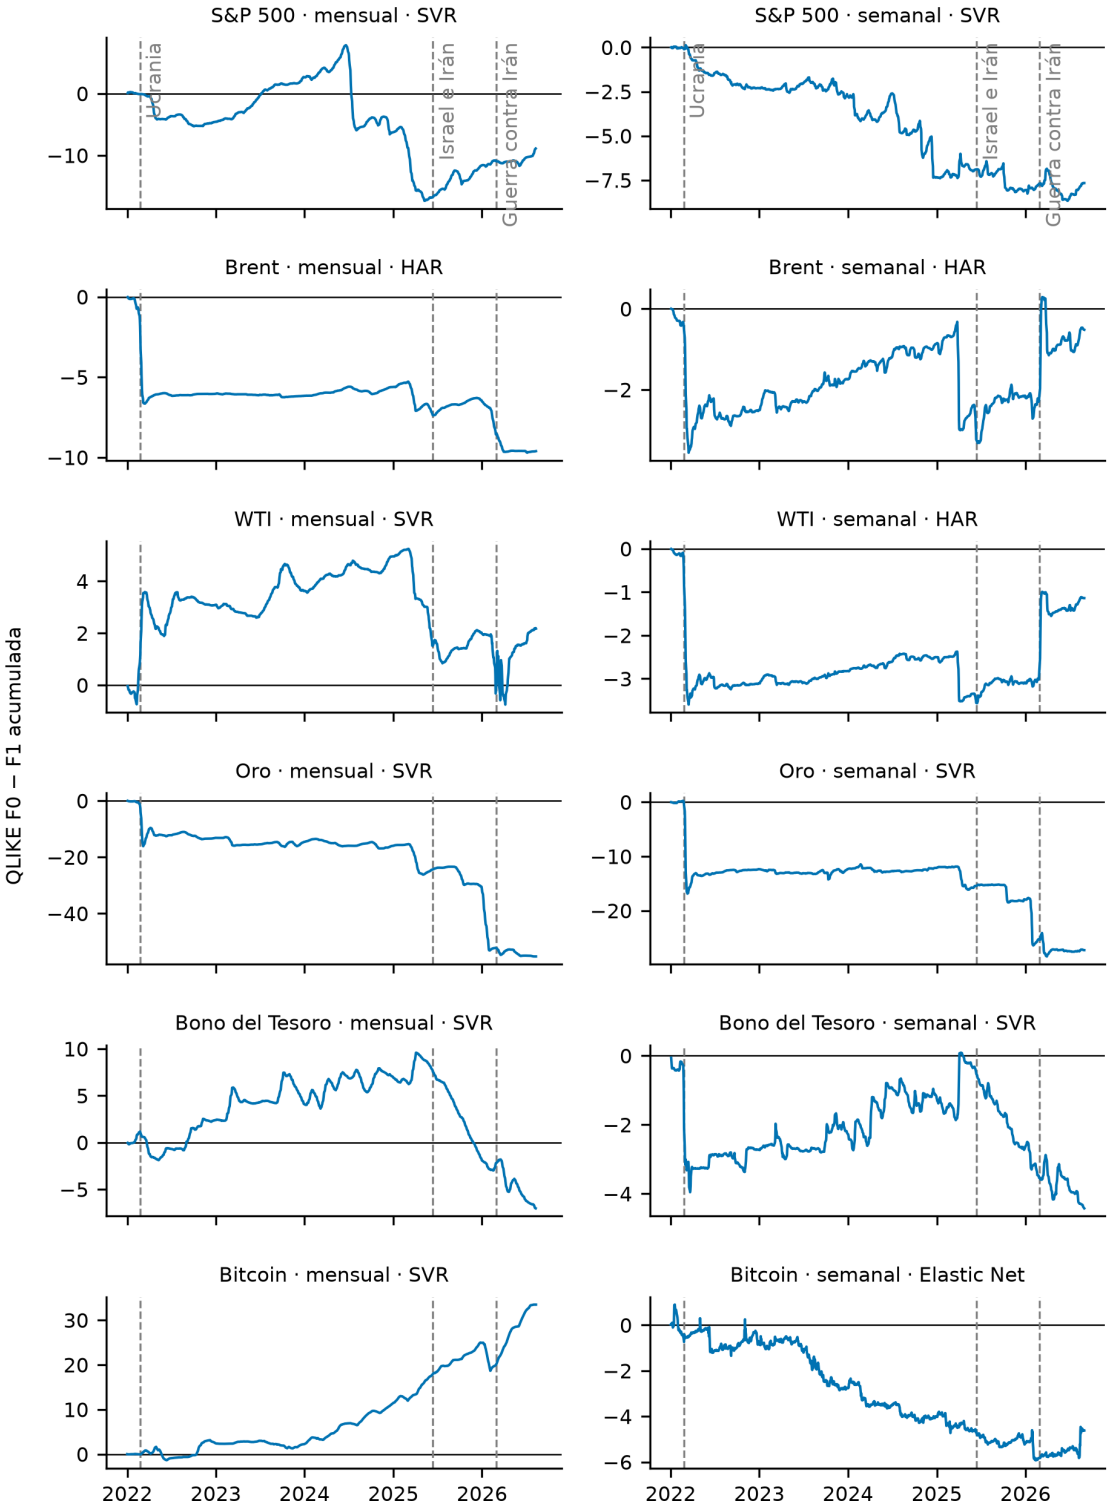


Figura 4.1: La línea sube cuando el modelo con F1 predice mejor. Las líneas verticales señalan la invasión de Ucrania, la guerra entre Israel e Irán y el inicio de la guerra contra Irán.

tabla D.2.

4.2.1 Renta variable

En el S&P 500, el modelo principal es el SVR en ambos horizontes. Con F0 predice ligeramente mejor que el HAR-RV, un 1,3 % en el horizonte mensual y un 2,7 % en el semanal, aunque sin diferencia significativa según el test de Diebold-Mariano (p = 0,739 y p = 0,066). La intensidad del riesgo geopolítico no mejora al modelo principal en ningún horizonte. Con F1, la pérdida aumenta frente a F0 tanto en el mensual (p = 0,230) como en el semanal (p = 0,779), y la composición la deteriora un 18,2 % frente al HAR-RV en el horizonte mensual. El conjunto de confianza de modelos incluye los doce modelos del caso mensual y los ocho del semanal, de modo que ninguno se distingue estadísticamente del mejor.

El deterioro de F1 en el horizonte mensual se concentra en pocos meses, ya que los tres peores, julio de 2024, marzo de 2025 y abril de 2022, suman una pérdida mayor que el deterioro total del periodo. Como cada mes corresponde a la fecha en que se formula la predicción, los dos primeros anticipan los repuntes de volatilidad de agosto de 2024 y abril de 2025, y en ambos casos el modelo con AI-GPR predijo menos volatilidad que el modelo sin él. El sesgo medio de la predicción pasa de una ligera sobrestimación con F0 (+0,047 en logaritmos) a una subestimación con F1 (−0,072), y la QLIKE penaliza especialmente quedarse corto en los episodios de volatilidad alta.

En el HAR-X, el SVR y XGBoost, la volatilidad pasada concentra entre el 49 % y el 62 % de la contribución SHAP y la composición, entre el 26 % y el 30 %. En Elastic Net, la volatilidad pasada alcanza el 89 %. Dentro de la composición, la amenaza nuclear figura entre los dos tipos de mayor contribución en el HAR-X, el SVR y XGBoost, aunque ningún tipo es dominante con los cuatro estimadores. Esa contribución no se traduce en capacidad predictiva, ya que al desordenar la composición por bloques de mes la pérdida disminuye en los cuatro estimadores.

4.2.2 Energía

En el horizonte mensual, el modelo principal del Brent es el HAR y el del WTI, el SVR. Ninguno de los dos cumple el criterio de mejora con la intensidad del riesgo geopolítico. En el Brent, la pérdida aumenta un 3,2 % con F1 frente a F0, y el deterioro se concentra en febrero y marzo de 2022, coincidiendo con la invasión de Ucrania. En el WTI, el SVR con F1 reduce ligeramente la pérdida respecto a F0, pero el test de Clark-West queda en el límite de la significación (p = 0,050), sin alcanzarla. La composición empeora la predicción en ambas series, con deterioros frente al HAR-RV del 11,4 % en el Brent y del 16,9 % en el WTI.

En el horizonte semanal, el modelo principal de ambas series es el HAR, y el AI-GPR tampoco lo mejora. Como resultado parcial, tres modelos no lineales que no son el principal sí obtienen mejoras significativas con F1 (tabla C.1). Son el SVR del Brent (p = 0,011) y el SVR (p = 0,014) y XGBoost (p < 0,001) del WTI. Estas mejoras son episódicas (figu-

ra 4.2). En XGBoost del WTI, los tres meses de mayor mejora suman más que la mejora total del periodo, de modo que fuera de ellos la ganancia neta es nula, mientras que en el SVR del Brent esos mismos meses concentran prácticamente toda la mejora. Se trata de febrero y marzo de 2022, con la invasión de Ucrania, y de marzo de 2026, con el inicio de la guerra de Estados Unidos e Israel contra Irán y la interrupción del tráfico de petroleros por el estrecho de Ormuz. Con el MSE, el SVR del Brent y el del WTI también mejoran con F1, pero XGBoost del WTI no lo hace, de modo que la más significativa de las tres mejoras depende de la pérdida elegida.

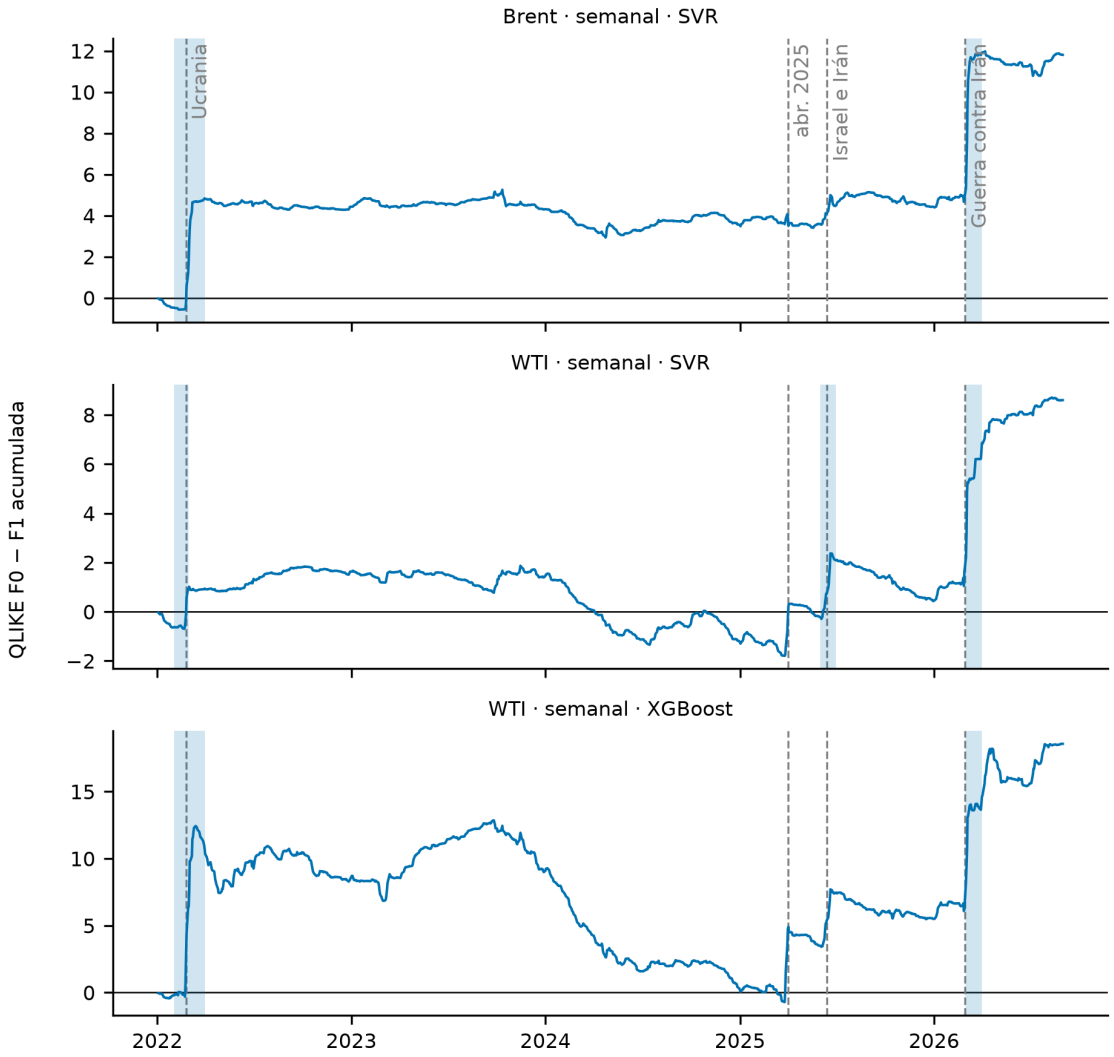


Figura 4.2: Esto con mejora significativa, que no son el modelo principal. La línea sube cuando el modelo con F1 predice mejor. El sombreado marca los tres meses de mayor mejora de cada modelo.

En esta muestra, por tanto, las mejoras de la energía en el horizonte semanal aparecen solo en especificaciones no lineales secundarias y se concentran en episodios de tensión con efectos sobre la oferta. El diseño no permite atribuir esa diferencia a la no linealidad,

porque los estimadores difieren también en sus hiperparámetros y en su forma de usar la volatilidad pasada. Los mismos meses de 2022 en que estos modelos semanales mejoran con el AI-GPR son, además, aquellos en que el HAR mensual del Brent más empeora.

El conjunto de confianza de modelos es coherente con esta lectura, porque en el Brent semanal quedan fuera el HAR-RV y Elastic Net con F0, mientras que sus versiones con F1 permanecen. Del mismo modo, en el WTI semanal se excluye XGBoost con F0 y se mantiene su versión con F1, mientras que en el WTI mensual se excluyen los modelos lineales con F2.

En el HAR-X, la composición concentra el 66,5 % de la contribución SHAP en el Brent y el 70,1 % en el WTI, con el conflicto militar como tipo de mayor contribución en ambas series. En Elastic Net, el peso de la composición es mucho menor en el Brent, donde domina la guerra civil. Esa contribución no se traduce en capacidad predictiva, porque al desordenar la composición por bloques de mes la pérdida disminuye en los modelos lineales y en el SVR de ambas series. Solo en XGBoost la permutación de la composición empeora la predicción, lo que sugiere que ese modelo extrae alguna información de ella.

Las dos series de energía coinciden en lo esencial, ya que ninguna mejora en el modelo principal y ambas muestran mejoras episódicas en modelos no lineales semanales. Difieren en el detalle, como el resultado del SVR mensual del WTI o el peso de la composición en Elastic Net. La sesión siguiente a cada vencimiento, en la que la serie continua cambia de contrato, presenta además una volatilidad significativamente mayor que el resto (sección 3.3). Como esa diferencia puede ampliarse en los episodios de tensión, en los que se concentran las mejoras de los modelos semanales, no puede descartarse que parte de esas mejoras recoja la volatilidad asociada al cambio de contrato y no solo la información geopolítica.

4.2.3 Metales preciosos

El oro es la serie en la que el riesgo geopolítico más deteriora la predicción. Con el SVR como modelo principal en ambos horizontes, la pérdida mensual aumenta un 20,1 % frente al HAR-RV al incorporar la intensidad y un 35,2 % al añadir la composición, mientras que en el semanal la intensidad la empeora un 5,3 %. Ningún contraste de Clark-West es significativo. En el periodo de entrenamiento, en cambio, el SVR con F1 predecía mejor que con F0 en ambos horizontes, con una pérdida de validación de 0,2148 frente a 0,2256 en el mensual.

El deterioro se concentra en pocos episodios (figura 4.3), ya que los tres meses de mayor pérdida, enero de 2026, abril de 2025 y febrero de 2022, explican el 62 % de la diferencia acumulada entre F1 y F0. Solo enero de 2026 explica el 40 %, y en el resto del periodo la diferencia apenas varía. Esa concentración es compatible con que el conjunto de confianza de modelos no excluya ninguna especificación, ya que con pérdidas tan concentradas las diferencias medias no son estadísticamente distinguibles.

En los modelos con F2, la composición concentra el 57,8 % de la contribución SHAP en el HAR-X y el 45,7 % en el SVR, con el conflicto militar como tipo de mayor contribución en

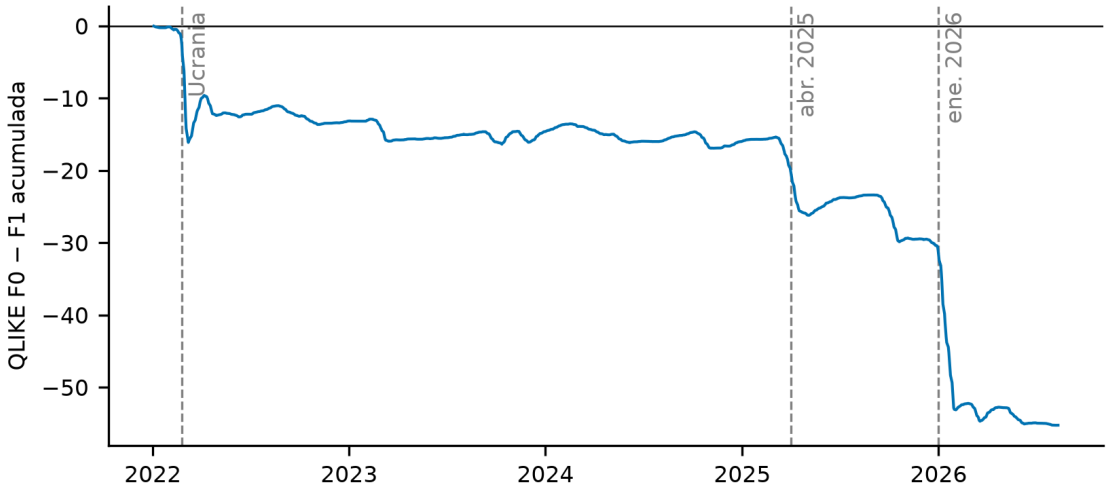


Figura 4.3: La línea sube cuando el modelo con F1 predice mejor y baja cuando predice peor. Las líneas verticales señalan los tres meses de mayor pérdida.

ambos. En el SVR con F1, la intensidad alcanza el 44,1 % de la contribución, la proporción más alta de los modelos principales.

El deterioro coincide con una subestimación de la volatilidad en los episodios de tensión. Todos los modelos reaccionan con retraso a los repuntes de volatilidad del oro de 2025 y 2026, pero los que incorporan el AI-GPR predicen todavía menos. El sesgo medio de la predicción pasa de −0,112 en logaritmos con F0 a −0,235 con F1 y a −0,271 con F2. En el SVR, los valores SHAP de la intensidad, del conflicto militar y de las sanciones son negativos cuando esas variables toman valores altos (figura 4.4).

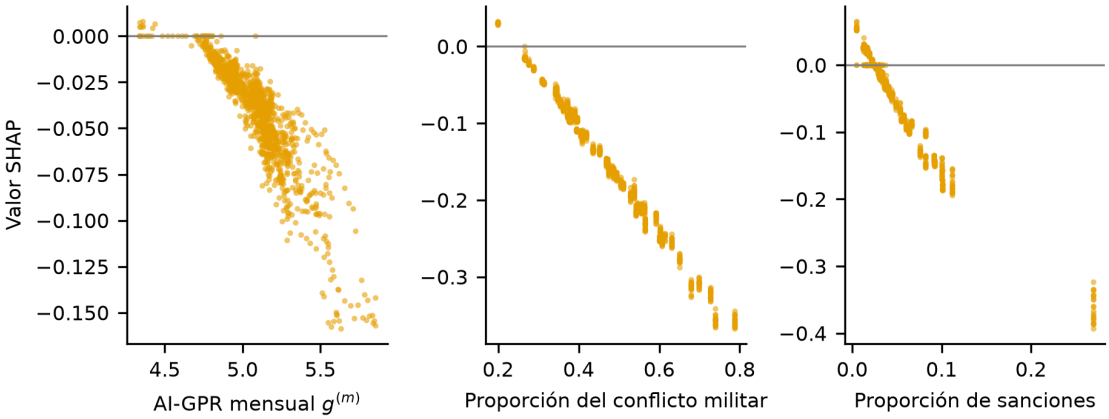


Figura 4.4: Un valor SHAP negativo indica que la variable reduce la volatilidad predicha.

Estos resultados son compatibles con que el modelo haya aprendido en el entrenamiento una asociación negativa entre riesgo geopolítico y volatilidad del oro y la haya aplicado en un periodo de riesgo elevado. En febrero de 2022, por ejemplo, el modelo

con AI-GPR predijo menos volatilidad del oro que el modelo sin él.

La importancia por permutación apunta en la misma dirección, ya que al desordenar por bloques de mes tanto la intensidad como la composición la pérdida disminuye en los cuatro estimadores. El oro es la única serie en la que la intensidad muestra este comportamiento de forma generalizada. Como hallazgo de robustez, cuando los modelos se entrenan solo con datos desde 2014, la intensidad mejora de forma significativa la predicción del oro en el horizonte semanal (p < 0,001, sección 4.4). Este hallazgo es compatible con que la relación estimada con los años anteriores a 2014 no se mantenga en el periodo reciente. La prueba cambia también el tamaño de la muestra y conserva los hiperparámetros ajustados con la muestra completa, por lo que no permite aislar esa explicación.

4.2.4 Deuda soberana

En el bono del Tesoro a diez años, el modelo principal es el SVR en ambos horizontes, aunque con F0 predice peor que el HAR-RV. La diferencia es del 5,0 % en el horizonte mensual, en el límite de la significación según el test de Diebold-Mariano (p = 0,056), y del 0,4 % en el semanal. En el semanal, además, la elección del SVR frente a XGBoost se decide por un margen estrecho en la validación cruzada (sección 4.6.3).

La intensidad del riesgo geopolítico no mejora al modelo principal, aunque en el caso mensual el test de Clark-West de F1 frente a F0 queda en el límite de la significación (p = 0,053) mientras la pérdida QLIKE aumenta un 5,5 %. La divergencia se explica en parte porque el test de Clark-West se construye sobre el error cuadrático y corrige la desventaja del modelo ampliado por estimar parámetros adicionales, mientras que la QLIKE pondera más la subestimación. Como el criterio exige a la vez la significación y la reducción de la QLIKE, la mejora no se acepta en este caso. El conjunto de confianza de modelos excluye en el caso mensual el SVR y XGBoost con F1 y el SVR con F2, de modo que las versiones no lineales con información geopolítica predicen significativamente peor que las mejores.

El bono del Tesoro es la única serie en que el AI-GPR desplaza las predicciones al alza. El sesgo medio pasa de una subestimación con F0 (−0,090 en logaritmos) a una sobrestimación con F1 (+0,068). A diferencia del oro y de la renta variable, el deterioro no depende de un único episodio. Los tres meses de mayor pérdida, marzo de 2022, agosto de 2024 y diciembre de 2025, tienen una magnitud similar y pertenecen a años distintos (tabla D.2).

En el SVR, la composición concentra el 44,8 % de la contribución SHAP, con el conflicto militar y las sanciones como tipos principales. El bono del Tesoro es además la única serie en que la importancia por permutación de la composición es positiva en los cuatro estimadores. Dentro de los modelos con F2, por tanto, la composición aporta información respecto a una versión desordenada de sí misma, aunque esa información no basta para que el modelo con F2 supere al modelo con F1 (p = 0,081).

Es también la serie más sensible a la especificación del modelo y de la muestra, como muestran dos hallazgos de robustez. La intensidad mejora de forma significativa la

predicción mensual cuando se agrupa por mes de calendario (p = 0,011) y la de ambos horizontes cuando los modelos se entrenan con la muestra desde 2014 (p < 0,001). Estos hallazgos sugieren una relación entre el riesgo geopolítico y la volatilidad del rendimiento del bono que la especificación principal no recoge, aunque proceden de especificaciones alternativas y no permiten aceptar la hipótesis en este caso.

4.2.5 Criptoactivos

Bitcoin es la única serie en que la intensidad del riesgo geopolítico mejora al modelo principal. En el horizonte mensual, el SVR con F1 reduce la pérdida QLIKE de 0,258 a 0,238, una mejora del 7,8 % frente al HAR-RV, con un estadístico de Clark-West de 4,62 (p < 0,001). Como resultado parcial, el HAR-X también mejora con F1 (p = 0,001), aunque menos (4,5 %). El conjunto de confianza de modelos es coherente con este resultado, porque al 10 % solo pertenecen al conjunto el HAR-X y el SVR con F1, y quedan excluidos todos los modelos sin información geopolítica. La composición, en cambio, deteriora la predicción un 17,1 % frente al HAR-RV.

En el horizonte semanal, el modelo principal, Elastic Net, no mejora con el AI-GPR (p = 0,617). Con el MSE, sin embargo, Elastic Net con F0 predice significativamente mejor que el HAR-RV (p < 0,001), algo que no ocurre con la QLIKE (p = 0,161). Como resultado parcial, el HAR-X sí lo hace de forma marginal (p = 0,048), y el conjunto de confianza excluye el HAR-RV y mantiene su versión con F1.

La mejora del horizonte mensual es sostenida (figura 4.5), ya que la diferencia acumulada entre F0 y F1 apenas varía en 2022 y 2023 y crece de forma continuada desde 2024. Los tres meses de mayor mejora explican solo un tercio de la ganancia total, de modo que el resultado no depende de un episodio aislado, y sus retrocesos más importantes corresponden a enero de 2026 y a mayo de 2022.

La mejora coincide con una reducción de la sobrestimación sistemática. Los modelos de Bitcoin predicen casi siempre más volatilidad de la que se realiza, y con el AI-GPR la sobrestimación media pasa de +0,348 en logaritmos con F0 a +0,298 con F1, mientras que con F2 aumenta hasta +0,509. En Bitcoin, además, desordenar la volatilidad pasada apenas empeora la predicción, a diferencia del resto de series, en las que es con diferencia la información más importante. Una lectura plausible es que, en el periodo de prueba, la volatilidad pasada de Bitcoin sea poco informativa sobre la futura y deje margen a otras variables.

La atribución SHAP indica que la mejora no se apoya en un peso elevado del riesgo geopolítico, ya que en el SVR con F1 la intensidad recibe el 12,7 % de la contribución, la proporción más baja entre los modelos principales que la emplean, frente al 87,3 % de la volatilidad pasada. Con F2, la composición concentra el 58,1 % de la contribución en el HAR-X, el 51,2 % en el SVR y el 31,1 % en XGBoost, mientras que Elastic Net anula todos los coeficientes geopolíticos. El tipo de evento con mayor contribución cambia con el estimador, ya que es el conflicto militar en el HAR-X, la guerra civil en el SVR y la tensión diplomática en XGBoost. Al desordenar la composición, la pérdida apenas aumenta en

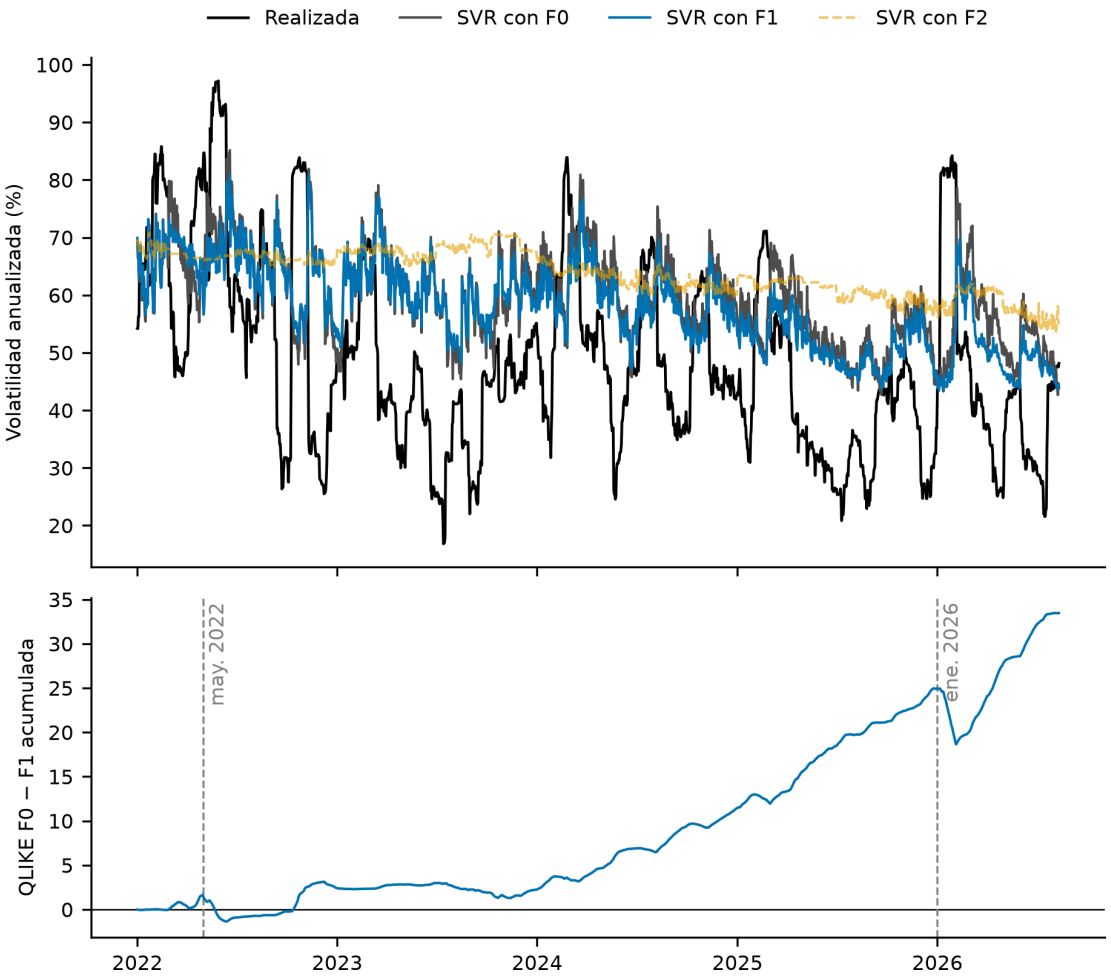


Figura 4.5: Arriba, volatilidad realizada y predicciones con F0, F1 y F2. Abajo, diferencia acumulada de la pérdida QLIKE entre F0 y F1, que sube cuando el modelo con F1 predice mejor. Las líneas verticales señalan los dos mayores retrocesos.

el HAR-X y el SVR, con valores inferiores a 0,004, y disminuye en XGBoost (tabla D.1).

La primera de las tres cautelas que acotan este resultado se refiere a su robustez, ya que la mejora se mantiene con la serie alineada al calendario hábil y con ambos valores mínimos alternativos, pero no al agregar la información a una observación mensual (sección 4.4). Además, el SVR con F0 y el SVR con F1 tienen hiperparámetros distintos, con un peso C que pasa de 2,74 a 0,047, y la corrección logarítmica normal depende de la varianza del error de cada modelo. Dos comprobaciones descartan que la mejora proceda de esas diferencias, empezando por la corrección. Con una misma corrección para ambos modelos, ya sea la de F0, la de F1 o ninguna, el modelo con F1 mantiene una QLIKE menor, con reducciones de entre el 5,9 % y el 7,1 % respecto a F0. El test de Clark-West, además, no depende de la corrección, porque se calcula sobre el error en logaritmos. Al estimar el SVR con F1 con los hiperparámetros de F0, la QLIKE pasa de 0,258 a 0,239 y el test sigue siendo significativo (t = 3,92, p < 0,001), de modo que la mejora procede de la información añadida y no del cambio de hiperparámetros. Por último, el diseño no permite distinguir si el AI-GPR aporta información específicamente geopolítica o si actúa como indicador de otros factores. En el periodo de prueba coinciden un riesgo geopolítico elevado y una volatilidad de Bitcoin menor que la de sus primeros años, con una volatilidad anualizada media que cae del 76,0 % en 2014 a 2021 al 50,8 % en 2022 a 2026. Sin controles de incertidumbre general, como el VIX o el EPU, no puede descartarse que parte de la mejora refleje esa coincidencia. El resultado es compatible con la evidencia de Kamal y Wahlstrøm (2023) sobre la sensibilidad de las criptomonedas al riesgo geopolítico, pero no la confirma por sí solo.

4.3 Análisis comparativo entre familias de activos

4.3.1 La intensidad del riesgo geopolítico

Como resultado principal, la intensidad del riesgo geopolítico mejora la predicción en una sola familia, los criptoactivos, en el horizonte mensual. En ese caso la mejora alcanza al modelo principal, es sostenida en el tiempo y el conjunto de confianza de modelos es coherente con ella. Como resultado parcial, la energía muestra mejoras en el horizonte semanal que se limitan a modelos no lineales secundarios y se concentran en episodios de tensión. En la renta variable, los metales preciosos y la deuda soberana, la intensidad no mejora la predicción del modelo principal, y en el oro la deteriora de forma marcada.

El efecto de incorporar el AI-GPR depende de la serie incluso en su dirección (tabla 4.2). Desplaza a la baja las predicciones de la renta variable y del oro, al alza las del bono del Tesoro y apenas modifica las de la energía. Solo en Bitcoin el desplazamiento reduce el sesgo del modelo sin información geopolítica. Como la QLIKE penaliza más quedarse corto que pasarse, el desplazamiento a la baja en series cuya volatilidad repuntó en el periodo de prueba es compatible con buena parte del deterioro observado.

En cuanto al tipo de modelo, la evidencia es limitada. En Bitcoin mensual, la ganancia del SVR con F1 es mayor que la del HAR-X con F1, de 7,7 frente a 4,5 puntos porcen-

Tabla 4.2: Un valor positivo indica sobrestimación

	S&P 500	Brent	WTI	Oro	Bono del Tesoro	Bitcoin
F0	+0,047	−0,066	−0,089	−0,112	−0,090	+0,348
F1	−0,072	−0,083	−0,093	−0,235	+0,068	+0,298
F2	−0,073	−0,003	−0,070	−0,271	+0,034	+0,509

tuales respecto a su versión con F0. Sin embargo, el test de Diebold-Mariano no permite afirmar que el SVR con F1 prediga mejor que el HAR-X con F1 (t = 1,49, p = 0,068), de modo que la diferencia entre ambas ganancias no es estadísticamente significativa al 5 %. En la energía semanal, las mejoras significativas aparecen solo en el SVR y en XGBoost, pero en Bitcoin semanal la única mejora significativa corresponde al HAR-X, que es lineal. Con esta evidencia no puede afirmarse que los modelos no lineales aprovechen en general mejor la información geopolítica.

La atribución SHAP de los modelos con F1 confirma que la mejora no depende del peso que el modelo asigna a la intensidad (figura 4.6). La volatilidad pasada concentra la mayor parte de la contribución en los 17 modelos analizados, y la intensidad no supera en ninguno el 45 %. En los seis modelos con mejora significativa, que son el SVR de Bitcoin mensual y los cinco secundarios, la intensidad recibe entre el 12,7 % y el 33,2 % de la contribución. Ese intervalo queda dentro del de los modelos principales que no mejoran, en los que oscila entre el 17,2 % y el 44,1 %. La proporción más alta corresponde al SVR del oro mensual, que es además el que más se deteriora. En el SVR de Bitcoin mensual, el componente mensual concentra el 53,5 % de la contribución de la intensidad, frente al 29,4 % del semanal y el 17,1 % del diario. Los tres componentes guardan una relación creciente con la volatilidad predicha, con correlaciones de Spearman entre su valor y su valor SHAP de 0,37 en el diario, 0,57 en el semanal y 0,68 en el mensual. El modelo aprovecha, por tanto, principalmente el nivel medio del riesgo geopolítico en el último mes y no sus variaciones diarias.

4.3.2 La composición por tipos de evento

Como resultado principal, la composición por tipos de evento no mejora a la intensidad en ningún modelo principal. Como resultado parcial, tres modelos secundarios cumplen formalmente el criterio, XGBoost en el Brent, el WTI y el bono del Tesoro mensuales, aunque ninguno supera al HAR-RV (sección 4.5). Tampoco lo hace en ninguna de las pruebas de robustez, en las que el criterio de F2 frente a F1 no se cumple en ningún caso mensual.

Los modelos asignan, sin embargo, una contribución considerable a la composición (figura 4.7). En el HAR-X de la energía, del oro y de Bitcoin, la composición concentra entre el 58 % y el 70 % de la contribución, y en el SVR, entre el 27 % y el 51 %. Los modelos usan la composición, pero usarla no mejora la predicción, que es la distinción entre contribución y capacidad predictiva planteada en la sección 1.4. La importancia por

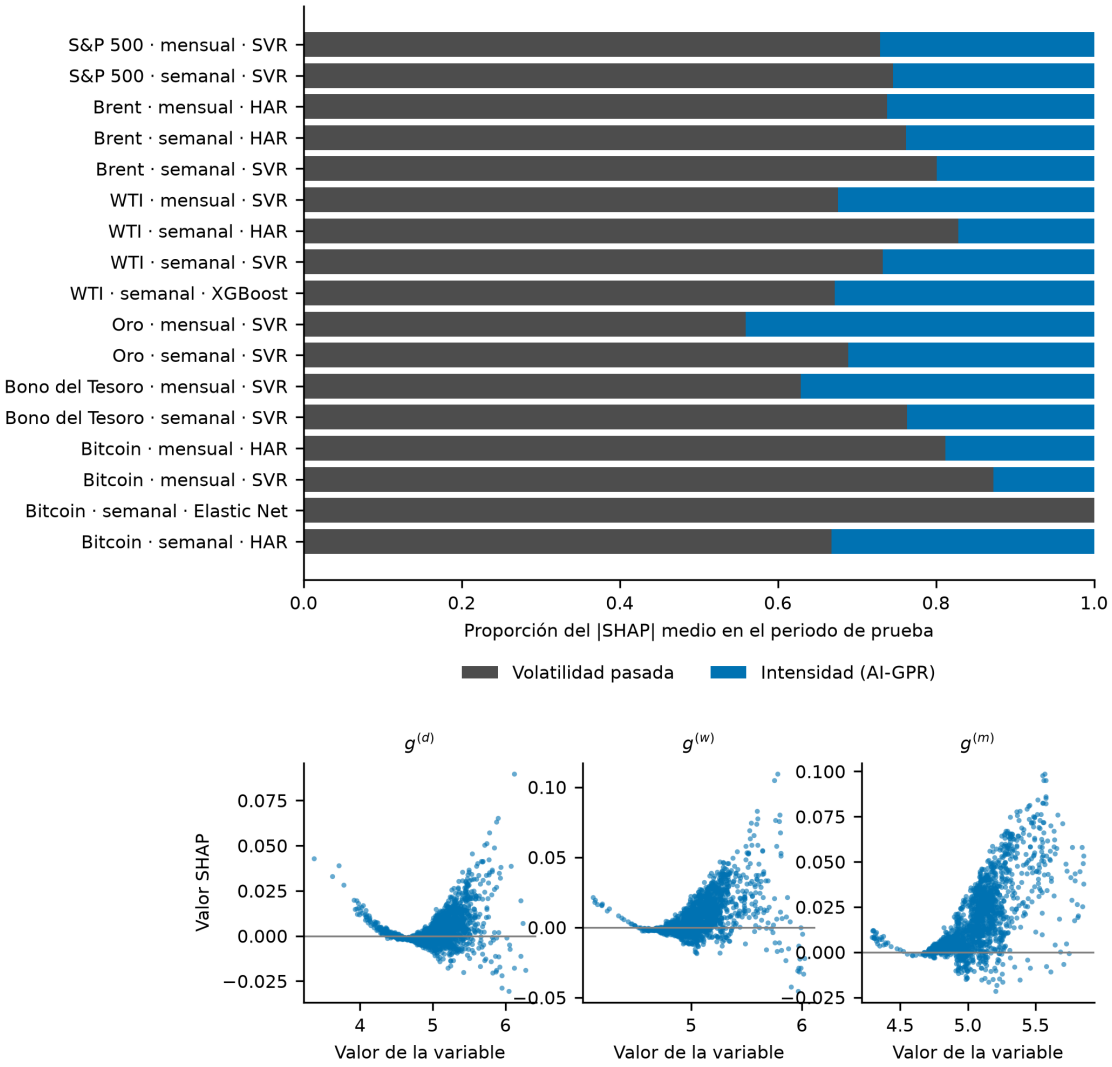


Figura 4.6: Arriba, proporción de la contribución por bloque. Abajo, dependencia de los valores SHAP respecto a los componentes de la intensidad en el SVR de Bitcoin mensual.

permutación apunta en la misma dirección, porque al desordenar la composición por bloques de mes la pérdida disminuye en 15 de los 24 modelos (tabla D.1). La composición aporta información respecto a una versión desordenada de sí misma en los cuatro estimadores del bono del Tesoro y en XGBoost de las dos series de energía. También lo hace en el HAR-X y el SVR de Bitcoin, aunque con aumentos de la pérdida inferiores a 0,004.

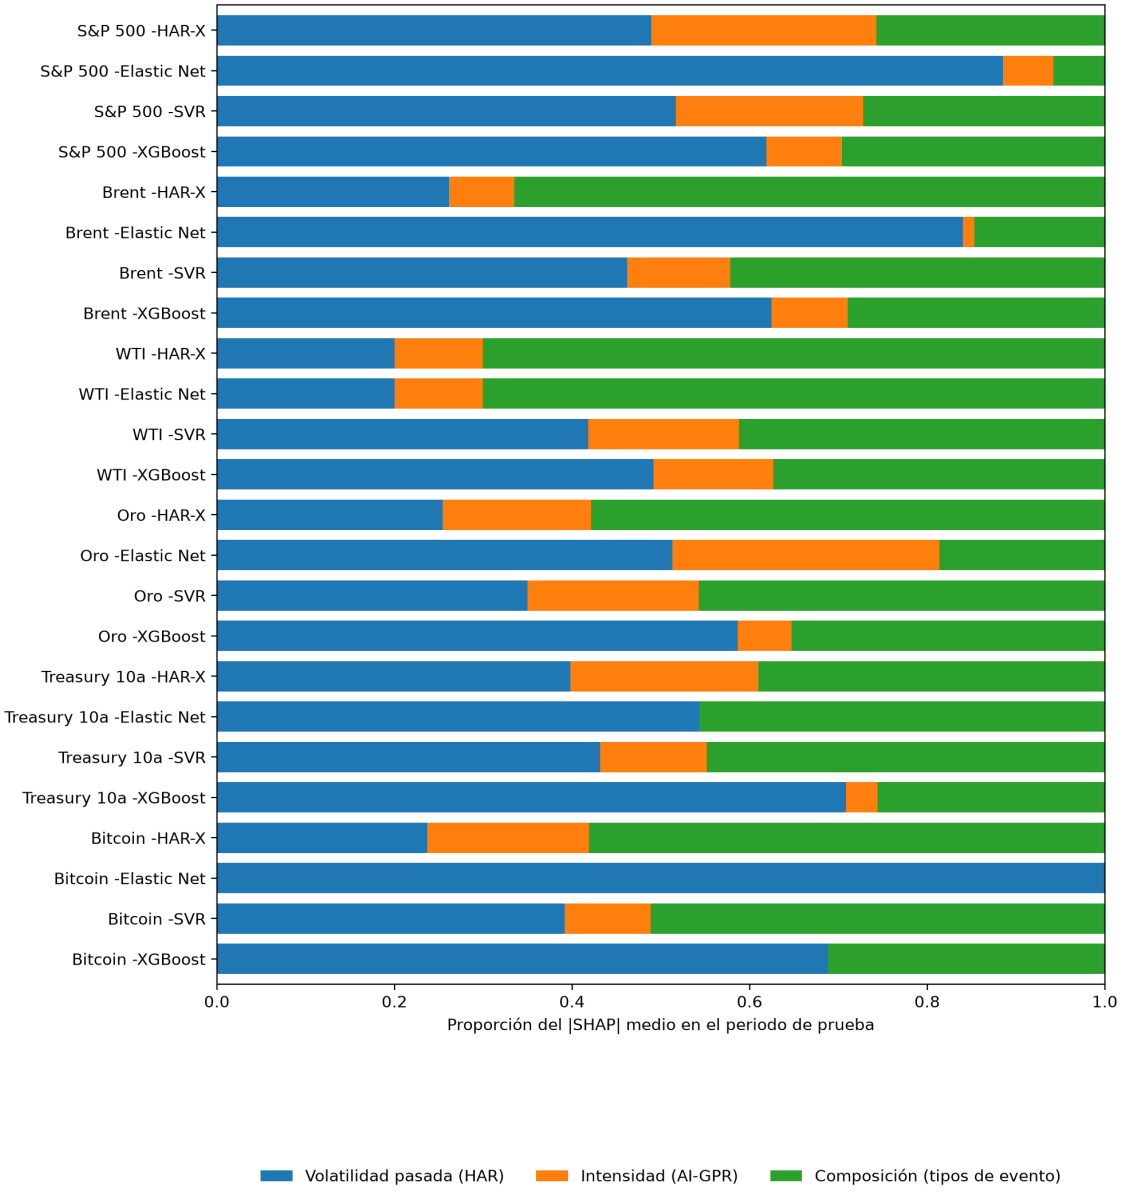


Figura 4.7: Proporción de la contribución SHAP por bloque de variables, por serie y estimador (horizonte mensual, conjunto F2).

Una explicación plausible, no contrastada en este trabajo, es el cambio de composición entre el entrenamiento y la prueba (tabla 2.6). El peso del conflicto militar se duplica y

el del terrorismo cae a un tercio, de modo que los modelos aplican relaciones estimadas con proporciones notablemente distintas de las que encuentran fuera de muestra.

En cuanto a los tipos de evento (figura 4.8), el conflicto militar es el de mayor contribución en los seis modelos HAR-X, aunque en el S&P 500 su ventaja sobre la amenaza nuclear es mínima (0,26 frente a 0,25). En los demás estimadores, el tipo dominante cambia con la serie, como muestra el SVR, en el que la guerra civil domina en el Brent y en Bitcoin, el conflicto militar en el oro y en el bono del Tesoro, y la amenaza nuclear y las sanciones empatan en el S&P 500. En XGBoost dominan las sanciones en el S&P 500 y en el bono del Tesoro, el terrorismo en la energía, la guerra civil en el oro y la tensión diplomática en Bitcoin. Con el criterio fijado en la metodología, ningún tipo de evento es dominante con los cuatro estimadores en ninguna serie.

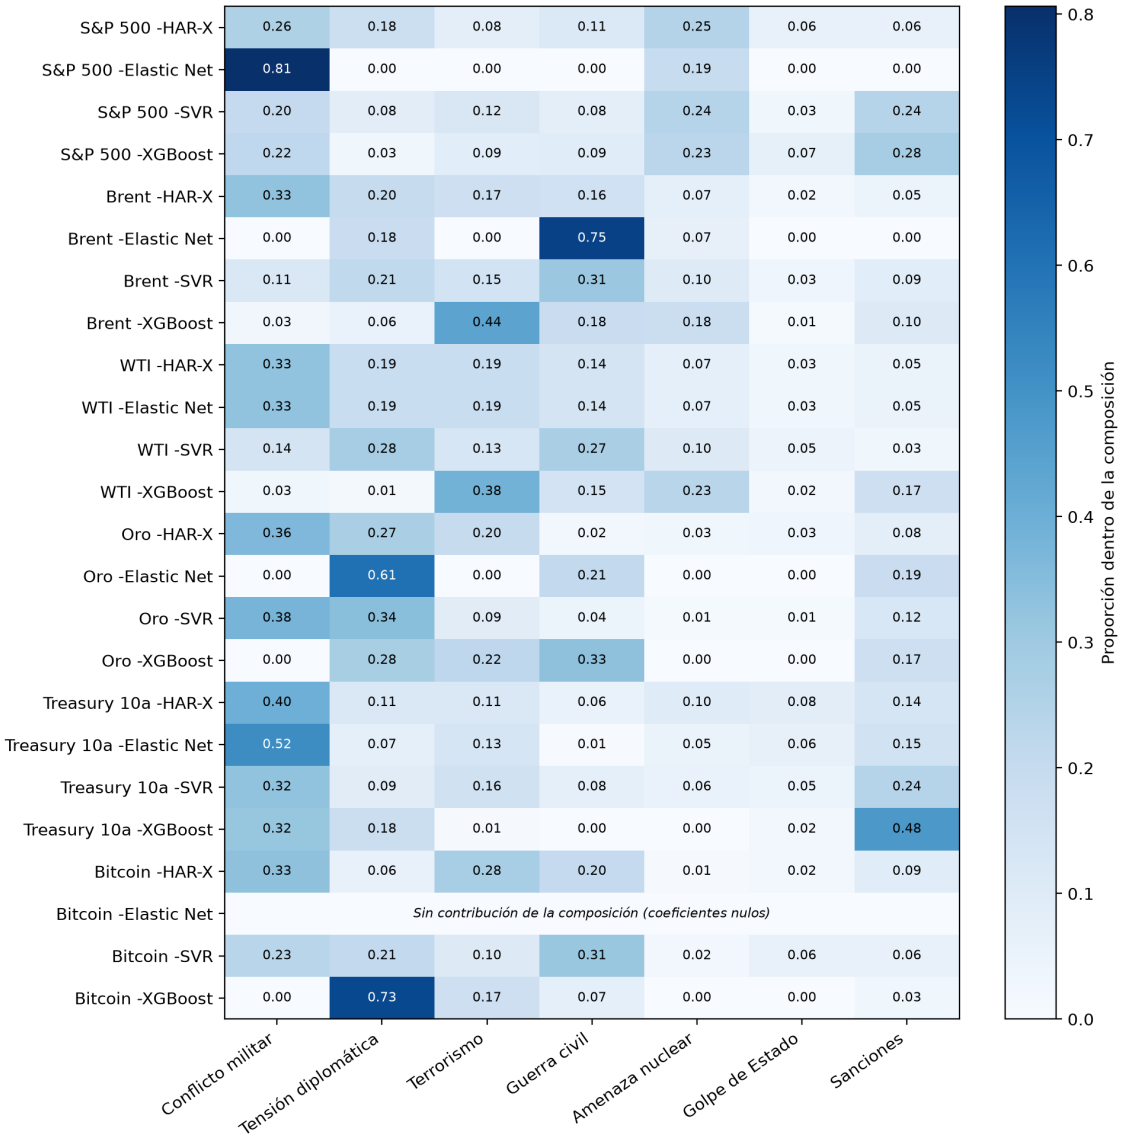


Figura 4.8: Contribución SHAP de cada tipo de evento dentro de la composición, por serie y estimador (horizonte mensual, conjunto F2).

4.3.3 Análisis exploratorio de la persistencia

El análisis exploratorio compara la contribución SHAP de los tipos de evento de persistencia esperada alta (conflicto militar y sanciones) con la de los de persistencia baja (terrorismo y golpe de Estado). La comparación se presenta con los cuatro estimadores y sin criterio de aceptación (tabla 4.3).

Con la contribución SHAP media, los tipos persistentes superan a los transitorios en todas las series con el HAR-X. El resultado depende, sin embargo, del estimador. En el SVR, los persistentes superan a los transitorios en todas las series salvo el WTI, donde ambos grupos casi empatan. En XGBoost solo lo hacen en el S&P 500 y en el bono del

Tabla 4.3: Horizonte mensual, conjunto F2.

Serie	HAR-X	Elastic Net	SVR	XGBoost
S&P 500	0,32 / 0,14	0,81 / 0,00	0,44 / 0,15	0,50 / 0,16
Brent	0,38 / 0,19	0,00 / 0,00	0,20 / 0,18	0,13 / 0,45
WTI	0,38 / 0,22	0,38 / 0,22	0,17 / 0,18	0,20 / 0,40
Oro	0,44 / 0,23	0,19 / 0,00	0,50 / 0,10	0,17 / 0,22
Bono del Tesoro	0,54 / 0,19	0,67 / 0,19	0,56 / 0,21	0,80 / 0,03
Bitcoin	0,42 / 0,30	—	0,29 / 0,16	0,03 / 0,17

Cada celda muestra la proporción de la contribución de la composición atribuida a los tipos persistentes y a los transitorios, calculada a partir de la figura 4.8. En Elastic Net de Bitcoin, los coeficientes de la composición son nulos.

Tesoro, mientras que en la energía, el oro y Bitcoin la comparación se invierte. Como los cuatro estimadores no coinciden, la mayor contribución de los tipos persistentes no es robusta a la forma funcional del modelo.

Con la contribución por unidad de variación, calculada con la normalización de la sección 2.7, el resultado cambia (tabla 4.4). Los tipos transitorios superan a los persistentes en todas las series con el HAR-X y en la energía y Bitcoin con todos los estimadores. En el S&P 500, el oro y el bono del Tesoro, en cambio, los persistentes superan a los transitorios con Elastic Net, el SVR y XGBoost, pero no con el HAR-X. Los coeficientes estandarizados del HAR-X ofrecen una tercera lectura, porque con ellos los persistentes superan a los transitorios en todas las series salvo Bitcoin, aunque con diferencias pequeñas en el S&P 500 y el WTI.

Las tres medidas no coinciden porque responden a preguntas distintas. La contribución media refleja también cuánto se aleja cada proporción de su media de entrenamiento, la normalizada mide el efecto por unidad de proporción y el coeficiente estandarizado mide el efecto de una variación típica en el entrenamiento. En el HAR-X, por ejemplo, el golpe de Estado tiene una proporción cercana al 1 % y una dispersión reducida, por lo que su efecto por unidad de proporción es elevado y pesa en el grupo de los transitorios, mientras que su coeficiente estandarizado es pequeño.

El análisis es, por tanto, no concluyente y presenta además dos limitaciones de fondo, ya que la persistencia es una clasificación previa basada en la literatura y no una magnitud estimada. Por otra parte, la composición solo se evalúa en el horizonte mensual, de modo que no puede observarse si la contribución de cada tipo cambia con el horizonte, que sería la consecuencia esperable de su persistencia.

4.4 Pruebas de robustez

Las pruebas de robustez se aplican al modelo principal de cada caso, con los hiperparámetros ajustados en la especificación principal. La tabla 4.5 recoge los casos en que la intensidad del riesgo geopolítico mejora la predicción de forma significativa en cada prueba. Como las pruebas suman varias decenas de contrastes adicionales, al 5 % cabe esperar algunos resultados significativos por azar. Por ello, los hallazgos con p < 0,001

Tabla 4.4: Horizonte mensual, conjunto F2.

	Contribución por unidad de variación				Coeficientes
Serie	HAR-X	Elastic Net	SVR	XGBoost	HAR-X
S&P 500	0,55 / 1,00	0,08 / 0,00	1,44 / 0,65	1,62 / 1,05	0,043 / 0,039
Brent	2,49 / 2,88	—	0,83 / 1,15	0,43 / 0,83	0,220 / 0,183
WTI	3,39 / 4,89	3,39 / 4,88	0,45 / 1,40	0,88 / 1,06	0,295 / 0,286
Oro	2,34 / 2,67	0,47 / 0,00	1,72 / 0,58	0,70 / 0,37	0,187 / 0,156
Bono del Tesoro	1,49 / 1,88	1,45 / 1,29	2,04 / 1,31	1,44 / 0,14	0,106 / 0,076
Bitcoin	2,76 / 3,80	—	0,11 / 0,24	0,05 / 0,15	0,197 / 0,271

Cada celda muestra el valor de los tipos persistentes y el de los transitorios. La contribución por unidad de variación es la suma, en cada grupo, de la contribución SHAP media de cada tipo dividida entre la distancia cuadrática media de su proporción en la prueba respecto a la media del entrenamiento. Los coeficientes son los valores absolutos de los coeficientes del HAR-X multiplicados por la desviación típica de cada proporción en el entrenamiento, sumados en cada grupo. En Elastic Net del Brent y de Bitcoin, los coeficientes de los cuatro tipos son nulos.

son los más difíciles de atribuir al azar, y el resto se lee con cautela.

Tabla 4.5: Mejoras significativas de F1 frente a F0 en las pruebas de robustez.

Prueba	Casos con mejora significativa (p de Clark-West)
Especificación principal	Bitcoin mensual (<0,001)
Agrupación por semana y mes de calendario	Bono del Tesoro mensual (0,011)
Agregación a frecuencia mensual	Ninguno
Series reestimadas desde 2014	S&P 500 semanal (0,007), oro semanal (<0,001) y bono del Tesoro mensual y semanal (<0,001)
Bitcoin alineado al calendario hábil	Bitcoin mensual (<0,001)
WTI con la variación del 22 de abril de 2020 corregida	WTI mensual (0,043)
Valor mínimo en el percentil 0,5	Bitcoin mensual (<0,001)
Valor mínimo en el percentil 5	Bitcoin mensual (<0,001) y WTI mensual (0,0496)

El resultado de Bitcoin se mantiene con la serie alineada al calendario hábil y con los dos valores mínimos alternativos. No se mantiene, en cambio, cuando la información se agrega a una observación por mes, ya sea por agrupación de calendario o a frecuencia mensual. En ambas pruebas, el modelo de Bitcoin se estima con una observación por mes y con hiperparámetros ajustados para la frecuencia diaria. En la prueba de frecuencia mensual, además, se entrena con 82 meses, frente a los 264 de las series tradicionales, porque su muestra comienza en 2014. Estas pruebas evalúan, por tanto, un modelo con una fracción de la información disponible, y la mejora de Bitcoin solo se observa con información diaria.

La prueba con las series reestimadas desde 2014 añade cuatro mejoras en el S&P 500 y el oro semanales y en el bono del Tesoro en ambos horizontes. Este hallazgo es com-

patible con un cambio en la relación entre el riesgo geopolítico y la volatilidad, en el que la relación estimada con los datos de 1999 a 2013 deterioraría la predicción del periodo de prueba. La prueba modifica a la vez el periodo y el tamaño de la muestra y mantiene los hiperparámetros de la especificación principal, por lo que no permite contrastar esa interpretación.

En el WTI mensual, la mejora pasa a ser significativa al corregir la variación del 22 de abril de 2020 (p = 0,043) y con el valor mínimo en el percentil 5 (p = 0,0496). Ambos valores están cerca del umbral y no sobrevivirían a un ajuste por comparaciones múltiples. Las importancias por permutación de cada tipo de evento por separado no se interpretan, porque al desordenar una única proporción se generan combinaciones incompatibles con las demás.

4.5 Resolución de las hipótesis

Cada hipótesis se resuelve con el modelo principal de cada caso y con los criterios de la sección 2.6.3, y la tabla 4.6 recoge el resultado. El análisis exploratorio, que no tiene veredicto, se resume al final de esta sección, tras la resolución de las tres hipótesis.

Tabla 4.6: Resolución de las hipótesis.

Hipótesis	Resolución	Evidencia
H1a	Se cumple en uno de los doce casos (Bitcoin mensual)	Clark-West con p < 0,001, menor QLIKE y valor p ajustado por Holm inferior a 0,001. En los once casos restantes no se cumple el criterio
H1b	No se cumple	Diebold-Mariano unilateral del SVR con F1 frente al HAR-X con F1 en Bitcoin mensual, con p = 0,068
H2	Se rechaza	La composición no mejora a la intensidad en ninguno de los seis modelos principales mensuales

La H1a se cumple solo en Bitcoin en el horizonte mensual, donde el SVR con F1 reduce la pérdida QLIKE de 0,258 a 0,238. El caso del WTI mensual queda en el límite (p = 0,050) sin cumplir el criterio, y en el bono del Tesoro mensual el test de Clark-West queda también en el límite (p = 0,053), pero la QLIKE aumenta. Los resultados parciales de la energía semanal, en tres modelos no lineales secundarios, y del HAR-X de Bitcoin semanal no intervienen en la resolución, aunque indican que la información geopolítica puede ser útil en especificaciones distintas de la principal.

La H1b solo puede evaluarse en Bitcoin mensual, el único caso que cumple la H1a, comparando el SVR con F1 con el HAR-X con F1. La ganancia del SVR respecto a su versión con F0 es mayor que la del HAR-X, de 7,7 frente a 4,5 puntos porcentuales, pero el test de Diebold-Mariano unilateral no es significativo al 5 % (p = 0,068). La H1b no se cumple, porque la mayor ganancia del modelo no lineal no basta para afirmar que aproveche mejor la información geopolítica.

La H2 se rechaza, porque con F2 los seis modelos principales mensuales predicen peor que con F1. Como resultado parcial, tres modelos secundarios cumplen formalmente el

criterio, XGBoost en el Brent, el WTI y el bono del Tesoro mensuales. En los tres, la intensidad por sí sola deterioraba mucho la predicción, entre un 12 % y un 25 % frente al HAR-RV. En el Brent y el WTI, la composición solo compensa en parte ese deterioro. En el bono del Tesoro lo compensa por completo y el modelo con F2 queda marginalmente por debajo de su versión con F0 (0,1082 frente a 0,1087), aunque sigue prediciendo peor que el HAR-RV (−2,1 %). En ninguno de los tres casos la composición mejora sobre la volatilidad pasada por sí sola. Como se anticipó en la sección 1.4, este rechazo indica que, con este diseño y esta muestra, la información geopolítica útil para predecir la volatilidad está contenida en la intensidad.

El análisis exploratorio no permite concluir que los tipos de evento persistentes concentren más contribución que los transitorios, porque el resultado cambia con el estimador y con la medida empleada (sección 4.3.3).

4.6 Discusión

4.6.1 Diálogo con la literatura

El resultado general, que el riesgo geopolítico no mejora la predicción de la volatilidad salvo en casos concretos, contrasta a primera vista con la evidencia de que afecta a los mercados financieros, aunque el contraste es menor de lo que parece. Engle y Campos-Martins (2023) no encuentran efecto del riesgo geopolítico sobre la volatilidad bursátil global cuando controlan por otras fuentes de incertidumbre. Smales (2021) documenta el efecto más claro en el petróleo, y Plakandaras et al. (2019) encuentran mejoras predictivas solo en el oro, sobre su precio y no sobre su volatilidad. Los resultados de este trabajo son coherentes con esa evidencia en la renta variable, donde el AI-GPR apenas aporta, y en la energía, donde solo aporta en especificaciones secundarias y en episodios concretos.

Tres diferencias de diseño pueden explicar por qué otros estudios encuentran efectos que aquí no aparecen. Buena parte de la literatura estima relaciones dentro de la muestra, mientras que este trabajo exige que la relación se mantenga fuera de ella. El modelo de referencia es además el HAR-RV, más difícil de superar que los modelos autorregresivos simples. En Niu et al. (2023), por ejemplo, el modelo de referencia ya incluía el índice de riesgo geopolítico, de modo que su mejora medía el estimador y no la aportación del índice. Por último, el periodo de prueba corresponde a un régimen de riesgo geopolítico elevado y persistente, con una composición por tipos de evento distinta de la del entrenamiento.

La aportación del trabajo está en aplicar el mismo diseño fuera de muestra a cinco familias de activos y en separar la intensidad del riesgo geopolítico de su composición. Con ese diseño, la composición no mejora al modelo principal en ningún caso, aunque los modelos le asignen una contribución considerable. La distinción entre contribución y capacidad predictiva resulta, por tanto, sustantiva, porque separa lo que un modelo usa de lo que efectivamente le ayuda a predecir.

4.6.2 Lectura de los resultados a través de los canales de transmisión

Los resultados admiten una lectura por canales (tabla 1.2), que debe entenderse como interpretación y no como contraste. En la energía, las mejoras semanales de los modelos no lineales secundarios se concentran en episodios de tensión con efectos sobre la oferta, en particular en 2022 y en marzo de 2026. Este patrón es compatible con el canal de oferta física, en el que el riesgo geopolítico afectaría a la volatilidad del crudo mediante perturbaciones discretas y de efecto rápido.

En el oro, el canal de huida hacia la calidad no se traduce en capacidad predictiva, ya que su papel como refugio, documentado por Baur y Lucey (2010) y Baur y Smales (2020), no implica que su volatilidad aumente con el riesgo geopolítico. Los resultados son compatibles con que la relación estimada en el entrenamiento no se mantenga en el periodo reciente, como sugiere la prueba con la muestra desde 2014.

En el bono del Tesoro, el AI-GPR desplaza las predicciones al alza, en la dirección que sugeriría una mayor demanda de activos seguros, pero la volatilidad realizada del periodo de prueba no acompaña ese desplazamiento. En la renta variable, donde la teoría asigna al riesgo geopolítico un efecto a través del sentimiento y la incertidumbre, el AI-GPR no aporta información adicional a la volatilidad pasada.

Bitcoin carece de un canal de transmisión establecido en la literatura, y su resultado debe leerse con esa cautela. La mejora es estadísticamente sólida en el modelo principal, pero coincide con la reducción de una sobrestimación sistemática y el diseño no permite distinguir si el AI-GPR aporta información específicamente geopolítica o recoge otros factores que coinciden con él en el periodo de prueba.

En conjunto, varios resultados son compatibles con un cambio en la relación entre el riesgo geopolítico y la volatilidad entre el periodo de entrenamiento y el de prueba. Entre ellos están el cambio de composición por tipos de evento, las mejoras adicionales al entrenar con la muestra desde 2014, la concentración del deterioro en episodios concretos y la dirección distinta del sesgo según la serie. Esta explicación no se formuló como hipótesis antes de la estimación, por lo que debe entenderse como una interpretación plausible y no como un resultado contrastado.

4.6.3 Sensibilidad de los resultados al ajuste de hiperparámetros

Algunos modelos del SVR y de XGBoost quedaron con hiperparámetros en el límite del espacio de búsqueda (sección 3.5 y tabla B.2). Su efecto sobre las conclusiones puede acotarse caso por caso, empezando por el único resultado que cumple la H1a. Los hiperparámetros del SVR de Bitcoin mensual con F0 y con F1 están dentro de los rangos explorados, de modo que ese resultado no depende de un modelo ajustado en el límite. Tampoco depende de la diferencia de hiperparámetros entre ambas versiones, porque la mejora se mantiene al estimar el SVR con F1 con los hiperparámetros de F0 (sección 4.2.5).

En los modelos principales del S&P 500 y del WTI mensuales, la versión con F1 tiene γ en el límite, y en el WTI y en Bitcoin mensuales lo está también la versión con F2.

Un ajuste incompleto de esas versiones tendería a perjudicar a la especificación con información geopolítica. Por ello no puede haber inflado ninguna mejora, aunque sí podría haber contribuido a que no se observen mejoras en esos casos, tanto en la H1a como en la H2. La magnitud de los deterioros con F2, superiores al 15 % frente al HAR-RV, hace poco probable que un ajuste más amplio los revierta, aunque el trabajo no lo ha comprobado. En los resultados parciales de la energía semanal, la situación difiere entre modelos, ya que en el SVR del WTI solo la versión con F1 queda en el límite, y XGBoost del WTI no tiene ningún hiperparámetro fuera de rango, de modo que ninguna de esas dos mejoras puede estar inflada por esta causa. En el SVR del Brent, en cambio, quedan en el límite tanto la versión con F0 como la versión con F1, por lo que no puede determinarse en qué sentido afecta el ajuste a su mejora.

El ajuste en el límite afecta también a la elección de un modelo principal en el bono del Tesoro semanal, donde el SVR resulta modelo principal por un margen estrecho frente a XGBoost (0,3214 frente a 0,3221), cuyo número de árboles supera el rango, y un ajuste más amplio de ese modelo podría haber invertido la elección. Como ninguna de las dos especificaciones mejora con el AI-GPR en ese caso, la resolución de la H1a no cambiaría.

4.6.4 Implicaciones

Para la predicción de la volatilidad, los resultados tienen tres implicaciones, la primera de las cuales es que el HAR-RV sigue siendo una referencia difícil de superar. Los modelos de aprendizaje automático lo superan en la validación cruzada de la mayoría de los casos, pero fuera de muestra sus diferencias con la referencia son pequeñas y no significativas. En esta muestra, además, el riesgo geopolítico no se comporta como un predictor general de la volatilidad, ya que su valor, cuando aparece, depende de la serie, del horizonte y de la especificación. Por último, los resultados sugieren que la relación entre riesgo geopolítico y volatilidad puede cambiar con el tiempo, de modo que el periodo con que se estiman los modelos puede influir en que el riesgo geopolítico aporte o no.

En el plano metodológico, el trabajo muestra que la interpretabilidad no sustituye a la evaluación fuera de muestra. Los modelos asignan a la composición una contribución considerable, aunque esta no mejora la predicción. La comparación entre tipos de evento depende, además, del estimador con que se calculan los valores SHAP. Interpretar esos valores sin contrastar antes la capacidad predictiva, y sin comparar varios estimadores, podría haber llevado a conclusiones que los resultados no sostienen.

CONCLUSIONES, RECOMENDACIONES Y TRABAJOS FUTUROS

Este trabajo ha evaluado si el riesgo geopolítico, medido con el índice AI-GPR y descompuesto por tipos de evento, mejora la predicción fuera de muestra de la volatilidad de cinco familias de activos representadas por seis series financieras. Para ello se comparó el modelo HAR-RV con su extensión lineal y con tres modelos de aprendizaje automático, Elastic Net, SVR y XGBoost, en dos horizontes y con un periodo de prueba de enero de 2022 a agosto de 2026.

Respuesta a las preguntas de investigación

La primera pregunta planteaba si la intensidad del riesgo geopolítico mejora la predicción de la volatilidad frente a un modelo basado en la volatilidad pasada y si esa mejora depende del tipo de modelo. La respuesta es negativa en la mayoría de los casos, ya que la intensidad mejora al modelo principal en uno solo de los doce, Bitcoin en el horizonte mensual, donde reduce la pérdida un 7,8 % frente al HAR-RV. Este resultado mantiene su significación tras ajustar por comparaciones múltiples, de modo que la H1a se cumple solo en ese caso. En la energía, la mejora aparece únicamente en tres modelos no lineales secundarios del horizonte semanal y se concentra en episodios de tensión. En la renta variable, los metales preciosos y la deuda soberana no mejora la predicción, y en el oro la deteriora. En cuanto al tipo de modelo, en Bitcoin mensual la ganancia del SVR es mayor que la del HAR-X, pero la diferencia no es significativa al 5 %, por lo que la H1b no se cumple. Con esta evidencia no puede afirmarse que los modelos no lineales aprovechen mejor la información geopolítica.

La segunda pregunta planteaba si la composición por tipos de evento aporta capacidad predictiva adicional a la intensidad y cómo se distribuye su contribución entre familias. La composición no mejora a la intensidad en ningún modelo principal, por lo que la H2 se rechaza. Este resultado negativo es informativo, porque indica que, con este diseño y esta muestra, la información geopolítica útil para predecir la volatilidad está contenida en la intensidad. Los modelos asignan, sin embargo, una contribución considerable a la composición, que en el HAR-X de la energía, del oro y de Bitcoin supera la mitad del total. El tipo de evento con mayor contribución cambia con la serie y con el estimador, de modo que ninguno es dominante con los cuatro estimadores. El análisis exploratorio tampoco permite concluir que los tipos persistentes contribuyan más que los transitorios, porque el resultado depende del estimador y de la medida empleada.

Grado de cumplimiento de los objetivos

El objetivo general se ha alcanzado con un resultado mayoritariamente negativo, que no resta validez al trabajo, porque el diseño permitía que la respuesta fuera negativa y la evidencia así lo indica. Se construyó y validó una base de datos con seis series

y el índice AI-GPR, con un control de calidad documentado de las anomalías de cada serie (OE1). Se compararon fuera de muestra el HAR-RV, el HAR-X y tres modelos de aprendizaje automático con tres conjuntos de variables y en dos horizontes (OE2). La mejora predictiva se contrastó con los tests de Clark-West y Diebold-Mariano y con el conjunto de confianza de modelos, y su robustez, con seis pruebas (OE3).

La contribución de cada variable se describió con SHAP y con la importancia por permutación, tanto en los modelos con composición como en los modelos con intensidad (OE4). Por último, el flujo principal se ejecutó dos veces con los mismos datos y reprodujo los mismos resultados, y el código está disponible en un repositorio público (ver 3.6) que permite repetir todo el análisis (OE5). Las comprobaciones añadidas al final del trabajo son cálculos de consulta que no modifican ningún resultado anterior.

Interpretación de los resultados

Varios resultados son compatibles con un cambio en la relación entre el riesgo geopolítico y la volatilidad entre el periodo de entrenamiento, de 1999 a 2021, y el de prueba, de 2022 a 2026. En la prueba, el peso del conflicto militar se duplica y el del terrorismo cae a un tercio. El deterioro de la predicción se concentra además en episodios concretos y el efecto del AI-GPR sobre las predicciones cambia de dirección según la serie. Al entrenar los modelos solo con datos desde 2014, la intensidad mejora la predicción en más series. Esta explicación es una interpretación plausible y no un resultado contrastado, porque no se formuló como hipótesis antes de la estimación y las pruebas que la apoyan modifican a la vez varios elementos del diseño.

Limitaciones

La principal limitación es la ausencia de controles de incertidumbre general, como el VIX o el EPU. Aunque el riesgo geopolítico es un fenómeno distinto de la incertidumbre económica (Caldara & Iacoviello, 2022), no puede descartarse que parte de la mejora observada en Bitcoin refleje factores distintos del riesgo geopolítico. En cambio, dos comprobaciones descartan que esa mejora proceda de la diferencia de hiperparámetros entre las versiones con F0 y con F1 o de la corrección logarítmica normal, porque se mantiene al igualar los hiperparámetros o la corrección entre ambas versiones.

El trabajo emplea un único periodo de prueba, que corresponde a un régimen geopolítico particular, por lo que no permite saber si los resultados se mantendrían en otro régimen. Los resultados positivos son además frágiles, porque el de Bitcoin no resiste la agregación mensual de la información, las mejoras del WTI mensual están en el límite de la significación y solo aparecen en pruebas de robustez, y la más significativa de las mejoras parciales de la energía semanal desaparece cuando se mide con el MSE.

Varias decisiones metodológicas acotan también el alcance de los resultados, empezando por el test de Clark-West, que en el SVR y XGBoost se aplica como aproximación porque las versiones con y sin riesgo geopolítico tienen hiperparámetros distintos. En algunos modelos de SVR y XGBoost, los hiperparámetros seleccionados quedan en

el límite del espacio explorado. Ninguno corresponde al resultado de Bitcoin, pero sí a versiones con información geopolítica de otros casos, en los que un ajuste más amplio podría haber reducido sus pérdidas. La volatilidad se aproxima con rendimientos diarios al cuadrado, una medida más ruidosa que la volatilidad realizada con datos intradía. Las series continuas de energía presentan, además, una volatilidad mayor en la sesión en que cambian de contrato, lo que añade ruido a la medida y obliga a interpretar con cautela las mejoras parciales de la energía semanal. Por último, la frontera entre algunas categorías del clasificador del AI-GPR es difusa, lo que limita la interpretación de las diferencias entre tipos de evento próximos.

Líneas de trabajo futuro

La línea más directa consiste en incorporar el VIX y el EPU como controles, empezando por Bitcoin, para comprobar si la mejora es específica del riesgo geopolítico. También convendría evaluar los modelos en varias ventanas de prueba y contrastar formalmente la estabilidad de la relación entre riesgo geopolítico y volatilidad, que en este trabajo solo se ha interpretado.

En cuanto a la composición, una línea natural es construirla con mayor frecuencia para evaluarla también en el horizonte semanal. Así podría contrastarse si la contribución de cada tipo de evento cambia con el horizonte, que es la consecuencia observable de su persistencia. Los índices específicos del petróleo que ofrece el propio AI-GPR, más próximos al canal de oferta física, permitirían además profundizar en la familia de energía, idealmente con series construidas a partir de los contratos individuales para evitar los saltos de los cambios de contrato. Por último, ampliar los rangos de búsqueda de los hiperparámetros que quedaron en el borde completaría el ajuste de los modelos afectados.

Recomendaciones

A quienes predicen la volatilidad, los resultados les sugieren mantener el HAR-RV como modelo de referencia y no incorporar el riesgo geopolítico de forma general. Antes de usarlo conviene comprobar fuera de muestra si mejora la predicción de la serie y del horizonte concretos. Las especificaciones no lineales de la energía a corto plazo son las que muestran más indicios en esta muestra, aunque como resultado parcial y sujeto a la cautela sobre los cambios de contrato. Conviene también revisar el periodo con que se estiman los modelos, porque una muestra que incluya relaciones que ya no se mantienen puede deteriorar la predicción.

A quienes investigan, el trabajo les recomienda contrastar la capacidad predictiva de una variable antes de interpretar su contribución con técnicas como SHAP porque una contribución elevada no garantiza que la variable mejore la predicción. Cuando se comparan variables, conviene además calcular la contribución con varios estimadores y tener en cuenta cuánto cambian las variables entre el entrenamiento y la prueba, ya que ambos factores pueden alterar la comparación.

REFERENCIAS BIBLIOGRÁFICAS

Andersen, T. G., & Bollerslev, T. (1998). Answering the Skeptics: Yes, Standard Volatility Models do Provide Accurate Forecasts. *International Economic Review*, *39*(4), 885-905. https://doi.org/10.2307/2527343

Antonakakis, N., Gupta, R., Kollias, C., & Papadamou, S. (2017). Geopolitical risks and the oil-stock nexus over 1899–2016. *Finance Research Letters*, *23*, 165-173. https://doi.org/10.1016/j.frl.2017.07.017

Azqueta-Gavaldon, A., & Ureta, B. (2026). CausalAlpha: A Real-Time Geopolitical Risk Index from OSINT Channels for Causal Discovery in Financial Markets [AD04]. https://doi.org/10.48550/ARXIV.2606.07049

Baker, M., & Wurgler, J. (2006). Investor Sentiment and the Cross-Section of Stock Returns. *The Journal of Finance*, *61*(4), 1645-1680. https://doi.org/10.1111/j.1540-6261.2006.00885.x

Baker, S., Bloom, N., & Davis, S. (2015, octubre). *Measuring Economic Policy Uncertainty* (inf. téc. Nº w21633) (AD07). National Bureau of Economic Research. Cambridge, MA. https://doi.org/10.3386/w21633

Baur, D. G., & Lucey, B. M. (2010). Is Gold a Hedge or a Safe Haven? An Analysis of Stocks, Bonds and Gold [AD14]. *Financial Review*, *45*(2), 217-229. https://doi.org/10.1111/j.1540-6288.2010.00244.x

Baur, D. G., & Smales, L. A. (2020). Hedging geopolitical risk with precious metals [AD16]. *Journal of Banking & Finance*, *117*, 105823. https://doi.org/10.1016/j.jbankfin.2020.105823

Berkman, H., Jacobsen, B., & Lee, J. B. (2011). Time-varying rare disaster risk and stock returns. *Journal of Financial Economics*, *101*(2), 313-332. https://doi.org/10.1016/j.jfineco.2011.02.019

Boungou, W., Gupta, P., & Wahyono, B. (2024). Coup d'état in Africa and stock market returns: the case of French companies. *Economics Letters*, *237*. Consultado el 5 de octubre de 2026, desde https://ora.ox.ac.uk/objects/uuid:2e7299ec-b0e3-4b9b-8301-122ae779b988

Brauneis, A., & Mestel, R. (2018). Price discovery of cryptocurrencies: Bitcoin and beyond. *Economics Letters*, *165*, 58-61. https://doi.org/10.1016/j.econlet.2018.02.001

Breiman, L. (2001). Random Forests. *Machine Learning*, *45*(1), 5-32. https://doi.org/10.1023/A:1010933404324

Caldara, D., & Iacoviello, M. (2022). Measuring Geopolitical Risk [P01]. *American Economic Review*, *112*(4), 1194-1225. https://doi.org/10.1257/aer.20191823

Charfeddine, L., & Al Refai, H. (2019). Political tensions, stock market dependence and volatility spillover: Evidence from the recent intra-GCC crises. *The North American Journal of Economics and Finance*, *50*, 101032. https://doi.org/10.1016/j.najef.2019.101032

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System [arXiv:1603.02754 [cs.LG]]. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. https://doi.org/10.1145/2939672.2939785

Corsi, F. (2008). A Simple Approximate Long-Memory Model of Realized Volatility. *Journal of Financial Econometrics*, *7*(2), 174-196. https://doi.org/10.1093/jjfinec/nbp001

Darbouche, H., & Fattouh, B. (2011, septiembre). *The Implications of the Arab Uprisings for Oil and Gas Markets* (inf. téc.). Oxford Institute for Energy Studies. https://doi.org/10.26889/9781907555336

Drakos, K. (2010). Terrorism activity, investor sentiment, and stock returns. *Review of Financial Economics*, *19*(3), 128-135. https://doi.org/10.1016/j.rfe.2010.01.001

Drucker, H., Burges, C. J., Kaufman, L., Smola, A., & Vapnik, V. (1996). Support vector regression machines. *Advances in neural information processing systems*, *9*.

Engle, R. F., & Campos-Martins, S. (2020, septiembre). Measuring and Hedging Geopolitical Risk [P03]. https://doi.org/10.2139/ssrn.3685213

Engle, R. F., & Campos-Martins, S. (2023). What are the events that shake our world? Measuring and hedging global COVOL [AD05]. *Journal of Financial Economics*, *147*(1), 221-242. https://doi.org/10.1016/j.jfineco.2022.09.009

Engle, R. F., Ghysels, E., & Sohn, B. (2013). Stock Market Volatility and Macroeconomic Fundamentals. *The Review of Economics and Statistics*, *95*(3), 776-797. Consultado el 4 de octubre de 2026, desde https://www.jstor.org/stable/43554794

Farzanegan, M. R., & Raeisian Parvari, M. (2014). Iranian-Oil-Free Zone and international oil prices. *Energy Economics*, *45*, 364-372. https://doi.org/10.1016/j.eneco.2014.08.004

Fisher, A., Rudin, C., & Dominici, F. (2019, diciembre). All Models are Wrong, but Many are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously. https://doi.org/10.48550/arXiv.1801.01489

Garman, M. B., & Klass, M. J. (1980). On the Estimation of Security Price Volatilities from Historical Data. *The Journal of Business*, *53*(1), 67-78. Consultado el 23 de septiembre de 2026, desde https://www.jstor.org/stable/2352358

Gupta, R., Majumdar, A., Nel, J., & Subramaniam, S. (2021). Geopolitical risks and the high-frequency movements of the us term structure of interest rates [AD09]. *Annals of Financial Economics*, *16*(03), 2150012. https://doi.org/10.1142/S2010495221500123

Hamilton, J. D. (2003). What is an oil shock? *Journal of Econometrics*, *113*(2), 363-398. https://doi.org/10.1016/S0304-4076(02)00207-5

Hansen, P. R., Lunde, A., & Nason, J. M. (2011). The Model Confidence Set. *Econometrica*, *79*(2), 453-497. https://doi.org/10.3982/ECTA5771

Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, *13*(2), 281-291. https://doi.org/10.1016/S0169-2070(96)00719-4

Holm, S. (1979). A Simple Sequentially Rejective Multiple Test Procedure. *Scandinavian Journal of Statistics*, *6*(2), 65-70. Consultado el 9 de noviembre de 2026, desde https://www.jstor.org/stable/4615733

Huh, I., & Pyun, J. H. (2018). Does Nuclear Uncertainty Threaten Financial Markets? The Attention Paid to North Korean Nuclear Threats and Its Impact on South Korea's Financial Markets. *Asian Economic Journal*, *32*(1), 55-82. https://doi.org/10.1111/asej.12142

Iacoviello, M., & Tong, J. (2026, agosto). *The AI-GPR Index: Measuring Geopolitical Risk using Artificial Intelligence* (inf. téc.) (AD06).

Kamal, M. R., & Wahlstrøm, R. R. (2023). Cryptocurrencies and the threat versus the act event of geopolitical risk [AD11]. *Finance Research Letters*, *57*, 104224. https://doi.org/10.1016/j.frl.2023.104224

Kapar, B., & Buigut, S. (2020). Effect of Qatar diplomatic and economic isolation on Qatar stock market volatility: an event study approach. *Applied Economics*, *52*(55), 6022-6030. https://doi.org/10.1080/00036846.2020.1781776

Kilian, L. (2008). Exogenous Oil Supply Shocks: How Big Are They and How Much Do They Matter for the U.S. Economy? *The Review of Economics and Statistics*, *90*(2), 216-240. Consultado el 5 de octubre de 2026, desde https://www.jstor.org/stable/40043142

Kilian, L. (2009). Not All Oil Price Shocks Are Alike: Disentangling Demand and Supply Shocks in the Crude Oil Market. *The American Economic Review*, *99*(3), 1053-1069. Consultado el 4 de octubre de 2026, desde https://www.jstor.org/stable/25592494

Kollias, C., Kyrtsou, C., & Papadamou, S. (2013). The effects of terrorism and war on the oil price–stock index relationship. *Energy Economics*, *40*, 743-752. https://doi.org/10.1016/j.eneco.2013.09.006

Korkusuz, B., Kambouroudis, D. S., & McMillan, D. G. (2023, febrero). Do Extreme Range Estimators Improve Realized Volatility Forecasts? Evidence from G7 Stock Markets. https://doi.org/10.2139/ssrn.4368227

Lumjiak, S., Quang, N. T. T., Gan, C., & Treepongkaruna, S. (2018). Good coups, bad coups: evidence from Thailand's financial markets. *Investment Management and Financial Innovations*, *15*(2), 68-86. https://doi.org/10.21511/imfi.15(2).2018.07

Lundberg, S., & Lee, S.-I. (2017, noviembre). A Unified Approach to Interpreting Model Predictions. https://doi.org/10.48550/arXiv.1705.07874

Nakamoto, S. (2008). Bitcoin: A Peer-to-Peer Electronic Cash System [AD15]. Consultado el 22 de septiembre de 2026, desde https://bitcoin.org/en/bitcoin-paper

Niu, Z., Wang, C., & Zhang, H. (2023). Forecasting stock market volatility with various geopolitical risks categories: New evidence from machine learning models [AD01]. *International Review of Financial Analysis*, *89*, 102738. https://doi.org/10.1016/j.irfa.2023.102738

Ortiz, A., Rodrigo, T., & Saborido, P. (2026, marzo). Geopolitics, Geoeconomics, and Sovereign Risk: Different Shocks, Different Channels [P05]. https://doi.org/10.48550/arXiv.2510.12416

Parkinson, M. (1980). The Extreme Value Method for Estimating the Variance of the Rate of Return. *The Journal of Business*, *53*(1), 61-65. Consultado el 23 de septiembre de 2026, desde https://www.jstor.org/stable/2352357

Pástor, Ľ., & Veronesi, P. (2012). Uncertainty about Government Policy and Stock Prices. *The Journal of Finance*, *67*(4), 1219-1264. Consultado el 4 de octubre de 2026, desde https://www.jstor.org/stable/23261358

Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, *160*(1), 246-256. https://doi.org/10.1016/j.jeconom.2010.03.034

Paul C. Tetlock. (2007). Giving Content to Investor Sentiment: The Role of Media in the Stock Market. *The Journal of Finance*, *62*(3), 1139-1168. Consultado el 17 de septiembre de 2026, desde http://www.jstor.org/stable/4622297

Plakandaras, V., Gogas, P., & Papadimitriou, T. (2019). The Effects of Geopolitical Uncertainty in Forecasting Financial Markets: A Machine Learning Approach [P02]. *Algorithms*, *12*(1), 1. https://doi.org/10.3390/a12010001

Rigobon, R., & Sack, B. (2005). The effects of war risk on US financial markets. *Journal of Banking & Finance*, *29*(7), 1769-1789. https://doi.org/10.1016/j.jbankfin.2004.06.040

Rogers, L. C. G., & Satchell, S. E. (1991). Estimating Variance From High, Low and Closing Prices. *The Annals of Applied Probability*, *1*(4), 504-512. Consultado el 4 de octubre de 2026, desde https://www.jstor.org/stable/2959703

Salisu, A., & Nsonwu, M. C. (2026). The stock market reaction to the US-China tensions: Evidence from emerging and developed markets. *Journal of Economics and Finance*, *50*(1), 46. https://doi.org/10.1007/s12197-026-09784-8

Salisu, A. A., Ogbonna, A. E., Lasisi, L., & Olaniran, A. (2022). Geopolitical risk and stock market volatility in emerging markets: A GARCH – MIDAS approach [AD02]. *The North American Journal of Economics and Finance*, *62*, 101755. https://doi.org/10.1016/j.najef.2022.101755

Smales, L. (2021). Geopolitical Risk and Volatility Spillovers in Oil and Stock Markets [P04]. *The Quarterly Review of Economics and Finance*, *80*. https://doi.org/10.1016/j.qref.2021.03.008

Smola, A. J., & Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, *14*(3), 199-222. https://doi.org/10.1023/B:STCO.0000035301.49549.88

Urquhart, A. (2016). The inefficiency of Bitcoin. *Economics Letters*, *148*, 80-82. https://doi.org/10.1016/j.econlet.2016.09.019

Yang, D., & Zhang, Q. (2000). Drift□Independent Volatility Estimation Based on High, Low, Open, and Close Prices. *The Journal of Business*, *73*(3), 477-492. https://doi.org/10.1086/209650

Zou, H., & Hastie, T. (2005). Regularization and Variable Selection Via the Elastic Net. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, *67*(2), 301-320. https://doi.org/10.1111/j.1467-9868.2005.00503.x

APÉNDICE A

DATOS Y DEPURACIÓN

Este apéndice detalla los calendarios de sesiones empleados en la depuración de las series y el contraste sobre los vencimientos de los contratos de energía, que el capítulo 3 resume.

Calendarios de sesiones y depuración

Cada serie se contrasta con un calendario de sesiones (tabla A.1). Para el S&P 500 y el bono del Tesoro se usan los calendarios oficiales de NYSE y SIFMA de la librería `pandas_market_calendars`. El de SIFMA se corrige con los festivos federales, los cierres extraordinarios del mercado de bonos y las sesiones especiales revisadas manualmente.

Tabla A.1: Calendarios de sesiones y tratamiento de los días fuera de sesión.

Serie	Calendario	Días fuera de sesión
S&P 500	NYSE	Se eliminan
Brent y WTI	ICE Futures Europe	Se eliminan solo si la variación es nula
Oro	Laborables salvo Navidad, Año Nuevo y Viernes Santo	Se eliminan solo si la variación es nula
Bono del Tesoro	SIFMA corregido	Se eliminan
Bitcoin	Todos los días	No existen

En el bono del Tesoro, las 217 observaciones eliminadas corresponden a 173 festivos, 40 fines de semana, tres Viernes Santos con el mercado cerrado y un cierre extraordinario. En el oro, los cierres del 10 y el 11 de marzo de 2008 repetían el valor del día anterior en sesiones con movimiento de precio y se sustituyeron por los cierres de una fuente externa. El registro de anomalías se guarda en tres columnas del conjunto de datos, que recogen el tipo de anomalía, la acción aplicada y su motivo.

Vencimientos de los contratos de energía

Los vencimientos se identifican con las reglas de cada mercado. En el WTI se sitúan en la tercera sesión anterior al día 25 del mes previo a la entrega o, si el día 25 no es hábil, en la tercera sesión anterior a la última sesión previa a esa fecha, mientras que en el Brent se sitúan en la última sesión de cada mes. La tabla A.2 compara la volatilidad de cuatro ventanas en torno a cada vencimiento con la del resto de sesiones. La sesión siguiente al vencimiento es aquella en la que la serie continua pasa al nuevo contrato, como en el caso documentado del 22 de abril de 2020.

Tabla A.2: Volatilidad diaria media en logaritmos en torno a los vencimientos.

Serie	Ventana	Ventana	Resto	p de Mann-Whitney
WTI	Cinco sesiones que terminan en el vencimiento	$-9{,}21$	$-8{,}99$	$< 0{,}001$
	Sesión siguiente	$-8{,}48$	$-9{,}07$	$< 0{,}001$
	Dos sesiones siguientes	$-8{,}71$	$-9{,}08$	$< 0{,}001$
	De cuatro sesiones antes a dos después	$-9{,}07$	$-9{,}03$	0,356
Brent	Cinco sesiones que terminan en el vencimiento	$-9{,}44$	$-9{,}14$	$< 0{,}001$
	Sesión siguiente	$-8{,}59$	$-9{,}24$	$< 0{,}001$
	Dos sesiones siguientes	$-8{,}74$	$-9{,}26$	$< 0{,}001$
	De cuatro sesiones antes a dos después	$-9{,}24$	$-9{,}19$	0,979

APÉNDICE B

AJUSTE DE LOS MODELOS Y ENTORNO DE EJECUCIÓN

Este apéndice recoge los rangos de búsqueda de los hiperparámetros, los valores seleccionados en el modelo principal de cada caso y el entorno de software con que se obtuvieron los resultados.

Rangos de búsqueda

La tabla B.1 recoge los rangos que explora la primera fase de la búsqueda, con 40 combinaciones aleatorias por modelo. La segunda fase evalúa la mitad y el doble del mejor valor, por lo que puede seleccionar valores fuera de estos rangos.

Tabla B.1: Rangos de búsqueda de la primera fase.

Estimador	Hiperparámetro	Rango
Elastic Net	Penalización α	$[10^{-5},\ 10]$
	Proporción L1 ρ	$[0,\ 1]$
SVR	Peso C	$[10^{-3},\ 10^{3}]$
	Margen ε	$[0{,}01;\ 2]$
	Escala del núcleo γ	$[10^{-3},\ 1]$
XGBoost	Profundidad	$\{1, \ldots, 6\}$
	Número de árboles	$[100,\ 1.500]$
	Tasa de aprendizaje	$[0{,}005;\ 0{,}3]$
	Peso mínimo por hoja	$[1,\ 100]$
	Submuestreo de filas y de columnas	$[0{,}5;\ 1]$
	Regularización L2	$[0{,}1;\ 100]$

Hiperparámetros seleccionados

La tabla B.2 recoge los hiperparámetros del modelo principal de cada caso con cada conjunto de variables y su pérdida QLIKE en la validación cruzada. Los valores marcados con una daga quedan fuera del rango de la primera fase, y ninguno corresponde al SVR de Bitcoin mensual con F0 o con F1, el único caso que cumple la H1a.

Entorno de software y coste computacional

Los resultados proceden de una ejecución con la semilla 42 en todas las fuentes de aleatoriedad, Python 3.14.7 y las librerías NumPy 2.5.3, pandas 3.0.6, SciPy 1.18.1, scikit-learn 1.9.1, XGBoost 3.2.0, SHAP 0.53.0, arch 8.0.0, statsmodels 0.15.0, joblib 1.6.0 y `pandas_market_calendars` 5.4.0. Una ejecución anterior con Python 3.11.15 y versiones anteriores de las librerías produjo los mismos resultados con cuatro decimales en todas las cifras contrastadas. La tabla B.3 recoge el tiempo de cada etapa en una ejecución

Tabla B.2: Hiperparámetros del modelo principal de cada caso.

Caso	Modelo	Conjunto	C o α	ε o ρ	γ	QLIKE CV
S&P 500, mensual	SVR	F0	47,3	1,19	0,00167	0,4095
		F1	47,3	0,595	0,000834†	0,4227
		F2	0,684	0,0963	0,00119	0,4586
S&P 500, semanal	SVR	F0	23,7	1,19	0,00167	0,4700
		F1	23,7	1,19	0,00167	0,4731
Brent, mensual	HAR	F0	—	—	—	0,2571
		F1	—	—	—	0,2574
		F2	—	—	—	0,3006
Brent, semanal	HAR	F0	—	—	—	0,4068
		F1	—	—	—	0,4063
WTI, mensual	SVR	F0	18,9	0,104	0,0182	0,3200
		F1	2,74	0,0482	0,000596†	0,3360
		F2	2,74	0,0963	0,000596†	0,3710
WTI, semanal	HAR	F0	—	—	—	0,4339
		F1	—	—	—	0,4355
Oro, mensual	SVR	F0	23,7	0,595	0,00334	0,2256
		F1	23,7	0,595	0,00334	0,2148
		F2	1,09	0,32	0,00199	0,2502
Oro, semanal	SVR	F0	23,7	0,595	0,00167	0,3873
		F1	3,91	0,0114	0,00294	0,3853
Bono del Tesoro, mensual	SVR	F0	0,781	0,0936	0,0685	0,1724
		F1	23,7	0,595	0,00167	0,1844
		F2	1,09	0,641	0,00199	0,1932
Bono del Tesoro, semanal	SVR	F0	4,66	0,594	0,0151	0,3214
		F1	5,49	0,0577	0,00155	0,3243
Bitcoin, mensual	SVR	F0	2,74	0,0482	0,00119	0,3750
		F1	0,0472	0,0301	0,0148	0,4010
		F2	0,00222	0,00591†	0,162	0,4220
Bitcoin, semanal	Elastic Net	F0	0,424	0,074	—	0,6217
		F1	0,174	0,729	—	0,6237

En el SVR, las columnas recogen el peso C, el margen ε y la escala del núcleo γ. En Elastic Net recogen la penalización α y la proporción L1 ρ. El HAR no tiene hiperparámetros. La daga indica un valor fuera del rango de la primera fase (tabla B.1).

completa en un equipo con 20 núcleos lógicos.

Tabla B.3: Tiempo de cómputo por etapa.

Etapa	Tiempo
Ajuste de hiperparámetros (90 modelos)	17 min
Predicción con ventana expansiva (6.720 reestimaciones)	30 min
Valores SHAP con F2 (24 modelos)	43 min
Valores SHAP con F1 (17 modelos)	26 min
Pruebas de robustez	19 min
Importancia por permutación (24 modelos)	11 min
Total	2.4 horas

APÉNDICE C

RESULTADOS COMPLETOS Y COMPLEMENTARIOS

En este apéndice se presentan los resultados completos de la evaluación fuera de muestra. Las tablas siguen el diseño descrito en el capítulo 2, con tres conjuntos de variables (F0, F1 y F2), cuatro estimadores y los horizontes semanal y mensual para cada una de las seis series.

La tabla C.1 presenta, para cada serie, horizonte y estimador, el R^2_{OOS} de cada conjunto de variables con la QLIKE como pérdida, expresado en porcentaje. Incluye además el valor p del test de Clark-West de F1 frente a F0 y de F2 frente a F1, junto con el del test de Diebold-Mariano del estimador con F0 frente al HAR-RV.

Tabla C.1: Resultados completos por serie, horizonte y estimador, con la QLIKE como pérdida

Serie	Horizonte	Estimador	R^2_{OOS} (%)			Clark-West (p)		DM (p)
			F0	F1	F2	F1/F0	F2/F1	F0 frente al HAR
S&P 500	mensual	HAR	0,0	−4,5	−13,7	0,678	0,735	n.a.
		Elastic Net	0,3	−4,1	−0,5	0,666	0,052	0,594
		SVR*	1,3	−2,1	−18,2	0,230	0,908	0,739
		XGBoost	6,8	4,7	3,4	0,709	0,036	0,073
	semanal	HAR	0,0	−0,2	n.a.	0,592	n.a.	n.a.
		Elastic Net	0,5	0,5	n.a.	0,728	n.a.	0,092
		SVR*	2,7	1,0	n.a.	0,779	n.a.	0,066
		XGBoost	5,5	7,0	n.a.	0,128	n.a.	0,054
Brent	mensual	HAR*	0,0	−3,2	−11,4	0,948	0,426	n.a.
		Elastic Net	0,0	−3,2	0,4	0,948	0,085	0,449
		SVR	−0,2	−0,5	−7,3	0,594	0,304	0,926
		XGBoost	−2,6	−12,3	−7,4	0,156	0,005	0,358
	semanal	HAR*	0,0	−0,1	n.a.	0,492	n.a.	n.a.
		Elastic Net	0,0	−0,1	n.a.	0,493	n.a.	0,140
		SVR	1,2	3,8	n.a.	0,011	n.a.	0,007
		XGBoost	2,5	2,4	n.a.	0,034	n.a.	0,263
WTI	mensual	HAR	0,0	−4,7	−22,8	0,978	0,680	n.a.
		Elastic Net	0,0	−4,7	−22,8	0,978	0,680	0,608
		SVR*	−2,1	−1,2	−16,9	0,050	0,911	0,491
		XGBoost	−4,4	−17,6	−10,1	0,082	0,003	0,377
	semanal	HAR*	0,0	−0,3	n.a.	0,773	n.a.	n.a.
		Elastic Net	0,0	−0,3	n.a.	0,774	n.a.	0,658
		SVR	−0,1	2,0	n.a.	0,014	n.a.	0,866

Continúa en la página siguiente

Tabla C.1 (continuación)

Serie	Horizonte	Estimador	R^2_{OOS} (%)			Clark-West (p)		DM (p)
			F0	F1	F2	F1/F0	F2/F1	F0 frente al HAR
		XGBoost	−4,0	0,6	n.a.	<0,001	n.a.	0,082
Oro	mensual	HAR	0,0	−11,8	−31,0	0,867	0,952	n.a.
		Elastic Net	0,0	−11,8	−18,7	0,867	0,760	0,750
		SVR*	−1,6	−20,1	−35,2	0,814	0,791	0,425
		XGBoost	−4,5	−11,3	−16,6	0,666	0,727	0,215
	semanal	HAR	0,0	−2,2	n.a.	0,900	n.a.	n.a.
		Elastic Net	0,0	−2,1	n.a.	0,894	n.a.	0,559
		SVR*	0,5	−5,2	n.a.	0,850	n.a.	0,688
		XGBoost	1,2	−0,8	n.a.	0,721	n.a.	0,616
Bono del Tesoro	mensual	HAR	0,0	−1,8	−10,4	0,189	0,421	n.a.
		Elastic Net	0,0	−1,8	−7,5	0,194	0,411	0,463
		SVR*	−5,0	−10,8	−14,8	0,053	0,081	0,056
		XGBoost	−2,5	−25,1	−2,1	0,152	<0,001	0,321
	semanal	HAR	0,0	−0,6	n.a.	0,215	n.a.	n.a.
		Elastic Net	0,0	−0,6	n.a.	0,214	n.a.	0,799
		SVR*	−0,4	−1,9	n.a.	0,841	n.a.	0,536
		XGBoost	−1,9	−3,1	n.a.	0,136	n.a.	0,167
Bitcoin	mensual	HAR	0,0	4,5	−1,9	0,001	0,891	n.a.
		Elastic Net	−0,6	−2,6	−17,3	0,947	0,996	0,748
		SVR*	0,1	7,8	−17,1	<0,001	0,994	0,966
		XGBoost	−0,1	−0,6	−4,3	0,510	0,941	0,978
	semanal	HAR	0,0	0,6	n.a.	0,048	n.a.	n.a.
		Elastic Net*	2,7	2,2	n.a.	0,617	n.a.	0,161
		SVR	1,0	1,9	n.a.	0,056	n.a.	<0,001
		XGBoost	2,5	2,8	n.a.	0,490	n.a.	0,408

Nota. El R^2_{OOS} es la mejora porcentual de la pérdida frente al HAR-RV, de modo que un valor positivo indica que el modelo predice mejor que la referencia. El asterisco identifica el modelo principal de cada caso, y la abreviatura n.a. indica que la comparación no se aplica, porque F2 solo se evalúa en el horizonte mensual y el HAR-RV no se compara consigo mismo. Los contrastes de Clark-West son unilaterales y emplean errores estándar robustos a heterocedasticidad y autocorrelación. DM es el test de Diebold-Mariano, bilateral, del estimador con F0 frente al HAR-RV.

La tabla C.2 repite la anterior con el MSE como pérdida, para comprobar que las conclusiones no dependen de la pérdida elegida (sección 2.6.3). Los valores p del test de Clark-West coinciden con los de la tabla C.1, porque el test se construye sobre el error cuadrático.

Tabla C.2: Resultados por serie, horizonte y estimador, con el MSE como pérdida

Serie	Horizonte	Estimador	R^2_{OOS} (%)			Clark-West (p)		DM (p)
			F0	F1	F2	F1/F0	F2/F1	F0 frente al HAR
S&P 500	mensual	HAR	0,0	*0,0*	−7,3	0,678	0,735	n.a.
		Elastic Net	1,1	*1,1*	2,2	0,666	0,052	0,269
		SVR*	−14,1	*−13,7*	*−4,7*	0,230	0,908	0,214
		XGBoost	−10,2	*−6,5*	*0,3*	0,709	0,036	0,273
	semanal	HAR	0,0	*0,5*	n.a.	0,592	n.a.	n.a.
		Elastic Net	0,9	1,9	n.a.	0,728	n.a.	0,126
		SVR*	−4,2	−10,0	n.a.	0,779	n.a.	0,401
		XGBoost	−46,4	−33,1	n.a.	0,128	n.a.	0,293
Brent	mensual	HAR*	0,0	−1,5	−12,3	0,948	0,426	n.a.
		Elastic Net	0,0	−1,5	*−2,6*	0,948	0,085	0,596
		SVR	0,8	*1,4*	−9,2	0,594	0,304	0,734
		XGBoost	−4,3	−5,8	*−10,0*	0,156	0,005	0,396
	semanal	HAR*	0,0	−0,4	n.a.	0,492	n.a.	n.a.
		Elastic Net	0,0	−0,4	n.a.	0,493	n.a.	0,990
		SVR	0,7	3,4	n.a.	0,011	n.a.	0,207
		XGBoost	−0,4	−6,8	n.a.	0,034	n.a.	0,924
WTI	mensual	HAR	0,0	−4,1	−20,8	0,978	0,680	n.a.
		Elastic Net	0,0	−4,1	−20,8	0,978	0,680	0,471
		SVR*	−4,4	−1,5	−8,7	0,050	0,911	0,508
		XGBoost	−14,4	−19,1	−10,4	0,082	0,003	0,397
	semanal	HAR*	0,0	−0,2	n.a.	0,773	n.a.	n.a.
		Elastic Net	0,0	−0,2	n.a.	0,774	n.a.	0,886
		SVR	−1,3	2,0	n.a.	0,014	n.a.	0,324
		XGBoost	−23,0	*−24,2*	n.a.	<0,001	n.a.	0,078
Oro	mensual	HAR	0,0	−3,8	−9,0	0,867	0,952	n.a.
		Elastic Net	0,0	−3,8	−6,1	0,867	0,760	0,511
		SVR*	−3,2	−6,4	−11,6	0,814	0,791	0,127
		XGBoost	−3,4	−4,6	−6,5	0,666	0,727	0,046
	semanal	HAR	0,0	−0,5	n.a.	0,900	n.a.	n.a.
		Elastic Net	0,0	−0,5	n.a.	0,894	n.a.	0,960
		SVR*	−0,4	−1,0	n.a.	0,850	n.a.	0,845
		XGBoost	1,8	0,9	n.a.	0,721	n.a.	0,503
Bono del Tesoro	mensual	HAR	0,0	−3,9	−15,8	0,189	0,421	n.a.
		Elastic Net	0,0	−3,8	−9,9	0,194	0,411	0,451
		SVR*	−4,3	−24,4	*−15,3*	0,053	0,081	0,005
		XGBoost	−5,8	−20,9	2,6	0,152	<0,001	0,029
	semanal	HAR	0,0	−1,3	n.a.	0,215	n.a.	n.a.
		Elastic Net	0,0	−1,3	n.a.	0,214	n.a.	0,143

Continúa en la página siguiente

Tabla C.2 (continuación)

Serie	Horizonte	Estimador	R^2_{OOS} (%)			Clark-West (p)		DM (p)
			F0	F1	F2	F1/F0	F2/F1	F0 frente al HAR
		SVR*	−0,4	−2,2	n.a.	0,841	n.a.	0,722
		XGBoost	−1,6	−6,5	n.a.	0,136	n.a.	0,538
Bitcoin	mensual	HAR	0,0	5,4	−28,3	0,001	0,891	n.a.
		Elastic Net	2,5	2,1	−17,6	0,947	0,996	0,262
		SVR*	2,3	14,3	−19,4	<0,001	0,994	0,150
		XGBoost	0,8	*4,0*	2,5	0,510	0,941	0,844
	semanal	HAR	0,0	1,5	n.a.	0,048	n.a.	n.a.
		Elastic Net*	4,2	3,6	n.a.	0,617	n.a.	<0,001
		SVR	1,2	2,4	n.a.	0,056	n.a.	<0,001
		XGBoost	4,0	4,4	n.a.	0,490	n.a.	0,036

Nota. Los valores en cursiva señalan que la variación del R^2_{OOS} respecto al conjunto anterior, de F0 a F1 o de F1 a F2, tiene signo distinto con el MSE que con la QLIKE. El valor p de DM corresponde al test de Diebold-Mariano sobre el MSE. El asterisco y n.a. tienen el mismo significado que en la tabla C.1.

La tabla C.3 indica, para cada serie y horizonte, los modelos que forman parte del conjunto de confianza de modelos y los que quedan excluidos. El conjunto se calcula sobre la QLIKE de todos los modelos, con un nivel del 10%, según el procedimiento de la sección 2.6.3. Cada modelo se identifica por su estimador y su conjunto de variables.

Tabla C.3: Conjunto de confianza de modelos (MCS) por serie y horizonte

Serie	Horizonte	Incluidos	Excluidos
S&P 500	mensual	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1, Elastic Net F2, HAR F2, SVR F2, XGBoost F2	ninguno
	semanal	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1	ninguno
Brent	mensual	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1, Elastic Net F2, HAR F2, SVR F2, XGBoost F2	ninguno
	semanal	SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1	HAR F0, Elastic Net F0
WTI	mensual	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1, SVR F2, XGBoost F2	HAR F2, Elastic Net F2

Continúa en la página siguiente

Tabla C.3 (continuación)

Serie	Horizonte	Incluidos	Excluidos
	semanal	Elastic Net F0, HAR F0, SVR F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1	XGBoost F0
Oro	mensual	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1, Elastic Net F2, HAR F2, SVR F2, XGBoost F2	ninguno
	semanal	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1	ninguno
Bono del Tesoro	mensual	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, Elastic Net F2, HAR F2, XGBoost F2	SVR F1, XGBoost F1, SVR F2
	semanal	Elastic Net F0, HAR F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1	ninguno
Bitcoin	mensual	HAR F1, SVR F1	HAR F0, Elastic Net F0, SVR F0, XGBoost F0, Elastic Net F1, XGBoost F1, HAR F2, Elastic Net F2, SVR F2, XGBoost F2
	semanal	Elastic Net F0, SVR F0, XGBoost F0, Elastic Net F1, HAR F1, SVR F1, XGBoost F1	HAR F0

Nota. HAR designa al HAR-RV con F0 y al HAR-X con F1 y F2.

APÉNDICE D

CONTRIBUCIÓN Y CONCENTRACIÓN TEMPORAL

Este apéndice recoge dos tablas que complementan la descripción de los resultados del capítulo 4. La primera indica si cada bloque de variables aporta información a los modelos con composición. La segunda indica si la diferencia de pérdidas entre los modelos con y sin intensidad es sostenida o se concentra en pocos meses.

Importancia por permutación

La tabla D.1 muestra el aumento de la pérdida QLIKE del periodo de prueba al desordenar al azar los valores de un bloque de variables, con el modelo ya estimado, en los 24 modelos del horizonte mensual con F2. Cada valor es la diferencia absoluta entre la QLIKE con el bloque desordenado y la QLIKE original, promediada en veinte permutaciones con semilla fija. El modelo evaluado es el mismo que se emplea en el análisis SHAP, estimado una sola vez con el periodo de entrenamiento. Un valor positivo indica que la pérdida aumenta al desordenar el bloque, es decir, que el bloque aporta información útil al modelo. Un valor negativo indica que la pérdida disminuye, de modo que el bloque perjudicaba la predicción. Las proporciones de la composición se desordenan por meses completos, porque su valor es constante dentro de cada mes.

Concentración temporal de la diferencia de pérdidas

La tabla D.2 descompone por meses la diferencia acumulada de la pérdida QLIKE entre F0 y F1 que muestran las figuras del capítulo 4. Para cada modelo principal y para los tres modelos secundarios de energía semanal con mejora significativa, recoge la diferencia total del periodo de prueba, los tres meses que más contribuyen a ella en el mismo sentido que el total y el porcentaje del total que explican. Un total positivo indica que el modelo con F1 predice mejor que el modelo con F0, y uno negativo, que predice peor.

El porcentaje explicado puede superar el 100 %. Ocurre cuando el resto de meses contribuye en sentido contrario, de modo que los tres meses principales suman más que el saldo final. Un valor alto indica que la diferencia depende de pocos episodios, mientras que un valor bajo indica que se acumula a lo largo del periodo.

Tabla D.1: Horizonte mensual, conjunto F2.

Serie	Estimador	Volatilidad pasada	Intensidad	Composición
S&P 500	HAR	0,2315	$-0{,}0002$	$-0{,}0068$
	Elastic Net	0,2042	$-0{,}0002$	$-0{,}0011$
	SVR	0,2904	$-0{,}0033$	$-0{,}0144$
	XGBoost	0,2908	0,0021	$-0{,}0099$
Brent	HAR	0,2610	$-0{,}0039$	$-0{,}0165$
	Elastic Net	0,2461	$-0{,}0004$	$-0{,}0042$
	SVR	0,2035	0,0065	$-0{,}0172$
	XGBoost	0,2188	$-0{,}0025$	0,0101
WTI	HAR	0,1731	$-0{,}0054$	$-0{,}0209$
	Elastic Net	0,1731	$-0{,}0054$	$-0{,}0209$
	SVR	0,1795	0,0023	$-0{,}0246$
	XGBoost	0,1587	$-0{,}0004$	0,0143
Oro	HAR	0,2984	$-0{,}0217$	$-0{,}0370$
	Elastic Net	0,2688	$-0{,}0162$	$-0{,}0170$
	SVR	0,2954	$-0{,}0281$	$-0{,}0334$
	XGBoost	0,2082	$-0{,}0002$	$-0{,}0138$
Bono del Tesoro	HAR	0,1176	0,0029	0,0006
	Elastic Net	0,1140	0,0000	0,0007
	SVR	0,1069	0,0016	0,0044
	XGBoost	0,1243	$-0{,}0008$	0,0049
Bitcoin	HAR	0,0202	0,0005	0,0032
	Elastic Net	0,0035	0,0000	0,0000
	SVR	0,0007	0,0015	0,0017
	XGBoost	0,0125	0,0000	$-0{,}0020$

HAR designa al HAR-X con F2. Un valor positivo indica que desordenar el bloque empeora la predicción. En Elastic Net de Bitcoin, los coeficientes de la intensidad y de la composición son nulos.

Tabla D.2: Meses con mayor contribución a la diferencia acumulada de la pérdida QLIKE entre F0 y F1.

Caso	Estimador	Total	Primer mes	Segundo mes	Tercer mes	Explicado
Modelos principales						
S&P 500, mensual	SVR	$-8{,}90$	jul. 2024 ($-12{,}66$)	mar. 2025 ($-6{,}31$)	abr. 2022 ($-3{,}57$)	253 %
S&P 500, semanal	SVR	$-7{,}66$	jul. 2024 ($-2{,}09$)	dic. 2024 ($-2{,}01$)	oct. 2025 ($-1{,}28$)	70 %
Brent, mensual	HAR	$-9{,}61$	feb. 2022 ($-3{,}95$)	mar. 2022 ($-2{,}22$)	feb. 2026 ($-1{,}65$)	81 %
Brent, semanal	HAR	$-0{,}52$	mar. 2022 ($-2{,}38$)	abr. 2025 ($-1{,}40$)	jun. 2025 ($-0{,}87$)	897 %
WTI, mensual	SVR	2,17	feb. 2022 (2,36)	abr. 2026 (1,53)	jun. 2022 (1,02)	226 %
WTI, semanal	HAR	$-1{,}14$	mar. 2022 ($-2{,}07$)	feb. 2022 ($-1{,}11$)	abr. 2025 ($-0{,}64$)	336 %
Oro, mensual	SVR	$-55{,}25$	ene. 2026 ($-21{,}99$)	abr. 2025 ($-6{,}32$)	feb. 2022 ($-6{,}08$)	62 %
Oro, semanal	SVR	$-27{,}28$	mar. 2022 ($-12{,}11$)	ene. 2026 ($-8{,}25$)	abr. 2025 ($-3{,}60$)	88 %
Bono del Tesoro, mensual	SVR	$-7{,}03$	mar. 2022 ($-1{,}96$)	ago. 2024 ($-1{,}84$)	dic. 2025 ($-1{,}82$)	80 %
Bono del Tesoro, semanal	SVR	$-4{,}42$	feb. 2022 ($-2{,}26$)	abr. 2026 ($-0{,}92$)	mar. 2022 ($-0{,}60$)	85 %
Bitcoin, mensual	SVR	33,47	mar. 2026 (3,80)	abr. 2026 (3,75)	jun. 2026 (3,46)	33 %
Bitcoin, semanal	Elastic Net	$-4{,}62$	jun. 2022 ($-0{,}94$)	sep. 2023 ($-0{,}84$)	feb. 2024 ($-0{,}71$)	54 %
Modelos secundarios de energía semanal						
Brent, semanal	SVR	11,81	mar. 2026 (7,04)	mar. 2022 (3,65)	feb. 2022 (1,66)	105 %
WTI, semanal	SVR	8,60	mar. 2026 (4,88)	jun. 2025 (2,29)	feb. 2022 (1,57)	102 %
WTI, semanal	XGBoost	18,57	mar. 2026 (7,83)	feb. 2022 (6,54)	mar. 2022 (4,41)	101 %

Las diferencias son sumas de las diferencias diarias de la pérdida QLIKE entre F0 y F1, en las mismas unidades que las figuras de diferencia acumulada. Entre paréntesis figura la contribución de cada mes. HAR designa al HAR-X.